Manual de Microeconometría

Carlos de Anta Puig

2026-01-01

© 2026 Carlos de Anta Puig

Publicado por DigitalReasons

www.digitalreasons.es

ISBN: 978-84-XXXX-XXX-X

Primera edición: 2026

Reservados todos los derechos. Ninguna parte de esta publicación puede ser reproducida, almacenada o transmitida en cualquier forma o por cualquier medio, ya sea electrónico, mecánico, fotocopia, grabación o cualquier otro, sin el permiso previo del autor.

A mis alumnos,
por su curiosidad, su esfuerzo
y las preguntas que me obligan
a pensar mejor las respuestas.

A quienes creen que la econometría
es difícil: lo es.
Pero merece la pena.

Índice

Prólogo **1**
Contenido del Tomo I iii
Material complementario iii
Convenciones iii

1 Fundamentos de Probabilidad, Inferencia y Econometría **1**
1.1 Introducción: ¿qué necesitamos saber antes de empezar? 1
1.2 Repaso de probabilidad 3
1.2.1 Variables aleatorias 3
1.2.2 Función de densidad y distribución acumulada . 3
1.2.3 Esperanza, varianza y momentos 3
1.2.4 Distribuciones clave para microeconometría . . . 4
1.2.5 Ejemplo numérico: cálculo de probabilidades con $\Phi(z)$ 7
1.3 Estimación e inferencia 9
1.3.1 Estimadores: propiedades deseables 9
1.3.2 Método de Máxima Verosimilitud (MV) 9
1.4 Contraste de hipótesis 13
1.4.1 Contraste de Wald 13
1.4.2 Contraste de Razón de Verosimilitudes (LR) . . . 13
1.4.3 Contraste del Multiplicador de Lagrange (LM / Score) 14
1.4.4 Comparación de los tres contrastes 14
1.4.5 Ejemplo numérico: test de significatividad individual 15
1.5 Repaso del Modelo Lineal (MCO) 16
1.5.1 Formulación 16
1.5.2 Supuestos clásicos 16

1.5.3 Propiedades de los estimadores MCO (Gauss-Markov) 16
1.5.4 Bondad de ajuste: R^2 y R^2 ajustado 17
1.5.5 Limitaciones de MCO cuando la variable dependiente es limitada 17
1.6 Especificación y diagnóstico del modelo 19
1.6.1 ¿Qué significa que un modelo esté bien especificado? 19
1.6.2 Sesgo por omisión de variables relevantes 19
1.6.3 Forma funcional: contraste RESET de Ramsey . . 20
1.6.4 Multicolinealidad 20
1.6.5 Análisis de residuos 21
1.6.6 Normalidad de los residuos 21
1.6.7 Homocedasticidad 21
1.6.8 Bondad de ajuste: más allá del R^2 22
1.7 Conceptos avanzados necesarios 23
1.7.1 Variable latente 23
1.7.2 Efectos marginales 23
1.8 Funciones esenciales en R 25
Código R del capítulo 25

2 Datos con Variable Dependiente Limitada 27
2.1 Introducción: ¿qué es una variable dependiente limitada? 27
2.1.1 ¿Por qué MCO no funciona? 28
2.1.2 Clasificación de las variables dependientes limitadas 29
2.2 Variables dependientes limitadas binarias 31
2.2.1 Concepto 31
2.2.2 La distribución de Bernoulli 32
2.2.3 La distribución Binomial 36
2.2.4 El concepto de variable latente 39
2.2.5 Modelo Lineal de Probabilidad (MLP): una primera aproximación 41
2.3 Variables dependientes limitadas multinomiales 42
2.3.1 Concepto 42

2.3.2 Variables multinomiales ordenadas 43
2.3.3 Variables multinomiales no ordenadas 44
2.3.4 La distribución Multinomial 45
2.4 Variables dependientes limitadas continuas 48
2.4.1 Concepto 48
2.4.2 Variables censuradas 48
2.4.3 Variables truncadas 51
2.4.4 Distribuciones para datos censurados y truncados 53
2.4.5 Resumen: censura vs. truncamiento 55
2.5 Funciones esenciales en R 57
2.6 Resumen y hoja de ruta 59
2.6.1 Lo que hemos aprendido 59
2.6.2 Conexión con los temas siguientes 59
2.6.3 Tabla-resumen de distribuciones 60
Código R del capítulo 60

3 Modelos de Elección Discreta 61
3.1 Introducción: ¿por qué modelos de elección discreta? . . 61
3.2 Fundamentos estadísticos 63
3.2.1 Variable aleatoria 63
3.2.2 La distribución de Bernoulli 64
3.2.3 Función de densidad 65
3.2.4 Función de distribución acumulada (CDF) 66
3.2.5 La verosimilitud: corazón de la estimación 67
3.3 El Modelo Lineal de Probabilidad (MLP) 69
3.3.1 Planteamiento 69
3.3.2 Limitaciones del MLP 69
3.3.3 El modelo que vamos a estimar 70
3.3.4 Ejemplo en R 70
3.4 El modelo Probit 73
3.4.1 Planteamiento 73
3.4.2 Estimación en R 73
3.5 El modelo Logit 75
3.5.1 Planteamiento 75
3.5.2 Estimación en R 76

3.6 El flujo completo: de las X a la probabilidad 77
3.7 Efectos marginales 78
3.7.1 El problema: ¿qué significan realmente los coeficientes? 78
3.7.2 Ejemplo numérico paso a paso 78
3.7.3 La fórmula general del efecto marginal 81
3.7.4 ¿Cómo resumir el efecto en un solo número? . . . 83
3.7.5 Cálculo en R de los efectos marginales 86
3.8 Odds ratios (solo Logit) 89
3.8.1 ¿Qué es el odds? 89
3.8.2 Los log-odds y el modelo Logit: demostración . . 89
3.9 Bondad de ajuste: Pseudo-R^2 de McFadden 97
3.9.1 ¿Por qué no podemos usar el R^2 clásico? 97
3.9.2 Criterios de información: AIC y BIC 97
3.9.3 Cálculo en R 98
3.10 Contrastes de hipótesis 100
3.10.1 Significación individual: el test z (o test de Wald individual) 100
3.10.2 Test de Wald (significación conjunta) 102
3.10.3 Test de Razón de Verosimilitud (LR) 104
3.11 Comparación completa: MLP vs Probit vs Logit 107
3.11.1 Coeficientes 107
3.11.2 Efectos marginales (sí son comparables) 107
3.11.3 Gráfico comparativo 108
3.11.4 Resumen comparativo 108
3.12 Resumen: lo esencial en 10 puntos 110
3.13 Funciones esenciales en R 111
3.13.1 Estimación 111
3.13.2 Predicción 111
3.13.3 Efectos marginales 111
3.13.4 Odds ratios (solo Logit) 111
3.13.5 Bondad de ajuste 111
3.13.6 Contrastes de hipótesis 111
3.13.7 Clasificación 112

Código R del capítulo 112

4 Modelos para Datos Censurados (Tobit) 113

4.1 Introducción: ¿por qué modelos para datos censurados? . 113
4.2 Datos censurados: conceptos básicos 115
4.2.1 ¿Qué es la censura? 115
4.2.2 Censura por la izquierda 115
4.2.3 Censura por la derecha 115
4.2.4 Censura en ambos lados 116
4.2.5 La variable latente y^* 116
4.2.6 La densidad de datos censurados: una mezcla discreta-continua 116
4.3 El modelo Tobit 118
4.3.1 Origen 118
4.3.2 Especificación del modelo 118
4.3.3 Ejemplos económicos clásicos 118
4.3.4 La función de log-verosimilitud 119
4.3.5 La reparametrización de Olsen (1978) 121
4.4 ¿Por qué MCO no funciona con datos censurados? 123
4.4.1 El sesgo de MCO: explicación detallada 123
4.4.2 Demostración visual en R 124
4.4.3 Comparación numérica: MCO vs Tobit 124
4.5 Interpretación de los coeficientes 125
4.5.1 ¿Por qué los coeficientes no son directamente efectos marginales? 125
4.5.2 Las tres medias condicionales: derivación detallada 125
4.5.3 Tabla resumen: las tres medias condicionales . . . 127
4.5.4 Relación entre $\hat{\beta}_{MCO}$ y $\hat{\beta}_{Tobit}$ 128
4.5.5 Reglas de interpretación de coeficientes 129
4.5.6 Ejemplo numérico detallado: horas trabajadas . . 129
4.5.7 Efecto de una variable dummy: tener hijos 131
4.5.8 Tabla resumen de interpretación (modelo de horas trabajadas) 131
4.5.9 Proporción de censura 131
4.5.10 Guía de interpretación 132

4.6 Pruebas de especificación 134
4.6.1 La idea central del diagnóstico: modelos anidados 134
4.6.2 Diagnóstico práctico: los tres contrastes esenciales 134
4.6.3 Test del multiplicador de Lagrange para heterocedasticidad 135
4.6.4 Test de normalidad de los errores 136
4.6.5 Tablas resumen: pruebas de especificación del modelo Tobit 138
4.7 Ejemplo práctico completo en R 140
4.7.1 El problema: aptitud académica censurada 140
4.7.2 Carga y exploración de datos 140
4.7.3 Análisis gráfico 141
4.7.4 Estimación del modelo Tobit 143
4.7.5 Interpretación de los coeficientes 143
4.7.6 Cálculo de p-valores 144
4.7.7 Significación de variables categóricas: Test de razón de verosimilitud 144
4.7.8 Bondad de ajuste 144
4.7.9 Comparación final: MCO vs Tobit 146
4.7.10 Efectos marginales 147
4.7.11 Pruebas de especificación del modelo estimado . 148
4.8 Extensiones del modelo Tobit 150
4.8.1 El método de Heckman en dos etapas 150
4.8.2 Modelo Tobit generalizado 150
4.9 Resumen: lo esencial en 10 puntos 151
4.10 Funciones esenciales en R 152
4.10.1 Estimación 152
4.10.2 Extracción de resultados 152
4.10.3 Efectos marginales 152
4.10.4 Diagnósticos y residuos 152
4.10.5 Comparación de modelos 153
4.10.6 Comparación MCO vs Tobit 153
Código R del capítulo 154

5 Modelos para Datos de Recuento 155

5.1 Introducción: ¿Por qué modelos para datos de recuento? 155
5.1.1 El modelo Poisson: concepto fundamental 156
5.2 Conceptos fundamentales de datos de recuento 157
5.2.1 ¿Qué es un dato de recuento? 157
5.2.2 Propiedades estadísticas clave 157
5.3 La distribución de Poisson 159
5.3.1 Concepto y propiedades matemáticas 159
5.3.2 Ejemplos de cálculo 160
5.4 Modelo de regresión de Poisson 161
5.4.1 Especificación del modelo 161
5.4.2 Estimación por máxima verosimilitud 161
5.4.3 Interpretación de coeficientes 162
5.5 Modelo de regresión Binomial Negativa 164
5.5.1 Motivación: El problema de la sobredispersión . . 164
5.5.2 Especificación del modelo Binomial Negativo . . . 165
5.5.3 Estimación del modelo NB 166
5.6 Inferencia estadística y comparación de modelos 167
5.6.1 Test de Wald (significación individual) 167
5.6.2 Test de razón de verosimilitud (significación conjunta) 169
5.6.3 Test de sobredispersión: Poisson vs Binomial Negativo 170
5.6.4 Medidas de bondad de ajuste 171
5.6.5 Procedimiento completo de comparación Poisson vs Binomial Negativo 179
5.6.6 Tablas resumen 180
5.7 Extensiones y temas avanzados 181
5.7.1 Sobredispersión: detección y corrección 181
5.7.2 Datos con exceso de ceros 181
5.7.3 Variables de offset 182
5.8 Resumen: lo esencial en 10 puntos 183
5.9 Funciones esenciales en R 184
5.9.1 Estimación de modelos 184
5.9.2 Extracción de resultados 184

5.9.3 Bondad de ajuste y comparación 184
5.9.4 Test de razón de verosimilitud (manual) 184
5.9.5 Predicción 184
5.9.6 Modelos con exceso de ceros 185
5.9.7 Offset (tasas) 185
Código R del capítulo 186

6 Datos de Panel **187**
6.1 Introducción: ¿por qué datos de panel? 187
6.2 Conceptos básicos 188
6.2.1 Estructura de los datos 188
6.2.2 Panel corto y panel largo 188
6.2.3 Panel balanceado y no balanceado 188
6.2.4 Descomposición de la variación: within, between y overall 188
6.3 El modelo general de datos de panel 191
6.3.1 Especificación 191
6.3.2 ¿Efectos fijos o efectos aleatorios? 191
6.4 Estimador Pooled OLS 192
6.4.1 Concepto 192
6.4.2 Cuándo es válido 192
6.4.3 El problema fundamental 192
6.5 Modelo de efectos fijos (estimador within) 193
6.5.1 Intuición 193
6.5.2 Ejemplo numérico paso a paso 193
6.5.3 Propiedades 194
6.5.4 Equivalencia con variables dummy (LSDV) 194
6.5.5 El R^2 en datos de panel 194
6.6 Estimador en primeras diferencias 196
6.7 Modelo de efectos aleatorios (GLS) 197
6.7.1 El supuesto clave 197
6.7.2 La transformación cuasi-within 197
6.7.3 Ventajas e inconvenientes 197
6.8 Test de Hausman: ¿efectos fijos o aleatorios? 199
6.8.1 Lógica del test 199

6.8.2 El estadístico 199
6.8.3 Regla de decisión 199
6.8.4 Ejemplo numérico 199
6.9 Diagnóstico en datos de panel 201
6.9.1 ¿Hay efectos individuales? (Test F) 201
6.9.2 ¿Hay efectos aleatorios? (Test de Breusch-Pagan) . 201
6.9.3 ¿Hay autocorrelación serial? 201
6.9.4 ¿Hay heterocedasticidad? 201
6.9.5 Errores robustos agrupados 201
6.10 Ejemplo práctico completo en R 203
6.10.1 Los datos 203
6.10.2 Estimación de los tres modelos 203
6.10.3 Test de Hausman 203
6.10.4 Diagnósticos 203
6.11 Extensiones 205
6.11.1 Efectos fijos bidireccionales 205
6.11.2 Difference-in-Differences (DiD) 205
6.11.3 Paneles dinámicos 205
6.12 Resumen: lo esencial en 10 puntos 206
6.13 Funciones esenciales en R 207
6.13.1 Estimación 207
6.13.2 Efectos individuales 207
6.13.3 Tests 207
6.13.4 Diagnóstico 207
6.13.5 Errores robustos 207
6.13.6 Paneles dinámicos 207
Código R del capítulo 208

Bibliografía **209**

Prólogo

Este manual nació de una frustración y de una convicción.

La frustración es la que siente cualquier profesor que, tras años de enseñanza, constata que los materiales disponibles no terminan de funcionar. Los manuales internacionales de referencia — Cameron y Trivedi, Wooldridge, Greene — son obras maestras, pero están escritos para investigadores, no para alumnos que se enfrentan por primera vez a un modelo Logit o a un panel de datos. Los apuntes de las universidades, por su parte, suelen pecar de lo contrario: son telegráficos, dan por supuestos conceptos que el alumno no domina, y saltan de la fórmula al código sin detenerse a explicar el porqué de cada paso.

La convicción es que la microeconometría puede explicarse de otra manera. Con rigor, sí — las derivaciones formales están aquí, completas y sin atajos —, pero también con claridad pedagógica, con ejemplos numéricos resueltos paso a paso, con gráficos que iluminan la intuición detrás de las fórmulas, y con un hilo narrativo que conecta cada modelo con los problemas económicos reales que lo motivaron.

Este manual está escrito pensando en mis alumnos. En los que llegan al curso con buena base de estadística pero nunca han visto una variable latente. En los que saben ejecutar `lm()` en R pero no entienden qué pasa cuando la variable dependiente es binaria. En los que necesitan no solo saber *qué* hace un modelo, sino *por qué* lo hace, *cuándo* usarlo y *cómo* interpretar sus resultados de forma que un economista — no un estadístico — pueda tomar decisiones informadas.

Cada capítulo sigue una estructura deliberada: primero la motivación económica del problema, después la formulación del modelo con sus supuestos explícitos, a continuación la estimación y sus propiedades, luego la interpretación detallada de los resultados (que es donde la mayoría de los manuales se quedan cortos), los diagnósticos necesarios para validar el modelo, y finalmente un ejemplo práctico completo en R que el alumno puede reproducir íntegramente. Los scripts de R que acompañan cada capítulo están disponibles en el repositorio del manual:

https://github.com/carlanta/MicroEconometrics

El primer tomo cubre los modelos fundamentales: elección discreta (Probit y Logit), datos censurados (Tobit), datos de recuento (Poisson y Binomial Negativa) y datos de panel (efectos fijos y aleatorios). Un segundo tomo, actualmente en preparación, abordará variables instrumentales, modelos de duración, datos cualitativos y extensiones avanzadas.

Escribir este manual ha sido un trabajo enorme — mucho mayor de lo que imaginé cuando comencé. Pero cada vez que un alumno me dice que por fin entiende qué son los efectos marginales, o que ahora sabe interpretar un odds ratio, o que ha conseguido replicar un paper con los modelos del curso, siento que el esfuerzo ha merecido la pena. Si este libro consigue que algún alumno más disfrute aprendiendo microeconometría, habrá cumplido su propósito.

Carlos de Anta Puig
Madrid, marzo de 2026

Contenido del Tomo I

El tomo se organiza en seis capítulos:

- **Capítulo 0**: Fundamentos
- **Capítulo 1**: Variable dependiente limitada
- **Capítulo 2**: Elección discreta
- **Capítulo 3**: Tobit
- **Capítulo 4**: Recuento
- **Capítulo 5**: Panel

Material complementario

Scripts disponibles en:

https://github.com/carlanta/MicroEconometrics

Convenciones

- Ecuaciones numeradas por capítulo
- Tablas y figuras por capítulo
- Código R oculto

Capítulo 1

Fundamentos de Probabilidad, Inferencia y Econometría

1.1 Introducción: ¿qué necesitamos saber antes de empezar?

La **microeconometría** estudia el comportamiento de agentes individuales — personas, hogares, empresas — utilizando modelos estadísticos adaptados a la naturaleza de los datos. A diferencia de la econometría clásica, donde la variable dependiente suele ser continua y sin restricciones, en microeconometría la variable dependiente presenta características que exigen un tratamiento específico. En ocasiones se trata de una variable **binaria** que refleja una decisión discreta, como participar o no en el mercado laboral. En otros casos, la variable está **censurada,** por ejemplo, las horas trabajadas, que acumulan una masa de observaciones en cero para quienes no trabajan. También puede tratarse de un **recuento**, como el número de visitas al médico, que solo toma valores enteros no negativos. Finalmente, la variable puede ser **ordenada**, como el nivel de satisfacción (bajo, medio, alto), donde las categorías tienen un orden natural pero las distancias entre ellas no están definidas.

Cada una de estas situaciones requiere un modelo específico (Logit, Probit, Tobit, Poisson...), y todos ellos comparten un conjunto de **herramientas matemáticas y estadísticas** que debemos dominar antes de avanzar.

Este tema cubre esos fundamentos. El alumno que complete este capítulo dispondrá de las bases necesarias para seguir con confianza el resto del curso.

> **Nota:** Este tema es un *repaso*. Se asume que el alumno ha cursado Estadística y Econometría. El objetivo no es enseñar desde cero, sino consolidar y conectar los conceptos con la microeconometría.

Organizaremos el repaso en seis grandes bloques:

1. **Probabilidad**: variables aleatorias, distribuciones, esperanza y varianza.
2. **Estimación e inferencia**: propiedades de los estimadores y

Máxima Verosimilitud.

3. **Contrastes de hipótesis**: Wald, LR y LM.
4. **El modelo lineal (MCO)**: formulación, supuestos y limitaciones.
5. **Especificación y diagnóstico**: la checklist que todo econometrista debe seguir.
6. **Conceptos avanzados**: variable latente, efectos marginales.

1.2 Repaso de probabilidad

1.2.1 Variables aleatorias

Una **variable aleatoria** X es una función que asigna un valor numérico a cada resultado de un experimento aleatorio. Distinguimos dos tipos:

- **Discreta**: toma un conjunto numerable de valores. Ejemplo: número de hijos ($X \in \{0, 1, 2, ...\}$).
- **Continua**: toma cualquier valor en un intervalo. Ejemplo: renta ($X \in [0, +\infty)$).

1.2.2 Función de densidad y distribución acumulada

Para una variable continua X:

- La **función de densidad de probabilidad** (pdf) $f(x)$ describe la probabilidad relativa de que X tome un valor cercano a x. Cumple:

$$f(x) \geq 0 \quad \text{y} \quad \int_{-\infty}^{+\infty} f(x)\, dx = 1$$

- La **función de distribución acumulada** (cdf) $F(x)$ da la probabilidad de que X sea menor o igual que x:

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\, dt$$

La relación entre ambas es directa: $f(x) = F'(x)$.

Para una variable discreta, la pdf se sustituye por la **función de masa de probabilidad** (pmf):

$$P(X = x) = p(x), \quad \sum_{x} p(x) = 1$$

1.2.3 Esperanza, varianza y momentos

La **esperanza** (o media) de X mide su valor central:

$$E[X] = \int_{-\infty}^{+\infty} x\, f(x)\, dx \quad \text{(continua)} \qquad E[X] = \sum_x x\, p(x) \quad \text{(discreta)}$$

La **varianza** mide la dispersión alrededor de la media:

$$\text{Var}(X) = E\left[(X - E[X])^2\right] = E[X^2] - (E[X])^2$$

La **desviación típica** es $\sigma = \sqrt{\text{Var}(X)}$.

Propiedades útiles (que usaremos constantemente):

- $E[aX + b] = aE[X] + b$
- $\text{Var}(aX + b) = a^2\text{Var}(X)$
- Si X e Y son independientes: $E[XY] = E[X]E[Y]$

1.2.4 Distribuciones clave para microeconometría

A lo largo del curso utilizaremos cuatro distribuciones fundamentales. Conviene tenerlas bien presentes.

1.2.4.1 Distribución Normal

La distribución **Normal** o gaussiana $X \sim N(\mu, \sigma^2)$ tiene densidad:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

La **Normal estándar** ($\mu = 0$, $\sigma = 1$) tiene una notación especial que usaremos constantemente:

- $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ es la **densidad** (pdf).
- $\Phi(z) = P(Z \leq z)$ es la **distribución acumulada** (cdf).

Propiedades esenciales de ϕ y Φ:

- Simetría: $\phi(-z) = \phi(z)$ y $\Phi(-z) = 1 - \Phi(z)$.
- $\phi'(z) = -z \cdot \phi(z)$ (derivada de la densidad).
- $\Phi'(z) = \phi(z)$.

¿Por qué importa? En los modelos **Probit** y **Tobit**, las probabilidades y los efectos marginales se expresan directamente en función de Φ y ϕ. Si no se dominan, no se puede interpretar ninguno de estos modelos.

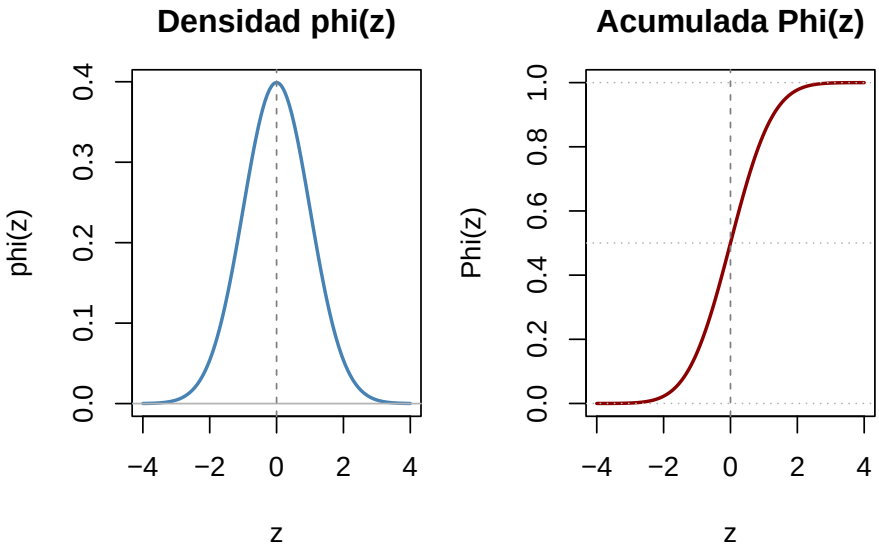

Figura 1.1: Distribución Normal estándar: densidad $\varphi(z)$ y acumulada $\Phi(z)$

1.2.4.2 Distribución Logística

La distribución **Logística** estándar tiene cdf:

$$\Lambda(z) = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}}$$

y densidad:

$$\lambda(z) = \frac{e^z}{(1+e^z)^2} = \Lambda(z)\,[1-\Lambda(z)]$$

¿Por qué importa? En los modelos **Logit**, las probabilidades se modelizan con Λ. La expresión $\Lambda(z)[1-\Lambda(z)]$ aparece en

todos los efectos marginales.

La Normal y la Logística son muy parecidas, pero la Logística tiene **colas más pesadas** (mayor probabilidad en los extremos).

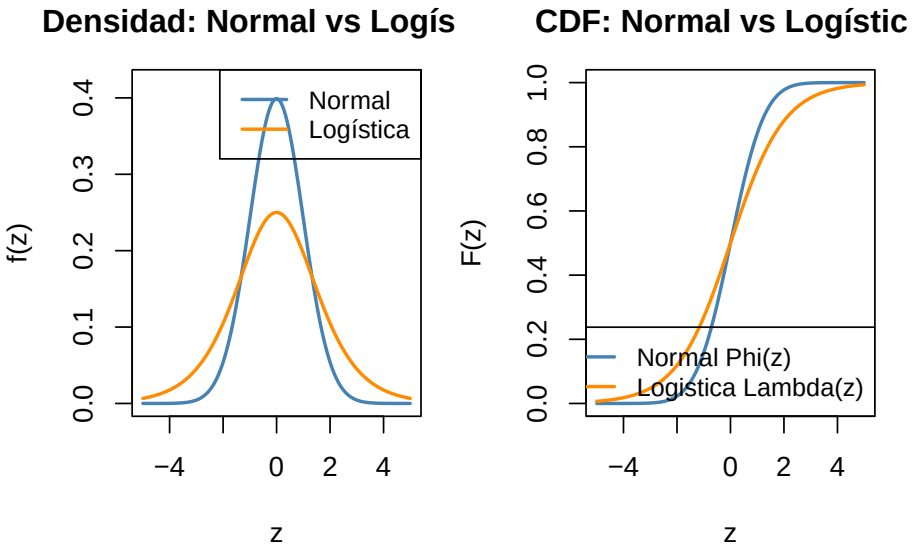

Figura 1.2: Comparación Normal vs Logística: densidad y distribución acumulada

1.2.4.3 Distribución de Poisson

La distribución de **Poisson** modela el número de veces que ocurre un evento en un intervalo. Si $X \sim \text{Poisson}(\lambda)$:

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

- $E[X] = \lambda$
- $\text{Var}(X) = \lambda$ (propiedad de **equidispersión**: media = varianza)

  ¿Por qué importa? En el Tema 4 estudiaremos modelos de **datos de recuento** basados en Poisson. La restricción de equidispersión es clave: cuando no se cumple, necesitamos la Binomial Negativa.

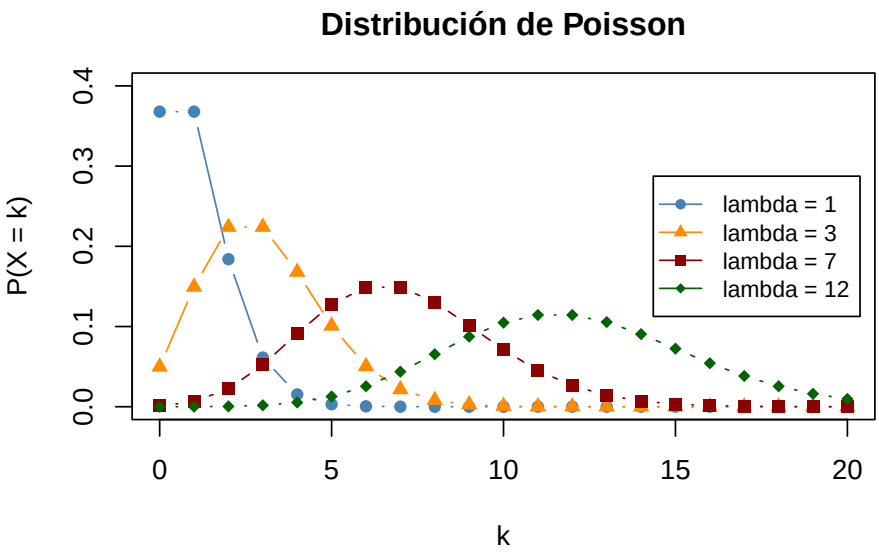

Figura 1.3: Distribución de Poisson para distintos valores de λ

1.2.4.4 Distribución Binomial

La distribución **Binomial** modela el número de éxitos en n ensayos independientes con probabilidad de éxito p. Si $X \sim \text{Bin}(n, p)$:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

- $E[X] = np$
- $\text{Var}(X) = np(1-p)$

El caso particular $n = 1$ es la distribución **Bernoulli**, que aparece en todos los modelos de variable dependiente binaria (Logit, Probit).

1.2.5 Ejemplo numérico: cálculo de probabilidades con $\Phi(z)$

Supongamos que la renta mensual de los hogares sigue una distribución $X \sim N(2000, 500^2)$, es decir, media 2000 € y desviación típica 500 €.

Pregunta: ¿Cuál es la probabilidad de que un hogar tenga una renta inferior a 1200 €?

Paso 1: Estandarizar.

$$z = \frac{x - \mu}{\sigma} = \frac{1200 - 2000}{500} = -1{,}6$$

Paso 2: Buscar $\Phi(-1{,}6)$.

$$P(X < 1200) = \Phi(-1{,}6) = 1 - \Phi(1{,}6) = 1 - 0{,}9452 = 0{,}0548$$

Interpretación: Aproximadamente un 5,5 % de los hogares tiene una renta inferior a 1200 €.

> **En R:** `pnorm(1200, mean = 2000, sd = 500)` devuelve directamente `0.0548`.

1.3 Estimación e inferencia

1.3.1 Estimadores: propiedades deseables

Un **estimador** $\widehat{\theta}$ es una función de los datos que utilizamos para aproximar un parámetro desconocido θ. Las propiedades deseables son:

Propiedad	Definición	Significado intuitivo
Insesgadez	$E[\widehat{\theta}] = \theta$	En promedio, acierta
Eficiencia	Menor varianza posible	Es el más preciso entre los insesgados
Consistencia	$\widehat{\theta} \xrightarrow{p} \theta$ cuando $n \to \infty$	Converge al valor real
Normalidad asintótica	$\sqrt{n}(\widehat{\theta} - \theta) \xrightarrow{d} N(0, V)$	Para muestras grandes, es aproximadamente normal

En microeconometría, la **consistencia** y la **normalidad asintótica** son las propiedades más importantes, ya que los estimadores de Máxima Verosimilitud (que usaremos constantemente) no suelen ser insesgados en muestras finitas, pero sí consistentes y asintóticamente normales.

1.3.2 Método de Máxima Verosimilitud (MV)

1.3.2.1 Concepto fundamental

Supongamos que disponemos de una muestra de n observaciones independientes $y_1, y_2, \dots, y_n$, cada una generada por una distribución con densidad $f(y_i|\theta)$ que depende de un parámetro desconocido θ.

La **función de verosimilitud** es la probabilidad conjunta de observar la muestra, vista como función de θ:

$$\mathcal{L}(\theta) = \prod_{i=1}^{n} f(y_i|\theta)$$

La idea de MV es: **elegir el valor de** θ que maximiza la probabilidad de haber observado los datos que tenemos.

En la práctica, maximizamos la **log-verosimilitud** (es más cómodo y numéricamente estable):

$$\ell(\theta) = \ln \mathcal{L}(\theta) = \sum_{i=1}^{n} \ln f(y_i|\theta)$$

La condición de primer orden es:

$$\frac{\partial \ell(\theta)}{\partial \theta} = 0$$

1.3.2.2 Ejemplo numérico: MV para una distribución Bernoulli

Supongamos que observamos los resultados de 10 individuos: 7 participan en el mercado laboral ($y = 1$) y 3 no ($y = 0$). Si asumimos $y_i \sim$ Bernoulli(p), ¿cuál es el estimador MV de p?

Verosimilitud:

$$\mathcal{L}(p) = \prod_{i=1}^{10} p^{y_i}(1-p)^{1-y_i} = p^7(1-p)^3$$

Log-verosimilitud:

$$\ell(p) = 7\ln(p) + 3\ln(1-p)$$

Condición de primer orden:

$$\frac{\partial \ell}{\partial p} = \frac{7}{p} - \frac{3}{1-p} = 0$$

Resolviendo:

$$7(1-p) = 3p \quad \Rightarrow \quad 7 = 10p \quad \Rightarrow \quad \hat{p}_{MV} = 0{,}7$$

El resultado es intuitivo: el estimador MV de la proporción es la proporción muestral.

1.3.2.3 Propiedades asintóticas del estimador MV

Bajo condiciones de regularidad, el estimador MV $\hat{\theta}_{MV}$ tiene tres propiedades fundamentales:

1. **Consistencia:** $\hat{\theta}_{MV} \xrightarrow{p} \theta_0$ (converge al valor verdadero).
2. **Normalidad asintótica:** $\sqrt{n}(\hat{\theta}_{MV} - \theta_0) \xrightarrow{d} N(0, \mathcal{I}(\theta_0)^{-1})$, donde $\mathcal{I}(\theta_0)$ es la **información de Fisher**.
3. **Eficiencia asintótica:** alcanza la cota inferior de Cramér-Rao; no existe un estimador consistente con menor varianza asintótica.

   ¿Por qué importa? Todos los modelos de microeconometría (Logit, Probit, Tobit, Poisson) se estiman por MV. La normalidad asintótica es lo que nos permite hacer contrastes de hipótesis e intervalos de confianza con estos modelos.

1.3.2.4 Comparación MV vs MCO

Aspecto	MCO	MV
Supuesto de distribución	No requiere (Gauss-Markov)	Requiere especificar $f(y\|X, \theta)$
Variable dependiente	Continua, sin restricciones	Cualquier tipo
Propiedades	BLUE (insesgado, eficiente entre lineales)	Consistente, asintóticamente eficiente

Aspecto	MCO	MV
Inferencia	Exacta con normalidad, asintótica sin ella	Siempre asintótica
Uso en microeconometría	Solo como referencia/comparación	Método principal

Regla práctica: Si la variable dependiente es continua y no tiene restricciones, MCO suele ser suficiente. En cualquier otro caso (binaria, censurada, recuento, ordenada), necesitamos MV.

1.4 Contraste de hipótesis

En econometría, constantemente necesitamos contrastar hipótesis del tipo:

$$H_0 : R\beta = q \quad \text{vs} \quad H_1 : R\beta \neq q$$

Existen tres enfoques fundamentales, los tres asintóticamente equivalentes. Los presentamos aquí porque los usaremos en todos los temas del curso.

1.4.1 Contraste de Wald

Idea: Estimar el modelo **sin restricciones** y comprobar si el estimador $\hat{\theta}$ está lejos del valor que impone H_0.

$$W = (\hat{\theta} - \theta_0)' \left[\text{Var}(\hat{\theta})\right]^{-1} (\hat{\theta} - \theta_0) \xrightarrow{d} \chi^2_q$$

donde q es el número de restricciones.

Caso particular (un solo parámetro):

$$W = \left(\frac{\hat{\theta} - \theta_0}{\text{se}(\hat{\theta})} \right)^2$$

que no es más que el cuadrado del habitual **estadístico** t.

Ventaja: Solo necesita el modelo sin restricciones.

1.4.2 Contraste de Razón de Verosimilitudes (LR)

Idea: Estimar el modelo **con** y **sin** restricciones, y comparar las log-verosimilitudes.

$$LR = 2 \left[\ell(\hat{\theta}_{SR}) - \ell(\hat{\theta}_R)\right] \xrightarrow{d} \chi^2_q$$

donde $\ell(\hat{\theta}_{SR})$ es la log-verosimilitud sin restricciones y $\ell(\hat{\theta}_R)$ la restringida.

Ventaja: Intuitivo: compara directamente cuánto «pierde» el modelo al imponer la restricción.

1.4.3 Contraste del Multiplicador de Lagrange (LM / Score)

Idea: Estimar el modelo **solo con restricciones** y comprobar si las condiciones de primer orden del modelo sin restricciones se satisfacen.

$$LM = s(\hat{\theta}_R)' \mathcal{I}(\hat{\theta}_R)^{-1} s(\hat{\theta}_R) \xrightarrow{d} \chi^2_q$$

donde $s(\hat{\theta}_R)$ es el vector score evaluado en el estimador restringido.

Ventaja: Solo necesita el modelo restringido (útil cuando el modelo sin restricciones es difícil de estimar).

1.4.4 Comparación de los tres contrastes

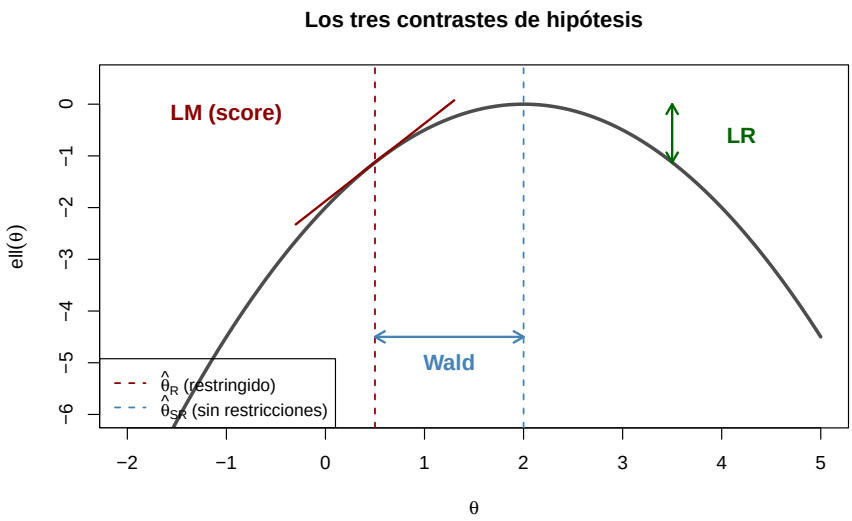

Figura 1.4: Los tres contrastes: Wald, LR y LM

Los tres contrastes son **asintóticamente equivalentes**: para muestras grandes, los tres dan resultados prácticamente idénticos. En muestras finitas pueden diferir ligeramente. En la práctica:

- **Wald** es el más usado porque solo requiere un modelo.
- **LR** es el más intuitivo.
- **LM** es útil cuando el modelo completo es difícil de estimar.

1.4.5 Ejemplo numérico: test de significatividad individual

Supongamos que hemos estimado un modelo y obtenemos $\hat{\beta}_1 = 0{,}45$ con $\text{se}(\hat{\beta}_1) = 0{,}18$.

Queremos contrastar $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$.

Test de Wald (versión t):

$$t = \frac{\hat{\beta}_1 - 0}{\text{se}(\hat{\beta}_1)} = \frac{0{,}45}{0{,}18} = 2{,}50$$

El p-valor es $P(|Z| > 2{,}50) = 2\Phi(-2{,}50) = 2 \times 0{,}0062 = 0{,}0124$.

Conclusión: Al 5 % de significación, rechazamos H_0. El coeficiente es estadísticamente significativo.

1.5 Repaso del Modelo Lineal (MCO)

1.5.1 Formulación

El modelo lineal clásico se expresa como:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

donde:

- $\mathbf{y}$ es el vector $n \times 1$ de observaciones de la variable dependiente.
- $\mathbf{X}$ es la matriz $n \times k$ de variables explicativas (incluye la constante).
- β es el vector $k \times 1$ de parámetros a estimar.
- ε es el vector $n \times 1$ de perturbaciones.

El estimador MCO es:

$$\hat{\beta}_{MCO} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

1.5.2 Supuestos clásicos

Los supuestos del modelo lineal clásico son:

1. **Linealidad:** $\mathbf{y} = \mathbf{X}\beta + \varepsilon$ (el modelo es lineal en los parámetros).
2. **Rango completo:** $\text{rango}(\mathbf{X}) = k$ (no hay multicolinealidad perfecta).
3. **Exogeneidad estricta:** $E[\varepsilon|\mathbf{X}] = \mathbf{0}$ (las perturbaciones no dependen de $\mathbf{X}$).
4. **Esfericidad:** $\text{Var}(\varepsilon|\mathbf{X}) = \sigma^2\mathbf{I}_n$ (homocedasticidad y no autocorrelación).
5. **Normalidad** (opcional): $\varepsilon|\mathbf{X} \sim N(\mathbf{0}, \sigma^2\mathbf{I}_n)$.

1.5.3 Propiedades de los estimadores MCO (Gauss-Markov)

Si se cumplen los supuestos 1-4, el estimador MCO es **BLUE** (*Best Linear Unbiased Estimator*):

- **Insesgado:** $E[\hat{\beta}] = \beta$.
- **Eficiente:** tiene la menor varianza entre todos los estimadores lineales e insesgados.

- **Consistente:** $\hat{\beta} \xrightarrow{p} \beta$ cuando $n \to \infty$.

La varianza del estimador es:

$$\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

1.5.4 Bondad de ajuste: R^2 y R^2 ajustado

El **coeficiente de determinación** mide qué proporción de la variabilidad de y explica el modelo:

$$R^2 = 1 - \frac{SCR}{SCT} = 1 - \frac{\sum \hat{\varepsilon}_i^2}{\sum (y_i - \bar{y})^2}$$

El R^2 **ajustado** penaliza por el número de variables:

$$\bar{R}^2 = 1 - \frac{SCR/(n-k)}{SCT/(n-1)}$$

> **Advertencia importante para el curso:** El R^2 es una medida válida para el modelo lineal con MCO. En modelos no lineales (Logit, Probit, Tobit, Poisson), el R^2 **no tiene la misma interpretación** y no es un criterio fiable. Usaremos en su lugar la log-verosimilitud, AIC y BIC.

1.5.5 Limitaciones de MCO cuando la variable dependiente es limitada

MCO parte del supuesto de que y puede tomar cualquier valor en $(-\infty, +\infty)$. Cuando la variable dependiente no satisface este supuesto, la estimación por MCO presenta deficiencias graves. En primer lugar, si la variable dependiente es binaria ($y \in \{0, 1\}$), el modelo lineal puede generar **predicciones fuera del rango** $[0, 1]$, lo que carece de sentido probabilístico. En segundo lugar, cuando la variable dependiente está censurada — con una acumulación de observaciones en un límite, típicamente cero —, MCO produce un **sesgo de atenuación** que subestima sistemáticamente el efecto de las variables explicativas. Finalmente, en modelos con variable dependiente binaria

aparece un problema de **heterocedasticidad inherente**, puesto que $\text{Var}(\varepsilon_i|X_i) = p_i(1-p_i)$ depende de las propias variables explicativas, violando el supuesto de varianza constante.

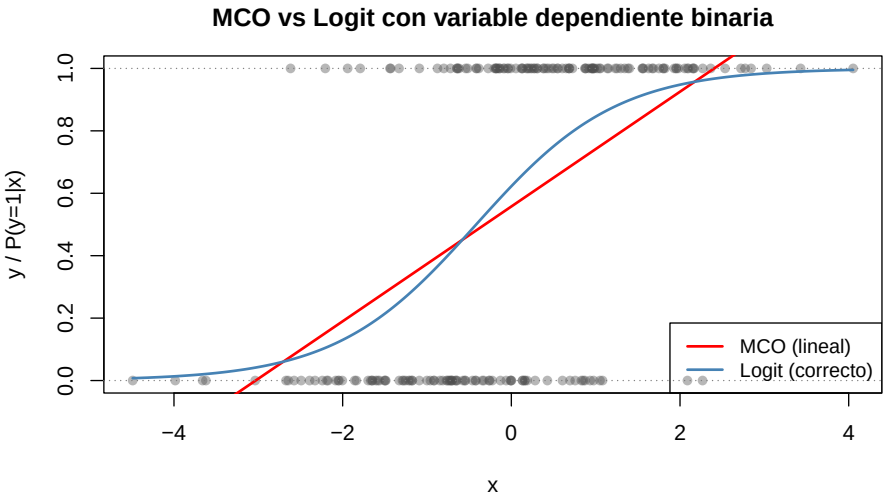

Figura 1.5: Limitaciones de MCO: predicciones fuera de rango con variable dependiente binaria

Estos problemas son la razón de ser de todo este curso: necesitamos modelos específicos para cada tipo de variable dependiente limitada.

1.6 Especificación y diagnóstico del modelo

Este apartado es fundamental. El alumno debe entender que estimar un modelo es solo el primer paso; **validar que el modelo es correcto** es igualmente importante.

1.6.1 ¿Qué significa que un modelo esté bien especificado?

Un modelo está **bien especificado** cuando:

1. Incluye las **variables relevantes** y no incluye las irrelevantes.
2. La **forma funcional** es correcta.
3. Los **supuestos distribucionales** se cumplen razonablemente.
4. No hay problemas graves de **multicolinealidad**.

Si el modelo está mal especificado, los estimadores pueden ser **sesgados**, **inconsistentes**, o los errores estándar pueden ser **incorrectos**, invalidando toda la inferencia.

1.6.2 Sesgo por omisión de variables relevantes

Si el modelo verdadero es:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

pero estimamos:

$$y = \gamma_0 + \gamma_1 x_1 + u$$

el estimador $\hat{\gamma}_1$ tiene un sesgo:

$$E[\hat{\gamma}_1] = \beta_1 + \beta_2 \cdot \delta_{21}$$

donde δ_{21} es el coeficiente de la regresión auxiliar de x_2 sobre x_1.

Regla práctica:

- Si la variable omitida está correlacionada con las incluidas ($\delta_{21} \neq 0$) y tiene efecto sobre y ($\beta_2 \neq 0$): hay sesgo.
- El signo del sesgo depende del producto $\beta_2 \cdot \delta_{21}$.

1.6.3 Forma funcional: contraste RESET de Ramsey

El **test RESET** (*Regression Equation Specification Error Test*) comprueba si la forma funcional es correcta.

Procedimiento:

1. Estimar el modelo original y obtener $\hat{y}$.
2. Estimar un modelo aumentado incluyendo $\hat{y}^2$ y $\hat{y}^3$ como regresores adicionales.
3. Contrastar con un test F si los coeficientes de $\hat{y}^2$ y $\hat{y}^3$ son conjuntamente significativos.

- **Si** H_0 se rechaza: la forma funcional es inadecuada.
- **Si** H_0 no se rechaza: no hay evidencia de mala especificación (no implica que sea perfecta).

En R: `lmtest::resettest(modelo, power = 2:3, type = "fitted")`

1.6.4 Multicolinealidad

La **multicolinealidad** se produce cuando dos o más variables explicativas están altamente correlacionadas. Consecuencias:

- Los estimadores siguen siendo insesgados y consistentes.
- Pero su **varianza aumenta**, lo que reduce la potencia de los contrastes.
- Los coeficientes individuales pueden ser no significativos, pero el modelo en conjunto sí.

Indicador: Factor de Inflación de la Varianza (VIF)

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión de x_j sobre las demás variables.

- $\text{VIF} = 1$: no hay colinealidad.
- $\text{VIF} > 5$: preocupante.
- $\text{VIF} > 10$: grave.

En R: `car::vif(modelo)`

1.6.5 Análisis de residuos

Los residuos $\hat{\varepsilon}_i = y_i - \hat{y}_i$ deben cumplir aproximadamente:

- Media cero.
- Varianza constante (homocedasticidad).
- No mostrar patrones sistemáticos.
- Aproximarse a una distribución normal (para inferencia exacta).

Un buen diagnóstico visual incluye:

1. **Residuos vs valores ajustados:** detecta heteroscedasticidad y no linealidad.
2. **QQ-plot:** detecta desviaciones de la normalidad.
3. **Residuos vs cada variable explicativa:** detecta relaciones no lineales omitidas.

1.6.6 Normalidad de los residuos

Test de Shapiro-Wilk:

- H_0: los residuos siguen una distribución normal.
- En R: `shapiro.test(residuals(modelo))`
- Sensible al tamaño muestral: con muestras grandes, casi siempre rechaza.

Test de Jarque-Bera:

- Basado en asimetría y curtosis.
- $JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right) \sim \chi^2_2$
- En R: `tseries::jarque.bera.test(residuals(modelo))`

  Nota práctica: En muestras grandes (frecuentes en microeconometría), la normalidad exacta de los residuos es menos importante gracias a los resultados asintóticos. Lo crucial es detectar **desviaciones severas** (colas muy pesadas, asimetría extrema).

1.6.7 Homocedasticidad

Test de Breusch-Pagan:

1. Estimar el modelo y obtener los residuos $\hat{\varepsilon}_i$.
2. Regresar $\hat{\varepsilon}_i^2$ sobre las variables explicativas.
3. Contrastar si los coeficientes son conjuntamente significativos.

- H_0: homocedasticidad.
- En R: `lmtest::bptest(modelo)`

Consecuencias de la heteroscedasticidad:

- Los estimadores MCO siguen siendo insesgados y consistentes.
- Pero los **errores estándar clásicos son incorrectos**, lo que invalida los contrastes y los intervalos de confianza.
- **Solución:** usar errores estándar robustos (White/HC).

1.6.8 Bondad de ajuste: más allá del R^2

En modelos no lineales (que son los que estudiaremos en este curso), el R^2 clásico no es apropiado. Utilizaremos:

Log-verosimilitud: Valor de $\ell(\hat{\theta})$. Más alto = mejor ajuste.

Criterio de Información de Akaike (AIC):

$$\text{AIC} = -2\ell(\hat{\theta}) + 2k$$

Criterio de Información Bayesiano (BIC):

$$\text{BIC} = -2\ell(\hat{\theta}) + k\ln(n)$$

donde k es el número de parámetros y n el tamaño muestral.

- Ambos penalizan la complejidad del modelo.
- **BIC penaliza más** que AIC (tiende a seleccionar modelos más parsimoniosos).
- En ambos casos: **menor es mejor**.

1.7 Conceptos avanzados necesarios

1.7.1 Variable latente

Muchos modelos de microeconometría se basan en el concepto de **variable latente**. La idea es que existe una variable y^* que **no observamos directamente**, pero que determina lo que sí observamos.

Formulación general:

$$y^* = \mathbf{x}'\beta + \varepsilon$$

Lo que observamos (y) es una transformación de y^*:

- **Modelo Logit/Probit:** $y = 1$ si $y^* > 0$, $y = 0$ en caso contrario.
- **Modelo Tobit:** $y = y^*$ si $y^* > 0$, $y = 0$ en caso contrario.

  Interpretación económica: En un modelo de participación laboral, y^* puede interpretarse como la «utilidad neta de trabajar». Si $y^* > 0$, la persona trabaja; si $y^* \leq 0$, no trabaja. Nunca observamos y^* directamente, solo la decisión final.

1.7.2 Efectos marginales

En los modelos lineales (MCO), el efecto marginal es simplemente el coeficiente β_j:

$$\frac{\partial E[y|\mathbf{x}]}{\partial x_j} = \beta_j$$

En modelos no lineales, esto **ya no es cierto**. El efecto marginal depende del punto donde se evalúa:

$$\frac{\partial E[y|\mathbf{x}]}{\partial x_j} = g(\mathbf{x}'\beta) \cdot \beta_j$$

donde $g(\cdot)$ depende del modelo:

- **Logit:** $g = \Lambda(z)[1 - \Lambda(z)]$
- **Probit:** $g = \phi(z)$

- **Tobit:** $g = \Phi(z/\sigma)$

Existen dos formas habituales de reportar efectos marginales:

- **MEM** (*Marginal Effect at the Mean*): evaluar en $\bar{\mathbf{x}}$.
- **AME** (*Average Marginal Effect*): calcular el efecto para cada observación y promediar.

  En la práctica, el AME es preferible porque no asume que el «individuo medio» sea representativo.

1.8 Funciones esenciales en R

A lo largo de este tema (y del curso) utilizaremos estas funciones de R:

Distribuciones:

- `dnorm()`, `pnorm()`, `qnorm()`, `rnorm()` — Normal
- `dlogis()`, `plogis()` — Logística
- `dpois()`, `ppois()` — Poisson
- `dbinom()`, `pbinom()` — Binomial

Estimación:

- `lm()` — Mínimos Cuadrados Ordinarios
- `optim()` — Optimización numérica (para MV manual)

Inferencia y diagnóstico:

- `summary()` — Resumen del modelo
- `coeftest()` (`lmtest`) — Test de coeficientes con errores robustos
- `vcovHC()` (`sandwich`) — Matriz de varianzas-covarianzas robusta
- `resettest()` (`lmtest`) — Test RESET de Ramsey
- `vif()` (`car`) — Factor de inflación de la varianza
- `bptest()` (`lmtest`) — Test de Breusch-Pagan
- `shapiro.test()` — Test de normalidad de Shapiro-Wilk
- `waldtest()`, `lrtest()` (`lmtest`) — Contrastes de Wald y LR

Bondad de ajuste:

- `AIC()`, `BIC()` — Criterios de información
- `logLik()` — Log-verosimilitud

Código R del capítulo

El script completo de este capítulo (`T00_mECO_Script_Fundamentos.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Capítulo 2

Datos con Variable Dependiente Limitada

2.1 Introducción: ¿qué es una variable dependiente limitada?

En el Tema 0 aprendimos a estimar modelos de regresión lineal por MCO. En aquellos modelos, la variable dependiente y podía tomar **cualquier valor real**: el salario, las ventas, el PIB... Sin embargo, en muchas aplicaciones microeconómicas la variable que queremos explicar **no es libre de tomar cualquier valor**. Cuando el rango de valores de la variable dependiente está **restringido de alguna forma**, decimos que se trata de una **variable dependiente limitada**.

Este tipo de datos aparece constantemente en economía aplicada. Cuando se analiza la participación laboral, la variable de interés es **binaria**: la persona trabaja o no trabaja, y la respuesta se codifica como 0 o 1. Cuando se estudia la elección de medio de transporte, la variable es **multinomial**: el viajero selecciona entre coche, autobús, tren o avión. Cuando se modela el gasto en seguros médicos, la variable es **continua pero censurada**: muchas familias no gastan nada (valor cero), mientras que las demás presentan un gasto estrictamente positivo.

En los tres casos, el modelo de regresión lineal clásico (MCO) genera problemas graves. El **objetivo de este tema** es presentar los distintos tipos de variables dependientes limitadas, entender por qué MCO falla en cada caso y conocer las distribuciones estadísticas asociadas. En

los temas siguientes estudiaremos los modelos adecuados para cada situación (Probit/Logit en el Tema 2, Tobit en el Tema 3).

2.1.1 ¿Por qué MCO no funciona?

Recordemos que el modelo lineal clásico es:

$$y_i = \mathbf{x}_i'\beta + u_i$$

y MCO estima los coeficientes minimizando $\sum \hat{u}_i^2$. El valor predicho $\hat{y}_i = \mathbf{x}_i'\hat{\beta}$ puede tomar **cualquier valor** en $(-\infty, +\infty)$.

Pero si y_i solo puede ser 0 o 1, resulta que:

1. **Las predicciones pueden salir fuera del rango** $[0, 1]$: MCO puede predecir probabilidades negativas o superiores a 1. Esto no tiene sentido.
2. **Los errores no son normales ni homocedásticos**: cuando y es binaria, el error $u_i = y_i - \mathbf{x}_i'\beta$ solo puede tomar dos valores, así que no puede seguir una distribución normal. Además, su varianza depende de $\mathbf{x}_i$, violando la homocedasticidad.
3. **Los contrastes t y F dejan de ser válidos**: al fallar los supuestos distribucionales, la inferencia clásica no es fiable.

Veamos esto con un ejemplo simulado:

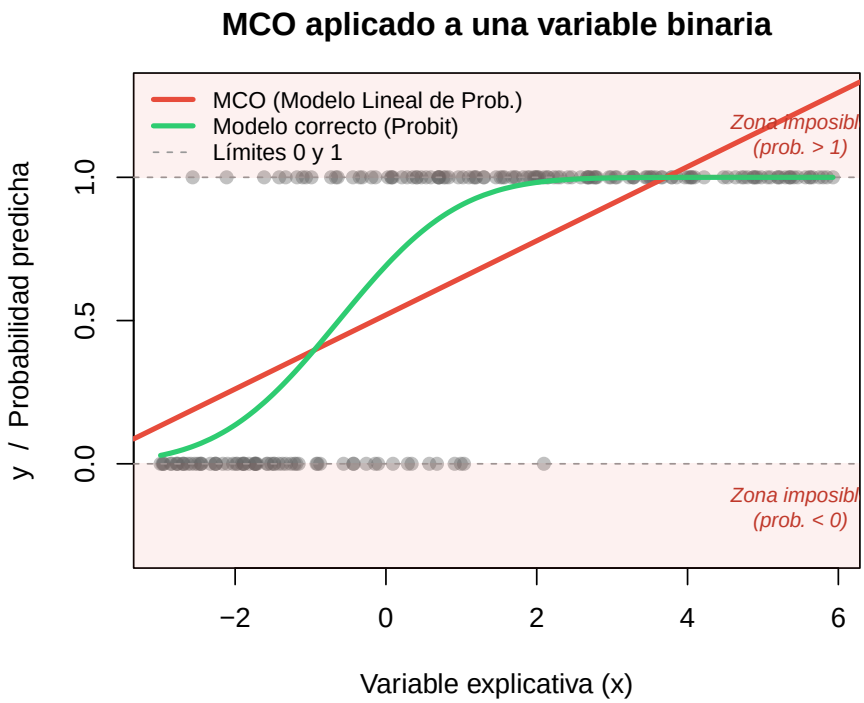

Figura 2.1: Problemas del Modelo Lineal de Probabilidad: las predicciones de MCO salen fuera de $[0, 1]$.

Como vemos en la figura, la recta de MCO (en rojo) cruza los límites 0 y 1. El modelo correcto (curva verde, un Probit) mantiene las predicciones siempre dentro de $[0, 1]$.

> **Conclusión:** Cuando la variable dependiente está limitada, necesitamos modelos que **respeten esas restricciones**. Este es el punto de partida de toda la microeconometría.

2.1.2 Clasificación de las variables dependientes limitadas

Las variables dependientes limitadas se clasifican en tres grandes familias, según la naturaleza de la restricción:

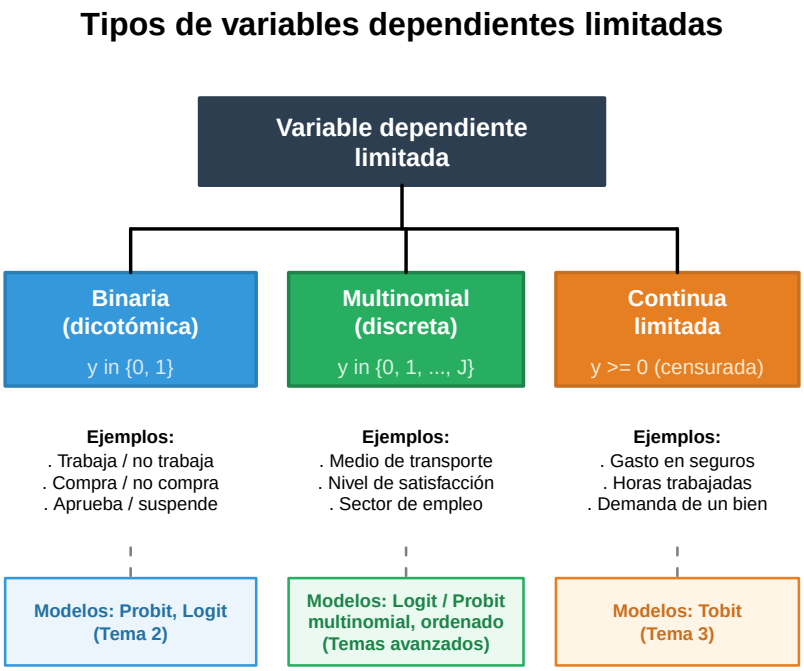

Figura 2.2: Clasificación de las variables dependientes limitadas.

En las secciones siguientes estudiaremos cada tipo en detalle.

2.2 Variables dependientes limitadas binarias

2.2.1 Concepto

Una variable dependiente **binaria** (o **dicotómica**) es aquella que solo puede tomar dos valores: 0 o 1. Típicamente codificamos:

$$y_i = \begin{cases} 1 & \text{si ocurre el evento de interés} \\ 0 & \text{en caso contrario} \end{cases}$$

Estos datos son extremadamente frecuentes en economía:

Cuadro 2.1: Ejemplos de variables dependientes binarias en economía

Contexto	Variable	y = 1	y = 0
Mercado laboral	Participación laboral	Trabaja	No trabaja
Banca	Concesión de crédito	Se concede	Se deniega
Salud	Tiene seguro médico	Sí tiene	No tiene
Marketing	Compra un producto	Compra	No compra
Educación	Aprueba el examen	Aprueba	Suspende
Comercio	Compra online	Compra online	No compra online

En todos estos casos, lo que queremos modelar es la **probabilidad** de que $y = 1$ en función de las características observables del individuo $\mathbf{x}_i$:

$$P(y_i = 1 \mid \mathbf{x}_i) = F(\mathbf{x}_i'\beta)$$

donde $F(\cdot)$ es una función que **siempre devuelve valores entre 0 y 1**. La elección de F determinará el modelo: si $F = \Phi$ (CDF de la Normal

estándar), tenemos el **Probit**; si $F = \Lambda$ (CDF de la logística), tenemos el **Logit**.

2.2.2 La distribución de Bernoulli

2.2.2.1 Intuición: la moneda y el dado

Antes de escribir fórmulas, pensemos en los ejemplos más sencillos de fenómenos aleatorios:

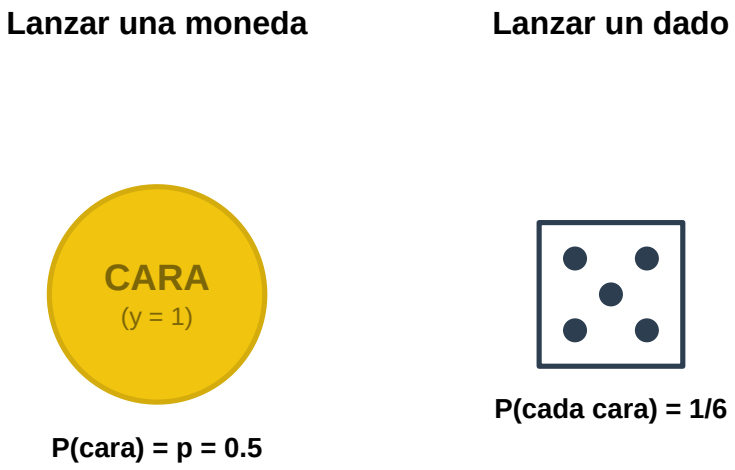

Figura 2.3: Los fenómenos aleatorios más simples: lanzar una moneda (dos resultados) o un dado (seis resultados).

- **Moneda justa:** Al lanzar una moneda, hay dos resultados posibles: cara ($y = 1$) o cruz ($y = 0$). Si la moneda es justa, $p = P(\text{cara}) = 0.5$. Pero una moneda trucada podría tener $p = 0.7$: saldría cara el 70% de las veces.
- **Dado:** Al lanzar un dado hay 6 resultados posibles. Si nos preguntamos "¿ha salido un 6?", la respuesta es sí ($y = 1$) con probabilidad $p = 1/6$, o no ($y = 0$) con probabilidad $1-p = 5/6$. También es una Bernoulli.

La **Bernoulli** captura exactamente esta idea: un experimento con solo

dos resultados posibles.

2.2.2.2 ¿Qué significa p? El parámetro de la Bernoulli

El parámetro p es la **probabilidad de éxito** (de que ocurra el evento de interés, $y = 1$). Es un número entre 0 y 1 que resume toda la incertidumbre del fenómeno:

$$P(y = 1) = p \qquad\qquad P(y = 0) = 1 - p$$

En forma compacta, la **función de masa de probabilidad** de la Bernoulli es:

$$\boxed{f(y; p) = p^y \cdot (1 - p)^{1-y}, \qquad y \in \{0, 1\}}$$

Comprobación rápida:

- Si $y = 1$: $f(1; p) = p^1 \cdot (1 - p)^0 = p$ ✓
- Si $y = 0$: $f(0; p) = p^0 \cdot (1 - p)^1 = 1 - p$ ✓

Sus momentos son:

- **Esperanza:** $E(y) = p$ (la media de muchas realizaciones tiende a p)
- **Varianza:** $Var(y) = p(1 - p)$ (la dispersión depende de p)

  Observación importante: La varianza **depende de** p, que a su vez depende de $\mathbf{x}_i$ en un modelo econométrico. Esto confirma que la homocedasticidad se viola de forma inherente cuando la variable dependiente es binaria.

2.2.2.3 Ejemplo concreto: una realización muestral

Imaginemos que encuestamos a 20 personas y les preguntamos si compraron por Internet en el último mes ($y = 1$) o no ($y = 0$). Los datos que obtenemos son una **realización muestral** de 20 variables Bernoulli:

Cuadro 2.2: Realización muestral: 20 observaciones de una Bernoulli

Persona	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
y	0	1	1	1	1	1	1	0	1	1	1	0	1	0	1	1	1	1	1	1

2.2.2.4 ¿Cómo obtenemos p a partir de una muestra?

En la práctica, **no conocemos** el valor verdadero de p. Lo que hacemos es **estimarlo** a partir de los datos observados. El estimador más natural es la **proporción muestral**:

$$\boxed{\widehat{p} = \frac{\text{número de éxitos}}{n} = \frac{\sum_{i=1}^{n} y_i}{n} = \bar{y}}$$

Es decir, $\widehat{p}$ es simplemente la **media muestral** de los unos y ceros.

> **¿Por qué** $\widehat{p}$ no coincide exactamente con p? Porque estamos trabajando con una muestra finita. Con $n = 20$, hay variabilidad muestral. Si aumentamos el tamaño de la muestra, $\widehat{p}$ se acerca cada vez más al verdadero p (esto es la **Ley de los Grandes Números**):

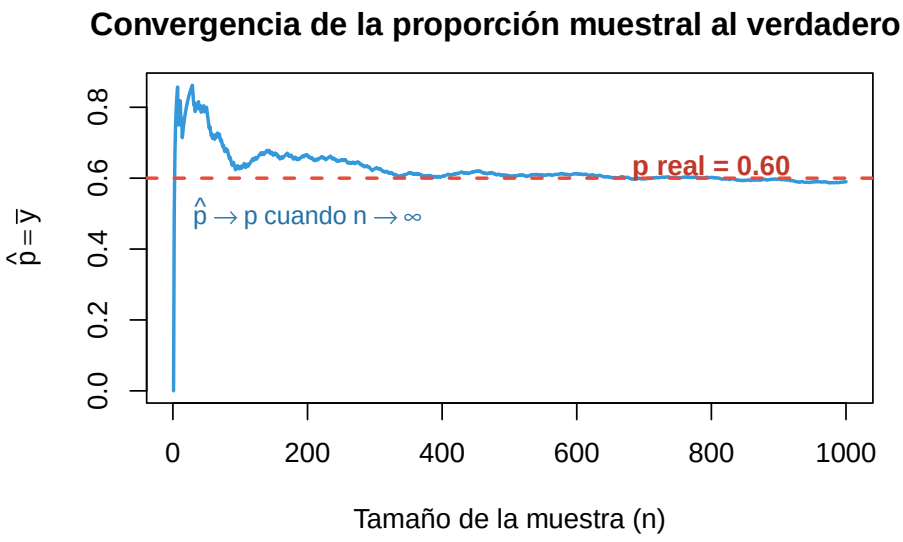

Figura 2.4: Ley de los Grandes Números: a medida que n crece, la proporción muestral converge al verdadero $p = 0.60$.

2.2.2.5 Gráficos de la distribución Bernoulli

Veamos cómo cambia la forma de la distribución según el valor de p:

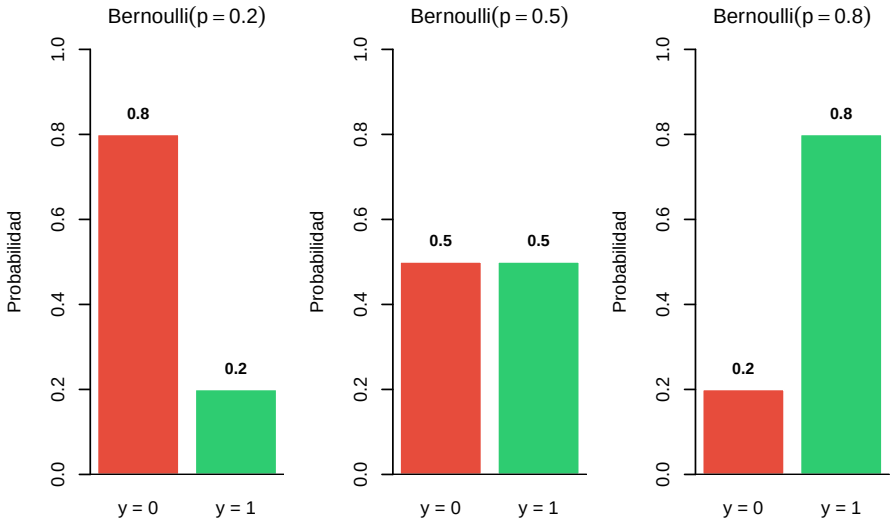

Figura 2.5: Distribución Bernoulli para distintos valores de p.

Con $p = 0.5$ la distribución es **simétrica** (como una moneda justa). Cuando p se aleja de 0.5, la distribución se **asimetra**: con $p = 0.2$ predominan los ceros; con $p = 0.8$, los unos.

2.2.3 La distribución Binomial

2.2.3.1 De una moneda a muchas monedas

Si en lugar de lanzar una moneda **una vez**, la lanzamos n veces (o equivalentemente, observamos a n individuos independientes con la misma probabilidad p de éxito), nos interesa saber: **¿cuántos éxitos obtendremos en total?**

El número total de éxitos k sigue una distribución **Binomial**:

$$\boxed{P(k; n, p) = \binom{n}{k} p^k (1-p)^{n-k}, \qquad k = 0, 1, \dots, n}$$

donde $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ es el **coeficiente binomial** (número de formas de elegir k éxitos entre n ensayos).

La Bernoulli es un caso particular de la Binomial con $n = 1$:

$$P(k; 1, p) = \binom{1}{k} p^k (1-p)^{1-k} = p^k (1-p)^{1-k} \quad \Rightarrow \quad \text{¡es exactamente la Bernoulli!}$$

2.2.3.2 Ejemplo concreto: lanzar 10 monedas

Supongamos que lanzamos 10 monedas justas ($p = 0.5$). ¿Cuál es la probabilidad de obtener exactamente k caras?

Cuadro 2.3: Distribución Binomial: P(k caras) al lanzar 10 monedas justas

k	Combinaciones	P(k)	P(k) en porcentaje
0	1	0.0010	0.10%
1	10	0.0098	0.98%
2	45	0.0439	4.39%
3	120	0.1172	11.72%
4	210	0.2051	20.51%
5	252	0.2461	24.61%
6	210	0.2051	20.51%
7	120	0.1172	11.72%
8	45	0.0439	4.39%
9	10	0.0098	0.98%
10	1	0.0010	0.10%

Lo más probable es obtener 5 caras (24.6%), pero no es raro obtener 4 o 6. Obtener 0 o 10 caras es extremadamente improbable ($< 0.1\%$).

2.2.3.3 Gráficos de la distribución Binomial

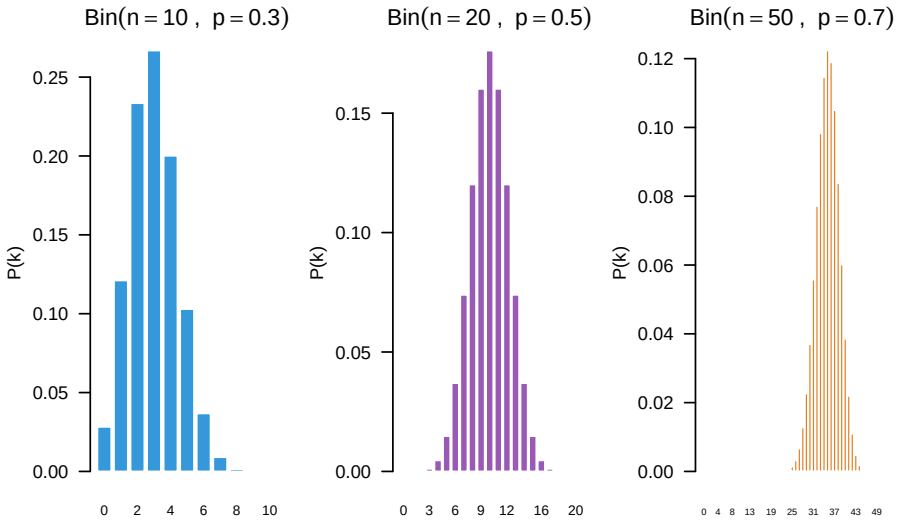

Figura 2.6: Distribución Binomial: número de éxitos en n ensayos independientes.

Observamos que a medida que n crece, la distribución Binomial se parece cada vez más a una **campana** (Normal). Este resultado se conoce como el **Teorema Central del Límite**.

2.2.3.4 Simulación: verificar la Binomial con datos

Vamos a simular el lanzamiento de 10 monedas y repetir el experimento 10.000 veces, para comprobar que las frecuencias observadas coinciden con las probabilidades teóricas:

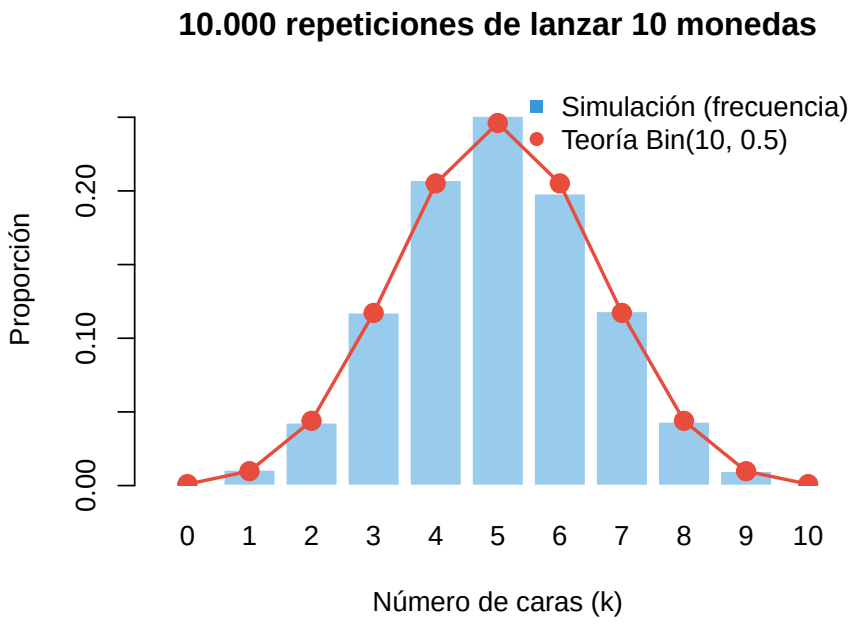

Figura 2.7: Simulación vs. teoría: la frecuencia relativa converge a la probabilidad teórica.

La simulación (barras azules) coincide casi perfectamente con la teoría (puntos rojos). Esto confirma que la distribución Binomial describe correctamente el número de éxitos en ensayos independientes.

¿Por qué nos importa la Binomial en microeconometría? Porque la función de verosimilitud de un modelo Probit o Logit se construye a partir del producto de distribuciones Bernoulli independientes, que tiene la estructura de una Binomial. Este es el punto de partida de la **estimación por Máxima Verosimilitud (MV)**, que estudiaremos en el Tema 2.

2.2.4 El concepto de variable latente

En muchos problemas económicos, la variable que realmente determina el comportamiento del individuo **no es directamente observable**. Por ejemplo, cuando una persona decide si trabajar o no, lo que determina

esa decisión es su **utilidad neta** de trabajar:

$$y_i^* = \mathbf{x}_i'\beta + u_i$$

donde y_i^* es la **variable latente** (no observable). Lo que sí observamos es la **decisión final**:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \quad \text{(la utilidad de trabajar supera la de no trabajar)} \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

Este enfoque de **variable latente** es el fundamento teórico de los modelos Probit y Logit. La intuición es clara: no observamos la utilidad, pero sí observamos la decisión que se deriva de ella.

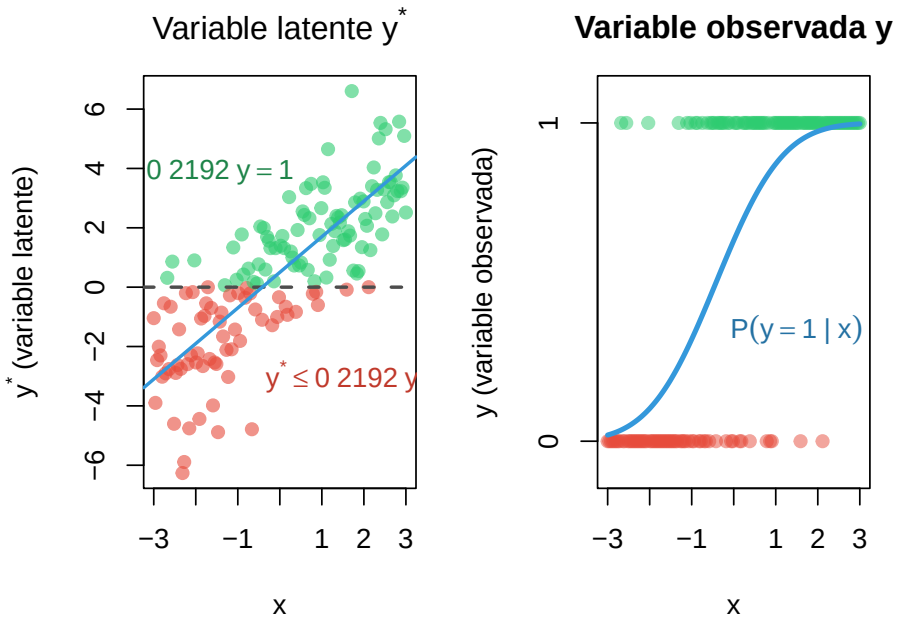

Figura 2.8: La variable latente y* determina la decisión observada y.

En el panel izquierdo vemos la variable latente y^*: algunos valores son positivos (verde, $y = 1$) y otros negativos (rojo, $y = 0$). En el panel

derecho vemos lo que realmente observamos: solo los unos y los ceros. La curva azul es la probabilidad estimada de $y = 1$ dado x.

2.2.5 Modelo Lineal de Probabilidad (MLP): una primera aproximación

La forma más sencilla (pero incorrecta) de modelar una variable binaria es aplicar MCO directamente:

$$P(y_i = 1 \mid \mathbf{x}_i) = \mathbf{x}_i'\beta$$

Esto se conoce como **Modelo Lineal de Probabilidad (MLP)**. Aunque es fácil de estimar e interpretar, tiene tres problemas fundamentales:

Problema 1: Predicciones fuera de $[0, 1]$. Las predicciones lineales $\widehat{y}_i = \mathbf{x}_i'\widehat{\beta}$ pueden ser negativas o superiores a 1. Esto carece de sentido como probabilidad. **Consecuencia:** predicciones sin interpretación económica.

Problema 2: Heterocedasticidad inherente. Como $Var(u_i) = p_i(1 - p_i)$ y p_i depende de $\mathbf{x}_i$, la varianza del error cambia con cada observación. **Consecuencia:** los errores estándar de MCO son incorrectos, por lo que los contrastes t y F no son válidos.

Problema 3: No normalidad de los errores. El error $u_i = y_i - p_i$ solo puede tomar dos valores, por lo que no puede seguir una distribución normal. **Consecuencia:** los intervalos de confianza y los contrastes pierden validez en muestras pequeñas.

A pesar de estos problemas, el MLP se utiliza en ocasiones como **primera aproximación rápida**, especialmente cuando las probabilidades predichas no caen lejos de $[0, 1]$. No obstante, los modelos Probit y Logit (Tema 2) son la solución estándar.

2.3 Variables dependientes limitadas multinomiales

2.3.1 Concepto

En muchos problemas económicos, la variable dependiente no es simplemente 0 o 1, sino que puede tomar **múltiples categorías**. Cuando hay más de dos alternativas posibles, hablamos de variables dependientes **multinomiales**:

$$y_i \in \{0, 1, 2, \dots, J\}$$

donde $J + 1$ es el número total de categorías.

Cuadro 2.4: Ejemplos de variables dependientes multinomiales

Contexto	Variable	Categorias	Tipo
Transporte	Medio de transporte elegido	Coche, autobús, tren, avión	No ordenada
Mercado laboral	Sector de empleo	Público, privado, autónomo	No ordenada
Satisfacción	Grado de satisfacción con un servicio	Muy insatisfecho, insatisfecho, neutro, satisfecho, muy satisfecho	Ordenada
Salud	Decisión de tratamiento médico	Sin tratamiento, tratamiento A, tratamiento B	Secuencial
Consumo	Tipo de vivienda	Alquiler, compra, compartida	No ordenada

Igual que en el caso binario, se supone que cada individuo elige la alternativa que le proporciona **mayor utilidad**:

$$y_i = j \quad \text{si} \quad U_{ij} > U_{ik} \quad \forall\, k \neq j$$

Las probabilidades de elección dependerán de la forma que tome la variable dependiente.

2.3.2 Variables multinomiales ordenadas

Cuando las categorías tienen un **orden natural**, hablamos de variables **ordenadas**. Un ejemplo clásico es el nivel de satisfacción:

$$y_i = \begin{cases} 0 & \text{Muy insatisfecho} \\ 1 & \text{Insatisfecho} \\ 2 & \text{Neutro} \\ 3 & \text{Satisfecho} \\ 4 & \text{Muy satisfecho} \end{cases}$$

Aquí la codificación numérica refleja un **orden** ($4 > 3 > 2 > 1 > 0$), pero la distancia entre categorías no tiene por qué ser igual. Es decir, la diferencia entre "muy insatisfecho" e "insatisfecho" no es necesariamente la misma que entre "satisfecho" y "muy satisfecho".

Otro ejemplo relevante: el nivel de ingresos ordenado en cuartiles:

$$y_i = \begin{cases} 1 & \text{si } x_i'\beta < \mu_1 \\ 2 & \text{si } \mu_1 \leq x_i'\beta < \mu_2 \\ 3 & \text{si } \mu_2 \leq x_i'\beta < \mu_3 \\ 4 & \text{si } x_i'\beta \geq \mu_3 \end{cases}$$

donde $\mu_1 < \mu_2 < \mu_3$ son los **umbrales** (thresholds) que separan las categorías.

Dentro de las variables ordenadas también encontramos las **secuenciales**: para elegir una categoría, es necesario haber pasado por un proceso de decisión previo. Por ejemplo, en el ámbito laboral:

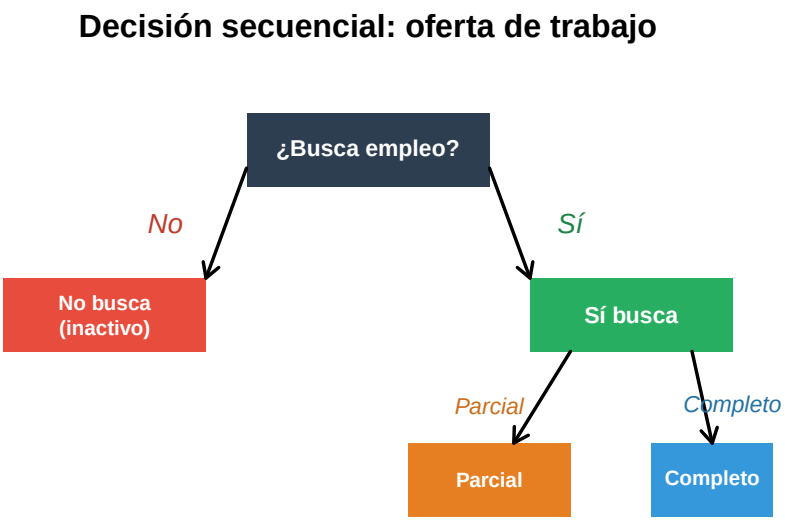

Figura 2.9: Ejemplo de decisión secuencial en el mercado laboral.

2.3.3 Variables multinomiales no ordenadas

Cuando las categorías **no tienen un orden natural**, hablamos de variables **no ordenadas**. El ejemplo más clásico es la elección del medio de transporte:

$$y_i \in \{\text{coche},\ \text{autobús},\ \text{tren},\ \text{avión}\}$$

No tiene sentido decir que "avión > tren" o que "autobús < coche" en un sentido ordinal. Cada alternativa es simplemente una opción distinta, y el individuo elige aquella que le reporta **mayor utilidad**:

$$y_i = j \quad \Longleftrightarrow \quad U_{ij} = \max(U_{i0}, U_{i1}, \dots, U_{iJ})$$

Los modelos para este tipo de variables (Logit multinomial, Probit multinomial) se estudian en temas avanzados de microeconometría.

2.3.4 La distribución Multinomial

Las variables multinomiales siguen una distribución **Multinomial**, que es la generalización de la Binomial a más de dos categorías.

Si realizamos n experimentos independientes, cada uno con $J+1$ resultados posibles con probabilidades $p_0, p_1, \dots, p_J$ (donde $\sum p_j = 1$), la probabilidad de observar $k_0, k_1, \dots, k_J$ éxitos de cada tipo es:

$$\boxed{P(k_0, k_1, \dots, k_J) = \frac{n!}{k_0!\, k_1! \cdots k_J!}\, p_0^{k_0}\, p_1^{k_1} \cdots p_J^{k_J}}$$

donde $\sum k_j = n$.

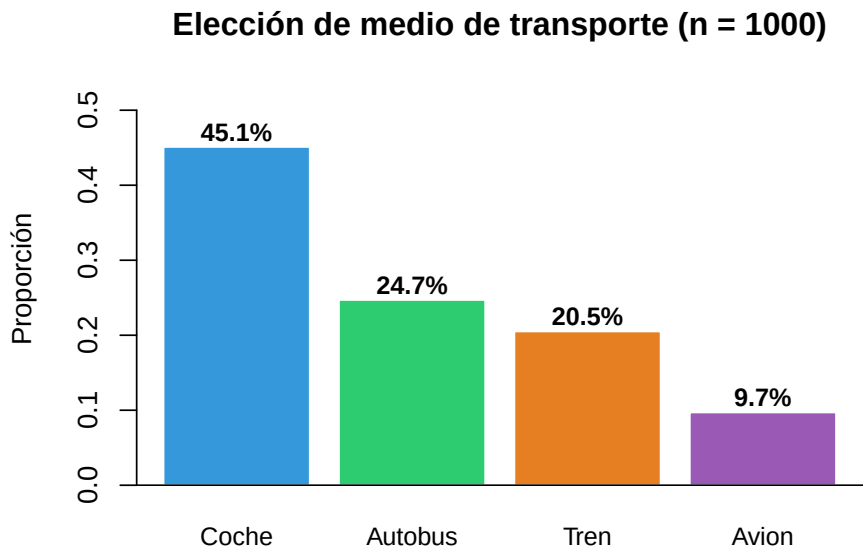

Figura 2.10: Ejemplo de distribución Multinomial: 1000 individuos eligen entre 4 medios de transporte.

2.3.4.1 Demostración: Bernoulli y Binomial como casos particulares

Es importante entender que las tres distribuciones que hemos visto (Bernoulli, Binomial, Multinomial) están **conectadas jerárquicamente**. Vamos a demostrarlo paso a paso.

1. La Bernoulli es un caso particular de la Multinomial con $J = 1$.

La distribución Multinomial para $n = 1$ ensayo con $J+1 = 2$ categorías (éxito/fracaso) es:

$$P(k_0, k_1) = \frac{1!}{k_0!\, k_1!}\, p_0^{k_0}\, p_1^{k_1}$$

donde $k_0 + k_1 = 1$ (solo hay un ensayo), $p_0 = 1 - p$ y $p_1 = p$.

Si $k_1 = 1$ (éxito): $P(0, 1) = \frac{1!}{0!\cdot 1!}(1-p)^0 \cdot p^1 = p$

Si $k_1 = 0$ (fracaso): $P(1, 0) = \frac{1!}{1!\cdot 0!}(1-p)^1 \cdot p^0 = 1 - p$

Esto es **exactamente la distribución Bernoulli**: $f(y; p) = p^y(1-p)^{1-y}$.

2. La Binomial es la Multinomial con $J = 1$ y n ensayos.

La distribución Multinomial para n ensayos con $J + 1 = 2$ categorías es:

$$P(k_0, k_1) = \frac{n!}{k_0!\, k_1!}\, p_0^{k_0}\, p_1^{k_1}$$

donde $k_0 + k_1 = n$, $p_0 = 1 - p$, $p_1 = p$. Sustituyendo $k_0 = n - k_1$:

$$P(k_1) = \frac{n!}{(n-k_1)!\, k_1!}\,(1-p)^{n-k_1}\, p^{k_1} = \binom{n}{k_1} p^{k_1}(1-p)^{n-k_1}$$

Esto es **exactamente la distribución Binomial**: $P(k; n, p) = \binom{n}{k} p^k (1-p)^{n-k}$. $\square$

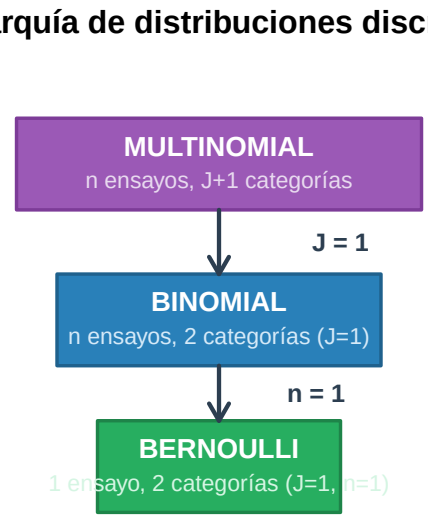

Figura 2.11: Jerarquía de distribuciones: la Bernoulli y la Binomial son casos particulares de la Multinomial.

> **Resumen:** La Multinomial es la distribución más general. Si restringimos a dos categorías ($J = 1$), obtenemos la Binomial. Si además hacemos un solo ensayo ($n = 1$), obtenemos la Bernoulli. Cada distribución es un **caso particular** de la anterior.

2.4 Variables dependientes limitadas continuas

2.4.1 Concepto

Hasta ahora hemos visto variables que toman **valores discretos** (0/1, o categorías). Pero también existen variables dependientes que son **continuas** pero cuyo rango está **limitado o restringido**. Esto sucede por dos razones:

- **Censura:** La variable existe para todos los individuos, pero solo observamos su valor en un subconjunto del rango. El resto se asigna a un valor fijo (típicamente 0).
- **Truncamiento (selección):** Solo observamos los datos de los individuos cuya variable dependiente supera (o no alcanza) un determinado umbral. Los demás **desaparecen** de la muestra.

  Clave: La diferencia fundamental es que en la **censura** observamos las variables explicativas $\mathbf{x}$ de **todos** los individuos, mientras que en el **truncamiento** perdemos toda la información de los individuos fuera del rango observable.

2.4.2 Variables censuradas

2.4.2.1 Concepto y ejemplos

En los datos **censurados**, todos los valores de la variable dependiente en un cierto rango se transforman o reportan como un solo valor, pero las variables explicativas $\mathbf{x}_i$ se observan para todos:

$$y_i = \begin{cases} y_i^* & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

donde $y_i^* = \mathbf{x}_i'\beta + u_i$ es la variable latente.

Ejemplos económicos de censura:

- **Gasto en seguros médicos:** Es positivo para quienes contratan un seguro y cero para los demás. Pero la renta, la edad y la situación

familiar se observan para todos.

- **Horas de trabajo:** Pueden ser 0 (para personas que no trabajan) o positivas. La educación, la experiencia y el número de hijos se observan para todos.
- **Demanda de un bien con restricción de capacidad:** Un coche cuesta al menos 13.000 €. Si la disposición a pagar del individuo es menor, observamos 0 como gasto, pero sí registramos sus datos socioeconómicos.

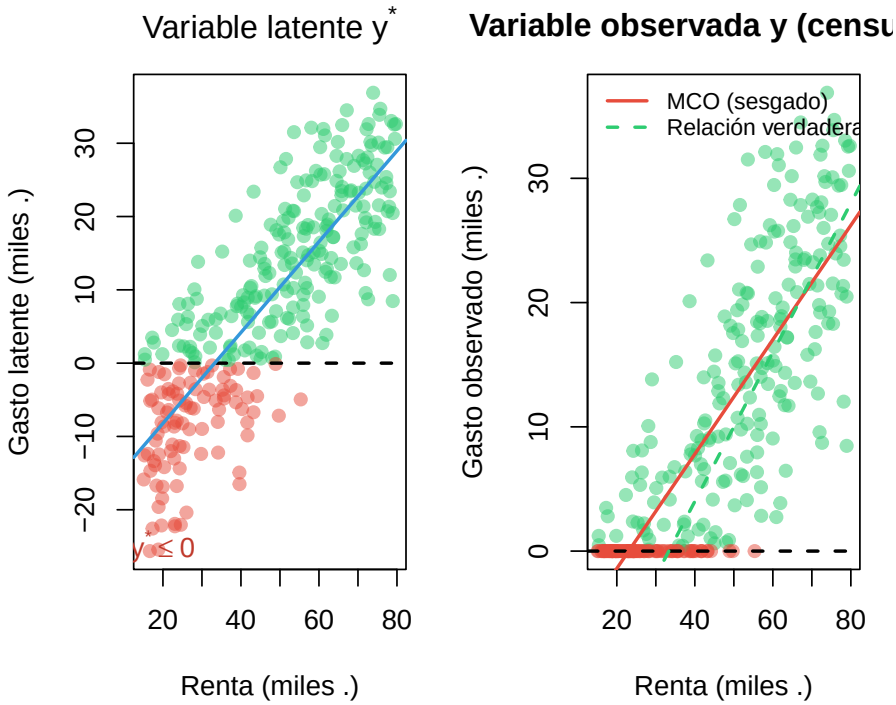

Figura 2.12: Ejemplo de datos censurados: gasto en seguros (censurado en 0).

En el panel derecho observamos que MCO aplicado a los datos censurados produce una estimación **sesgada** (línea roja): subestima la pendiente y sobreestima la constante, porque trata los ceros como si fueran valores reales. El modelo **Tobit** (Tema 3) corrige este sesgo.

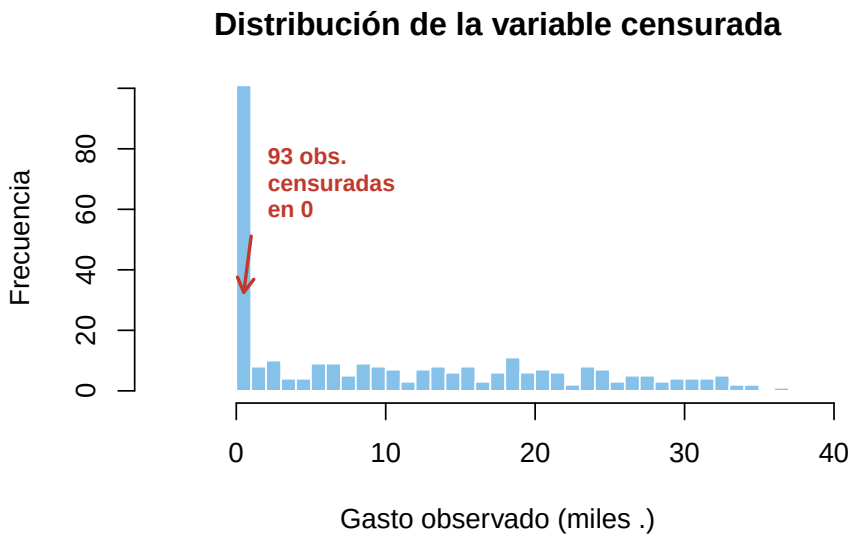

Figura 2.13: Histograma de una variable censurada: masa de probabilidad en 0 + distribución continua.

La distribución de la variable censurada tiene **dos componentes**: un componente **discreto** (la masa de probabilidad en 0) y un componente **continuo** (para los valores positivos). Esta mezcla es la razón por la que MCO no funciona correctamente.

2.4.2.2 Tipos de censura

La censura puede ser por la izquierda o por la derecha:

- **Censura por la izquierda** (desde abajo): $y_i = \max(y_i^*, c)$ — no observamos valores por debajo de c.
- **Censura por la derecha** (desde arriba): $y_i = \min(y_i^*, c)$ — no observamos valores por encima de c.

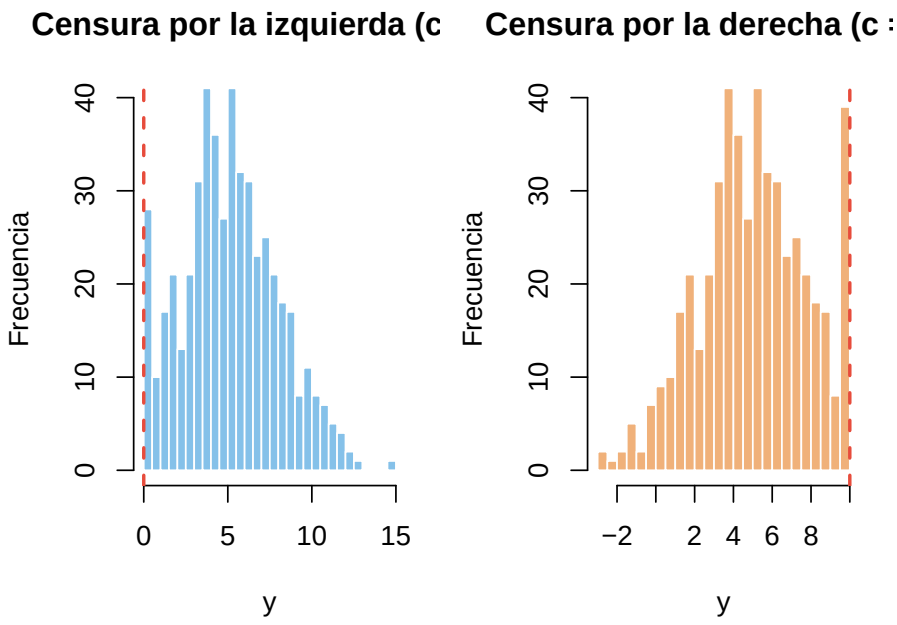

Figura 2.14: Censura por la izquierda vs. censura por la derecha.

Un ejemplo clásico de censura por la derecha: las calificaciones en un examen están censuradas en la nota máxima (10 sobre 10). Todos los estudiantes que habrían obtenido más de 10 (si fuera posible) quedan registrados con un 10.

2.4.3 Variables truncadas

2.4.3.1 Concepto y ejemplos

En el **truncamiento** (o **selección**), solo observamos los datos cuando y_i supera (o no alcanza) un umbral. Los individuos fuera del rango observable **desaparecen completamente** de la muestra: no observamos ni su y_i ni sus variables explicativas $\mathbf{x}_i$.

$$\text{Solo observamos } (y_i, \mathbf{x}_i) \text{ si } y_i > c$$

Ejemplos:

- **Mercado inmobiliario:** Si la vivienda más barata cuesta 300.000 €, solo observamos a los compradores con disposición a pagar $\geq$ 300.000 €. Los que no compran no aparecen en la muestra.
- **Encuestas de renta:** Si una encuesta solo incluye a hogares con renta superior a un umbral, los hogares con renta inferior no aparecen en los datos.
- **Admisión universitaria:** Si solo analizamos datos de estudiantes admitidos (nota > corte), los no admitidos están ausentes de la muestra.

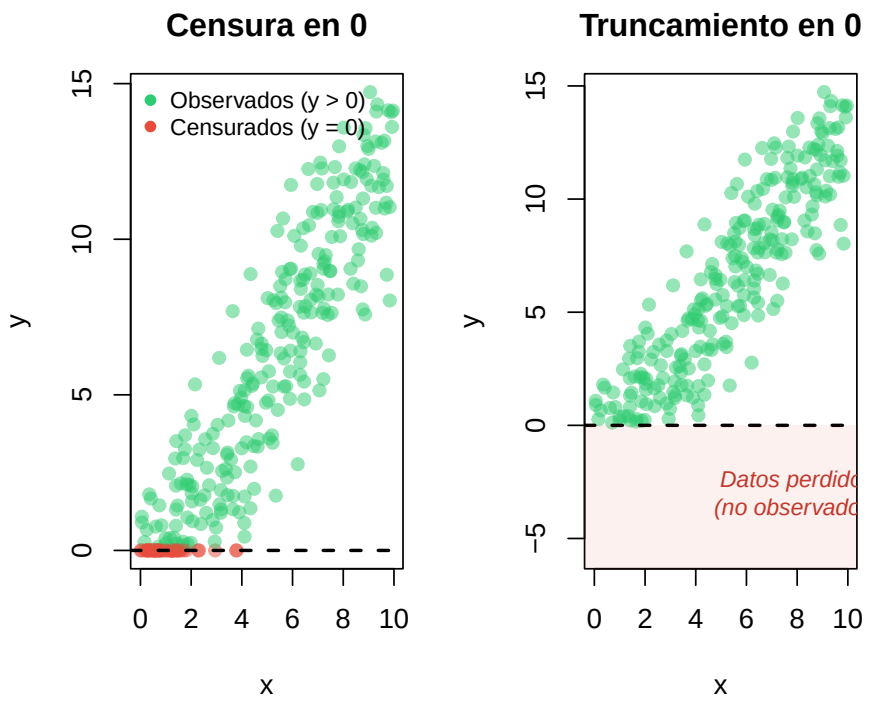

Figura 2.15: Censura vs. truncamiento: en la censura observamos las X de todos; en el truncamiento perdemos toda la información.

¿Por qué es peor el truncamiento que la censura? Porque en la censura al menos conservamos las variables explicativas de todos los individuos (sabemos *quiénes* son los censurados). En el truncamiento, esos individuos

simplemente no existen en nuestros datos, lo que genera un **sesgo de selección** más difícil de corregir.

2.4.3.2 Tipos de truncamiento

Al igual que en la censura:

- **Truncamiento por la izquierda:** Solo observamos $y_i > c$. Ejemplo: solo vemos compras por encima de un precio mínimo.
- **Truncamiento por la derecha:** Solo observamos $y_i < c$. Ejemplo: encuesta que excluye a los hogares con renta superior a un umbral.

2.4.4 Distribuciones para datos censurados y truncados

2.4.4.1 Distribución normal censurada

Si la variable latente $y^* \sim N(\mu, \sigma^2)$ y censuramos en 0, la distribución de la variable observada $y = \max(y^*, 0)$ tiene dos componentes:

$$f(y) = \begin{cases} \Phi(-\frac{\mu}{\sigma}) & \text{si } y = 0 \\ \frac{1}{\sigma}\phi(\frac{y-\mu}{\sigma}) & \text{si } y > 0 \end{cases}$$

donde $\phi(\cdot)$ es la densidad de la Normal estándar y $\Phi(\cdot)$ su distribución acumulada.

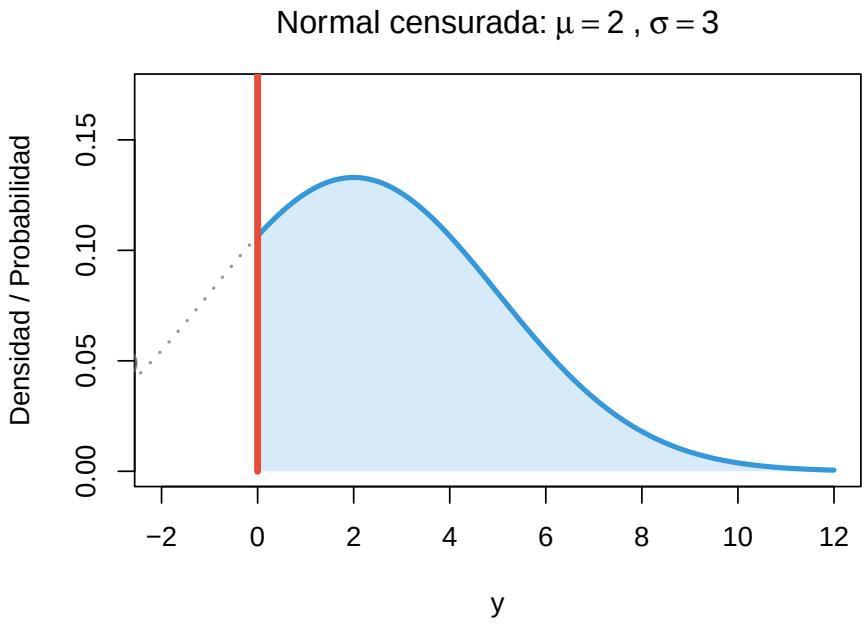

Figura 2.16: Distribución normal censurada: masa en 0 + densidad continua.

2.4.4.2 Distribución normal truncada

Si solo observamos los valores $y > 0$ de una variable $y^* \sim N(\mu, \sigma^2)$, la densidad se **reescala** para que integre a 1 en el rango observable:

$$f(y \mid y > 0) = \frac{\frac{1}{\sigma}\phi\left(\frac{y-\mu}{\sigma}\right)}{1 - \Phi\left(-\frac{\mu}{\sigma}\right)}, \qquad y > 0$$

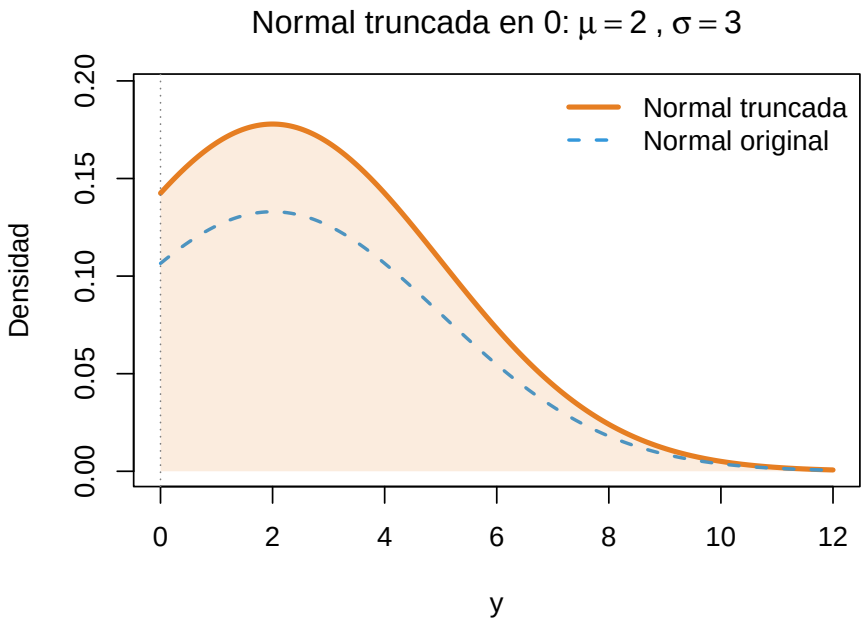

Figura 2.17: Distribución normal truncada vs. normal completa.

La distribución truncada es siempre más alta que la normal original en la zona observable, porque debe compensar la probabilidad perdida en la zona no observable.

2.4.5 Resumen: censura vs. truncamiento

Cuadro 2.5: Comparación entre censura y truncamiento

Caracteristica	Censura	Truncamiento
¿Se observan las X de todos?	Sí — las X se observan para todos los individuos	No — las X de los truncados se pierden
¿Hay masa de probabilidad en un punto?	Sí — hay una masa en el punto de censura (ej. y = 0)	No — la distribución es continua pero reescalada

Caracteristica	Censura	Truncamiento
Información perdida	Se pierden los valores exactos de y* para los censurados	Se pierde toda la información de los individuos truncados
Modelo adecuado	Tobit (Tema 3)	Modelos de selección (Heckman)
Sesgo si usamos MCO	Moderado — subestima pendientes	Grave — sesgo de selección

2.5 Funciones esenciales en R

A continuacion se recogen las funciones de R mas relevantes para este tema introductorio. Su uso detallado se desarrolla en la practica y el script.

Exploración de datos:

- `str()` — Estructura del dataset (tipos de variables, dimensiones).
- `summary()` — Estadísticos descriptivos.
- `table()` — Tabla de frecuencias para variables categoricas.
- `prop.table()` — Proporciones a partir de una tabla de frecuencias.

Distribuciones:

- `dbinom(k, n, p)` — Funcion de masa de la Binomial: $P(X = k)$.
- `pbinom(q, n, p)` — Funcion de distribucion acumulada de la Binomial.
- `rbinom(n, size, p)` — Generar datos aleatorios Binomial.
- `dnorm()`, `pnorm()`, `rnorm()` — Funciones de la Normal.
- `plogis()`, `qlogis()` — Funcion logistica y su inversa.

Modelo Lineal de Probabilidad (MLP):

- `lm(y ~ x1 + x2, data)` — Estimacion por MCO.
- `predict(modelo)` — Predicciones (pueden salir fuera de $[0, 1]$).
- `coeftest(modelo, vcov = vcovHC(...))` — Inferencia con errores robustos.

Visualizacion:

- `barplot()` — Diagrama de barras para variables categoricas.
- `hist()` — Histograma para variables continuas.
- `plot()` — Grafico de dispersion.
- `abline()` — Añadir lineas de referencia.

Tablas:

- `knitr::kable()` — Tabla formateada para documentos RMD.
- `DT::datatable()` — Tabla interactiva con exportacion a

Excel/CSV.

2.6 Resumen y hoja de ruta

2.6.1 Lo que hemos aprendido

En este tema hemos establecido las bases conceptuales de la microeconometría:

1. **Variable dependiente limitada**: su rango está restringido de alguna forma (binaria, multinomial o continua limitada).
2. **MCO no funciona** correctamente con estos datos: genera predicciones fuera de rango, viola la homocedasticidad y la normalidad.
3. Las **variables binarias** ($y \in \{0, 1\}$) siguen una distribución **Bernoulli** y se modelan mediante el concepto de **variable latente**.
4. Las **variables multinomiales** ($y \in \{0, 1, \dots, J\}$) pueden ser ordenadas o no ordenadas, y siguen una distribución **Multinomial**.
5. Las **variables continuas limitadas** pueden ser **censuradas** (observamos las X de todos, pero no el valor exacto de y para algunos) o **truncadas** (perdemos toda la información de los individuos fuera del rango).

2.6.2 Conexión con los temas siguientes

Cuadro 2.6: Hoja de ruta de la asignatura de Microeconometría

Tema	Contenido	Tipo de variable
Tema 1 (este)	Tipos de variables dependientes limitadas, distribuciones, por qué MCO falla	Todas (introducción general)
Tema 2	Modelos de elección discreta: Probit y Logit (variable binaria)	Binaria: y in {0, 1}
Tema 3	Modelos para datos censurados: Tobit (variable continua limitada)	Censurada: y >= 0

2.6.3 Tabla-resumen de distribuciones

Cuadro 2.7: Distribuciones asociadas a cada tipo de variable dependiente limitada

Distribución	Tipo	Soporte	Uso en microeconometría
Bernoulli(p)	Discreta	$\{0, 1\}$	Probit / Logit (Tema 2)
Binomial(n, p)	Discreta	$\{0, 1, \dots, n\}$	Verosimilitud en modelos binarios
Multinomial$(n, p_1 \dots p_J)$	Discreta	$k_0 + k_1 + \cdots + k_J = n$	Modelos multinomiales (avanzado)
Normal censurada	Mixta	$[0, +\infty)$	Modelo Tobit (Tema 3)
Normal truncada	Continua	$(c, +\infty)$	Modelos de selección (Heckman)

En el **Tema 2** veremos cómo los modelos Probit y Logit resuelven los problemas del MLP utilizando las distribuciones Normal y Logística como funciones de enlace. ¡Ya tenemos las bases para entenderlos!

Código R del capítulo

El script completo de este capítulo (`T01_mECO_Script_VD_Limitada.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Capítulo 3

Modelos de Elección Discreta

3.1 Introducción: ¿por qué modelos de elección discreta?

En muchas situaciones económicas, la variable que queremos explicar no es continua (como el salario o el PIB), sino que toma un número finito de valores. Los casos más habituales son las **decisiones binarias**:

- ¿Trabaja esta persona o no? ($y = 1$ o $y = 0$)
- ¿Se concede un crédito o se deniega?
- ¿Compra el consumidor el producto o no?

Cuando la variable dependiente es binaria, el modelo de regresión lineal clásico (MCO) presenta **problemas graves**. Los modelos de elección discreta —Probit y Logit— resuelven estos problemas y son la herramienta estándar en microeconometría aplicada.

En estos apuntes seguiremos un hilo conductor muy claro:

1. Primero entenderemos los **fundamentos estadísticos** que hay detrás (variable aleatoria, densidad, distribución, verosimilitud).
2. Después veremos el **Modelo Lineal de Probabilidad (MLP)** y sus limitaciones.
3. A continuación, los modelos **Probit** y **Logit**, que resuelven esas limitaciones.
4. Finalmente, aprenderemos a **interpretar** los resultados (efectos marginales, odds ratios) y a **evaluar** la calidad del modelo (pseudo-R^2, contrastes).

Todo se ilustrará con un ejemplo aplicado: la **participación laboral** en España.

3.2 Fundamentos estadísticos

Antes de estimar ningún modelo, necesitamos repasar cuatro conceptos clave que aparecen constantemente en el tema.

3.2.1 Variable aleatoria

Una **variable aleatoria** es una variable cuyo valor depende del resultado de un fenómeno aleatorio. En nuestro contexto:

$$y_i = \text{¿Trabaja la persona } i\text{?}$$

Antes de observar a la persona, **no sabemos** si y_i será 0 o 1. Después de observarla, tenemos un dato fijo. La estadística nos permite modelar esa incertidumbre.

Hay dos tipos:

- **Discreta**: toma valores contables $(0, 1, 2, \ldots)$. Ejemplo: $y \in \{0, 1\}$.
- **Continua**: toma cualquier valor en un intervalo. Ejemplo: el salario.

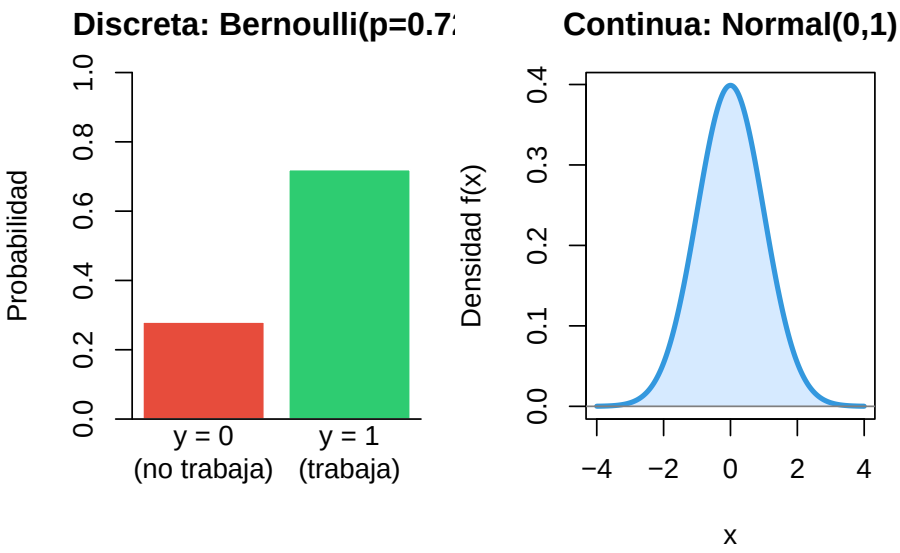

Figura 3.1: Variable discreta (Bernoulli) y continua (Normal).

3.2.2 La distribución de Bernoulli

Cuando y solo puede ser 0 o 1, sigue una distribución **Bernoulli(p)**:

$$P(y = 1) = p \qquad\qquad P(y = 0) = 1 - p$$

En una sola expresión compacta:

$$\boxed{P(y) = p^y \cdot (1 - p)^{1-y}}$$

Comprobación rápida:

- Si $y = 1$: $p^1 \cdot (1 - p)^0 = p$ ✓
- Si $y = 0$: $p^0 \cdot (1 - p)^1 = 1 - p$ ✓

Esta fórmula compacta es **exactamente** la que aparece dentro de la función de verosimilitud (sección 2.5). La clave de todo el tema es que, en lugar de asumir que p es la misma para todos los individuos, haremos que **dependa de sus características**: $p_i = F(x_i'\beta)$.

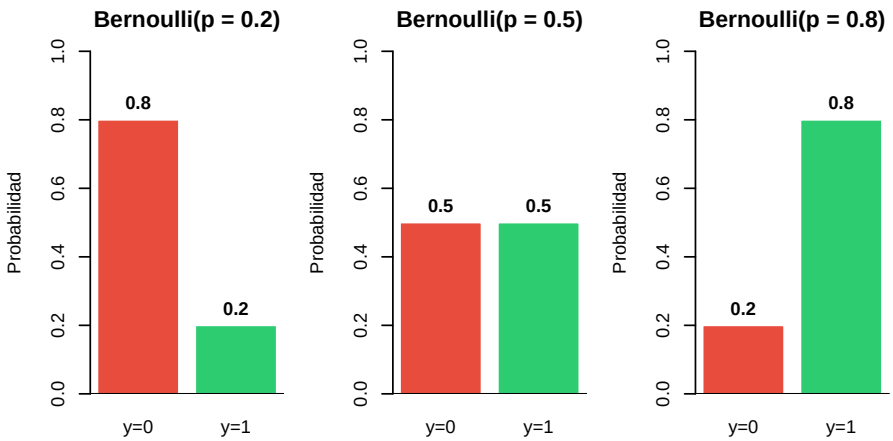

Figura 3.2: Distribución Bernoulli con distintos valores de p.

3.2.3 Función de densidad

Para variables **continuas**, no tiene sentido hablar de $P(X = 2.317...)$ (esa probabilidad es siempre cero). En su lugar usamos la **función de densidad** $f(x)$:

$$P(a < X < b) = \int_a^b f(x)\,dx = \text{área bajo la curva}$$

La distribución continua más importante en estadística es la **Normal** (campana de Gauss):

$$f(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

La **Normal estándar** $N(0,1)$ — con $\mu = 0$ y $\sigma = 1$ — es la que utiliza el modelo **Probit**.

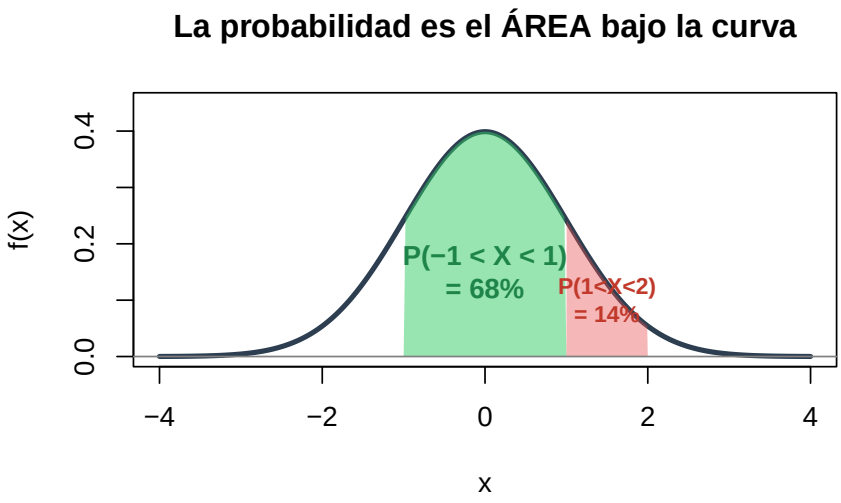

Figura 3.3: La probabilidad es el área bajo la curva de densidad.

3.2.4 Función de distribución acumulada (CDF)

La **CDF** responde a la pregunta: *¿cuál es la probabilidad de obtener un valor* $\leq x$?

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\, dt$$

Propiedad fundamental: $F(x)$ siempre está en $[0, 1]$. Esto la hace **perfecta para modelar probabilidades**.

Cada modelo usa una CDF diferente:

- **Probit** $\rightarrow \Phi(x'\beta)$, la CDF de la Normal estándar.
- **Logit** $\rightarrow \Lambda(x'\beta) = \frac{1}{1+e^{-x'\beta}}$, la CDF de la distribución logística.

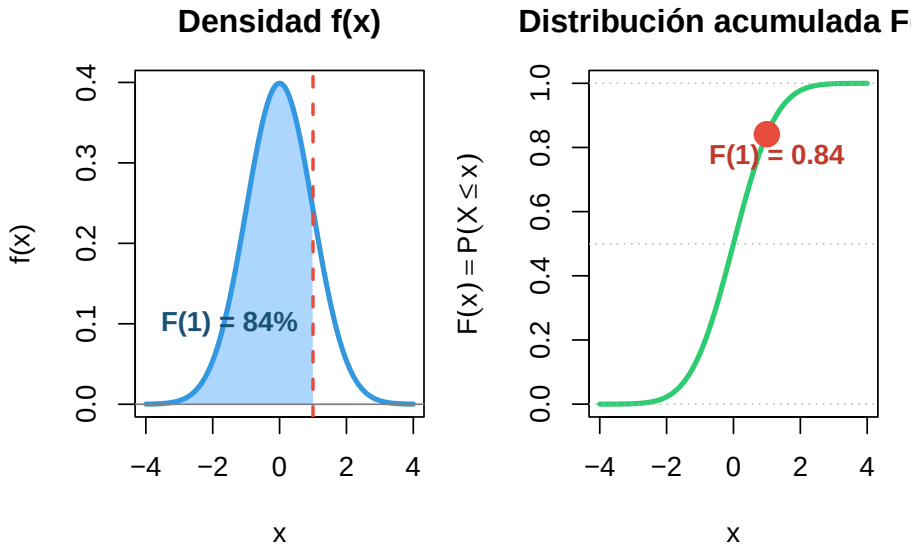

Figura 3.4: Densidad y distribución acumulada de la Normal estándar.

3.2.5 La verosimilitud: corazón de la estimación

3.2.5.1 Intuición

Imaginemos que lanzamos una moneda 3 veces y observamos: **Cara, Cara, Cruz**. ¿Cuál es la probabilidad p de cara más compatible con este resultado?

La **verosimilitud** $L(p)$ mide exactamente eso: *dado un valor del parámetro, ¿qué tan probable es haber observado estos datos?*

$$L(p) = p \cdot p \cdot (1-p) = p^2(1-p)$$

El **estimador de máxima verosimilitud (MV)** elige el valor de p que maximiza $L(p)$. En este ejemplo: $\hat{p} = 2/3$ (la proporción muestral de caras).

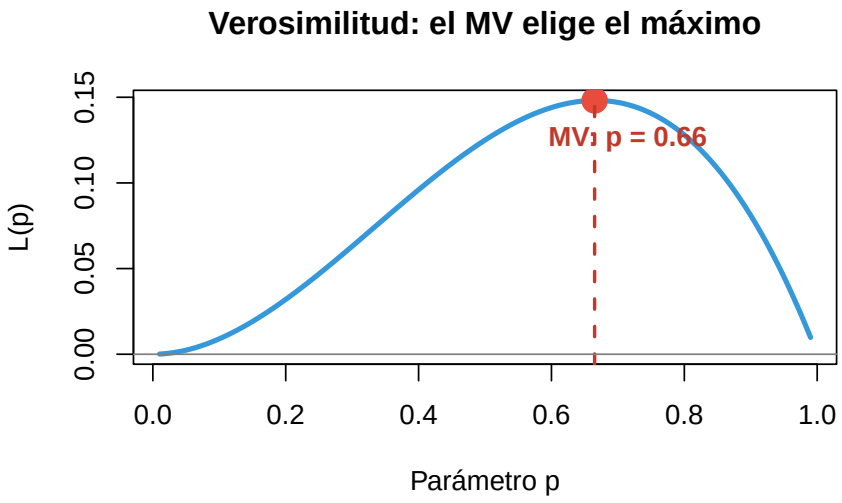

Figura 3.5: Verosimilitud de observar [Cara, Cara, Cruz] según el parámetro p.

3.2.5.2 De la verosimilitud a la log-verosimilitud

Con N observaciones independientes, la verosimilitud es un **producto**:

$$L(\beta) = \prod_{i=1}^{N} p_i^{y_i} \cdot (1 - p_i)^{1-y_i}$$

Problema práctico: multiplicar muchos números entre 0 y 1 produce números minúsculos que el ordenador no puede manejar (underflow numérico).

Solución: tomar logaritmos. El logaritmo convierte el producto en suma, y **el máximo se conserva** (el logaritmo es una función creciente):

$$\boxed{\ln L(\beta) = \sum_{i=1}^{N} [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)]}$$

Esta es la **función objetivo** que maximizan Probit y Logit. El término $ll_i = y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$ es la **contribución** del individuo i a la log-verosimilitud:

- Si $y_i = 1$ y el modelo predice $\widehat{P}_i$ alto $\rightarrow \ln(\widehat{P}_i)$ es cercano a 0 $\rightarrow$ **bien**.
- Si $y_i = 1$ pero el modelo predice $\widehat{P}_i$ bajo $\rightarrow \ln(\widehat{P}_i)$ es muy negativo $\rightarrow$ **mal**.

El estimador MV busca los β que hacen la log-verosimilitud **lo menos negativa posible**.

3.3 El Modelo Lineal de Probabilidad (MLP)

3.3.1 Planteamiento

El enfoque más simple para modelar una variable binaria es tratar y como si fuera continua y aplicar MCO:

$$P(y_i = 1 \mid x_i) = x_i'\beta = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots$$

Es decir, la probabilidad es una **función lineal** de las variables explicativas. Este modelo se llama **Modelo Lineal de Probabilidad (MLP)**.

Ventaja: es extremadamente sencillo. Los coeficientes **son directamente los efectos marginales**: β_j indica cuánto cambia la probabilidad al aumentar x_j en una unidad.

3.3.2 Limitaciones del MLP

El MLP tiene **tres problemas graves**:

3.3.2.1 Problema 1: Probabilidades fuera de $[0, 1]$

Una recta puede tomar cualquier valor real. Nada impide que el modelo prediga $\widehat{P} = -0.15$ o $\widehat{P} = 1.30$, lo cual **no tiene sentido** como probabilidad.

3.3.2.2 Problema 2: Heterocedasticidad

Si $y \sim \text{Bernoulli}(p_i)$, entonces $\text{Var}(\varepsilon_i) = p_i(1 - p_i)$, que depende de x_i. Los errores **no son homocedásticos**, lo que invalida la inferencia estándar (los errores estándar y los p-valores del MCO son incorrectos).

3.3.2.3 Problema 3: Efecto marginal constante

El MLP asume que el efecto de, por ejemplo, un año más de educación es **siempre el mismo**, independientemente de si la persona tiene 6 años o 18 años de educación. Económicamente, esto no es realista:

el efecto debería ser mayor en la zona intermedia (donde hay más incertidumbre) y menor en los extremos (donde la decisión ya está prácticamente tomada).

3.3.3 El modelo que vamos a estimar

A lo largo de todo este tema utilizaremos un mismo modelo aplicado: la **participación laboral**. La variable dependiente es binaria:

$$y_i = \begin{cases} 1 & \text{si la persona } i \text{ trabaja} \\ 0 & \text{si no trabaja} \end{cases}$$

El modelo que estimaremos relaciona la probabilidad de trabajar con seis variables explicativas:

$$P(\text{trabaja}_i = 1) = F(\beta_0 + \beta_1 \text{ educación}_i + \beta_2 \text{ edad}_i + \beta_3 \text{ sexo}_i + \beta_4 \text{ experiencia}_i + \beta_5 \text{ hij}$$

donde $F(\cdot)$ es la función de enlace: la identidad en el MLP, Φ en el Probit y Λ en el Logit. Las variables son:

- **educación**: años de educación completados.
- **edad**: edad en años.
- **sexo**: variable dummy (1 = Mujer, 0 = Hombre).
- **experiencia**: años de experiencia laboral.
- **hijos**: número de hijos menores de edad.
- **ingreso_familiar**: ingreso del hogar no procedente del trabajo del individuo (en miles de euros).

Estimaremos este mismo modelo con los tres métodos (MLP, Probit, Logit) para poder comparar resultados.

3.3.4 Ejemplo en R

Cuadro 3.1: Coeficientes del MLP (estimados por MCO)

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	0.0454	0.0933	0.4861	0.6271
educacion	0.0231	0.0068	3.3869	0.0008
edad	0.0127	0.0059	2.1554	0.0316
sexoMujer	-0.0870	0.0342	-2.5405	0.0114
experiencia	0.0011	0.0058	0.1838	0.8542
hijos	-0.0433	0.0145	-2.9832	0.0030
ingreso_familiar	-0.0054	0.0030	-1.7924	0.0737

Interpretación (recuerda: en el MLP, los coeficientes = efectos marginales):

- **educación**: un año más de educación aumenta la probabilidad de trabajar en 2.3 puntos porcentuales.
- **sexo** (**Mujer**): ser mujer reduce la probabilidad en 8.7 pp.

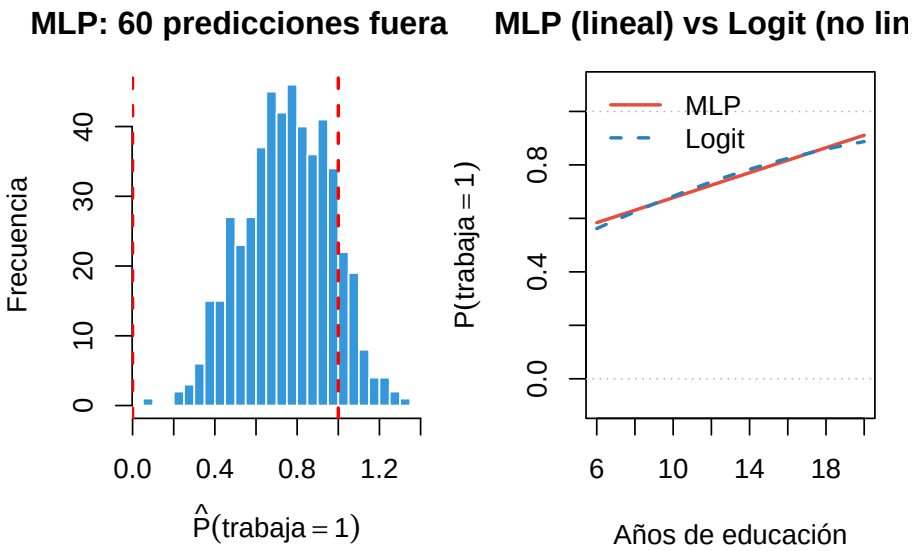

Figura 3.6: Limitaciones del MLP: predicciones fuera de [0,1] y efecto marginal constante.

Conclusión: El MLP sirve como referencia rápida, pero sus limitaciones teóricas son serias. Necesitamos modelos que **garanticen** $\hat{P} \in [0, 1]$ y capturen la no linealidad. Esos modelos son el Probit y el Logit.

3.4 El modelo Probit

3.4.1 Planteamiento

El modelo Probit resuelve los tres problemas del MLP **envolviendo** el índice lineal $x'\beta$ con la CDF de la Normal estándar $\Phi(\cdot)$:

$$\boxed{P(y_i = 1 \mid x_i) = \Phi(x_i'\beta) = \Phi(\beta_0 + \beta_1 x_{1i} + \cdots)}$$

donde $\Phi(z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt$

Dado que $\Phi(\cdot)$ siempre devuelve valores en $[0, 1]$, **las predicciones siempre son probabilidades válidas**.

3.4.1.1 ¿Cómo se estima?

No por MCO, sino por **máxima verosimilitud (MV)**. Se buscan los $\hat{\beta}$ que maximizan:

$$\ln L(\beta) = \sum_{i=1}^{N} [y_i \ln \Phi(x_i'\beta) + (1 - y_i) \ln(1 - \Phi(x_i'\beta))]$$

Este problema no tiene solución cerrada — se resuelve numéricamente mediante algoritmos iterativos (Newton-Raphson, BFGS, etc.). En R, la función `glm()` hace todo el trabajo.

3.4.2 Estimación en R

Cuadro 3.2: Coeficientes del modelo Probit (estimados por MV)

	Estimate	Std. Error	z value	Pr(>|z|)
(Intercept)	-1.9298	0.3865	-4.9927	0.0000
educacion	0.0924	0.0274	3.3751	0.0007
edad	0.0536	0.0240	2.2352	0.0254
sexoMujer	-0.3457	0.1409	-2.4534	0.0142
experiencia	0.0000	0.0234	0.0008	0.9993

	Estimate	Std. Error	z value	Pr(>|z|)
hijos	-0.1837	0.0585	-3.1417	0.0017
ingreso_familiar	-0.0233	0.0124	-1.8853	0.0594

3.4.2.1 ¿Cómo se interpretan los coeficientes?

¡Cuidado! A diferencia del MLP, los coeficientes del Probit **NO** son efectos marginales. Solo nos dicen la **dirección** del efecto:

- $\hat{\beta}_j > 0 \rightarrow$ la variable x_j **aumenta** la probabilidad.
- $\hat{\beta}_j < 0 \rightarrow$ la variable x_j **disminuye** la probabilidad.

Para saber **cuánto** cambia la probabilidad, necesitamos calcular los **efectos marginales** (sección 6).

3.5 El modelo Logit

3.5.1 Planteamiento

El modelo Logit es conceptualmente idéntico al Probit, pero usa la **función logística** $\Lambda(\cdot)$ en lugar de la Normal:

$$\boxed{P(y_i = 1 \mid x_i) = \Lambda(x_i'\beta) = \frac{1}{1 + e^{-x_i'\beta}} = \frac{e^{x_i'\beta}}{1 + e^{x_i'\beta}}}$$

3.5.1.1 Ventajas del Logit respecto al Probit

1. **Fórmula cerrada**: $\Lambda(z) = 1/(1+e^{-z})$ se calcula directamente, sin integrales.
2. **Interpretación vía odds ratios**: los coeficientes tienen una interpretación directa en términos de log-odds (veremos esto en la sección 7).
3. **El más usado** en la práctica por estas dos razones.

3.5.1.2 Logit vs Probit: ¿cuál elegir?

En la práctica, ambos producen resultados **prácticamente idénticos**. La función logística y la Normal acumulada son casi iguales en el rango central, donde se concentra la mayoría de los datos. Solo difieren ligeramente en las colas (la logística tiene colas más gruesas).

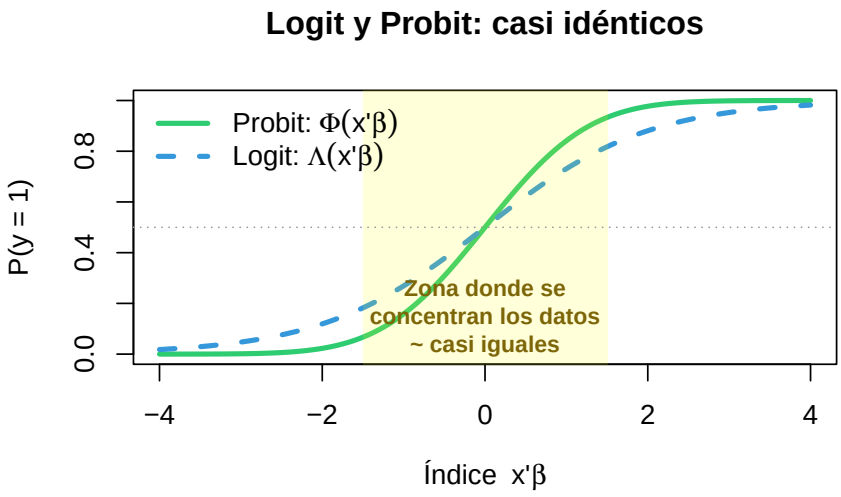

Figura 3.7: Logit y Probit son casi idénticos en el rango central.

Regla práctica: la elección entre Logit y Probit es una **convención** del área de investigación. En economía del trabajo y salud suele usarse Probit; en marketing, finanzas y machine learning se prefiere Logit.

3.5.2 Estimación en R

Cuadro 3.3: Coeficientes del modelo Logit (estimados por MV)

	Estimate	Std. Error	z value	Pr(>|z|)
(Intercept)	-3.3250	0.6825	-4.8721	0.0000
educacion	0.1586	0.0481	3.3008	0.0010
edad	0.0932	0.0422	2.2073	0.0273
sexoMujer	-0.6437	0.2477	-2.5989	0.0094
experiencia	0.0012	0.0412	0.0290	0.9769
hijos	-0.3111	0.1024	-3.0366	0.0024
ingreso_familiar	-0.0434	0.0216	-2.0052	0.0449

3.6 El flujo completo: de las X a la probabilidad

Para que quede completamente claro cómo funcionan estos modelos, veamos el flujo paso a paso:

PASO 1 — Índice lineal: se calcula $x_i'\hat{\beta} = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots$ (esto es como el $\hat{y}$ del MCO).

PASO 2 — Función de enlace: el índice se "pasa" por la función $F(\cdot)$: Φ para Probit o Λ para Logit.

PASO 3 — Probabilidad: el resultado es $\hat{P}_i = F(x_i'\hat{\beta}) \in [0, 1]$.

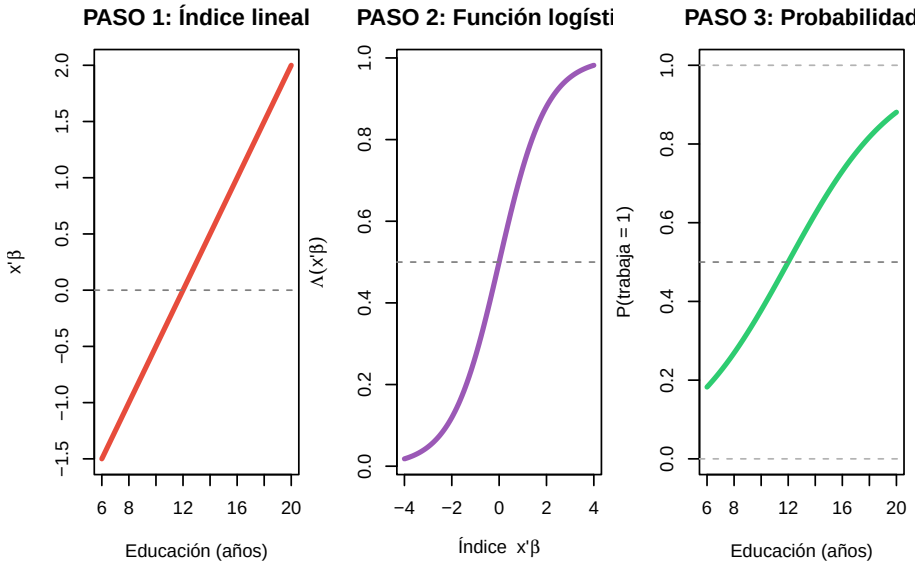

Figura 3.8: Del índice lineal a la probabilidad: el flujo completo.

3.7 Efectos marginales

3.7.1 El problema: ¿qué significan realmente los coeficientes?

Empecemos con una pregunta concreta. Hemos estimado el modelo Logit y obtenemos $\widehat{\beta}_{\text{educacion}} = 0.35$. Un alumno pregunta: *"¿Entonces un año más de educación aumenta la probabilidad de trabajar en 0.35?"*

La respuesta es NO. Y entender por qué es la clave de toda esta sección.

3.7.1.1 En el MLP sí funcionaba así

En el MLP (regresión lineal), el modelo es:

$$P(y_i = 1) = \beta_0 + \beta_1 \cdot \text{educacion}_i + \cdots$$

Si $\beta_1 = 0.04$, entonces un año más de educación **siempre** aumenta la probabilidad en 0.04 (4 puntos porcentuales), sin importar nada más. El efecto es **constante**.

3.7.1.2 En el Logit/Probit ya no funciona así

En el Logit, el modelo es:

$$P(y_i = 1) = \Lambda(\beta_0 + \beta_1 \cdot \text{educacion}_i + \cdots)$$

La función $\Lambda(\cdot)$ es una curva en forma de S, **no** una recta. Por eso, el efecto de un año más de educación **depende de dónde estés en la curva**.

3.7.2 Ejemplo numérico paso a paso

Veamos esto con números concretos. Supongamos un modelo Logit simple:

$$P(\text{trabaja} = 1) = \Lambda(-3 + 0.25 \cdot \text{educacion})$$

3.7.2.1 Persona A: 8 años de educación (nivel bajo)

$$x'\beta = -3 + 0.25 \times 8 = -1.0 \qquad \Rightarrow \qquad P = \Lambda(-1.0) = \frac{1}{1+e^1} = 0.269$$

Si pasa a **9 años**:

$$x'\beta = -3 + 0.25 \times 9 = -0.75 \qquad \Rightarrow \qquad P = \Lambda(-0.75) = 0.321$$

Efecto marginal $= 0.321 - 0.269 =$ **+5.2 puntos porcentuales**.

3.7.2.2 Persona B: 12 años de educación (nivel medio)

$$x'\beta = -3 + 0.25 \times 12 = 0.0 \qquad \Rightarrow \qquad P = \Lambda(0) = 0.500$$

Si pasa a **13 años**:

$$x'\beta = -3 + 0.25 \times 13 = 0.25 \qquad \Rightarrow \qquad P = \Lambda(0.25) = 0.562$$

Efecto marginal $= 0.562 - 0.500 =$ **+6.2 puntos porcentuales**.

3.7.2.3 Persona C: 18 años de educación (nivel alto)

$$x'\beta = -3 + 0.25 \times 18 = 1.5 \qquad \Rightarrow \qquad P = \Lambda(1.5) = 0.818$$

Si pasa a **19 años**:

$$x'\beta = -3 + 0.25 \times 19 = 1.75 \qquad \Rightarrow \qquad P = \Lambda(1.75) = 0.852$$

Efecto marginal $= 0.852 - 0.818 =$ **+3.4 puntos porcentuales**.

3.7.2.4 ¿Qué acabamos de ver?

El mismo cambio (+1 año de educación) produce efectos **muy diferentes** según el punto de partida:

Persona	Educación	P antes	P después	Efecto marginal
A (nivel bajo)	$8 \to 9$	26.9%	32.1%	**+5.2 pp**
B (nivel medio)	$12 \to 13$	50.0%	56.2%	**+6.2 pp**
C (nivel alto)	$18 \to 19$	81.8%	85.2%	**+3.4 pp**

El efecto es máximo en la zona intermedia (donde $P \approx 0.5$) y se reduce en los extremos. Esto tiene todo el sentido económico: si alguien ya tiene un 95% de probabilidad de trabajar, un año más de educación apenas puede subirla; pero si está en el 50%, el mismo año puede marcar una gran diferencia.

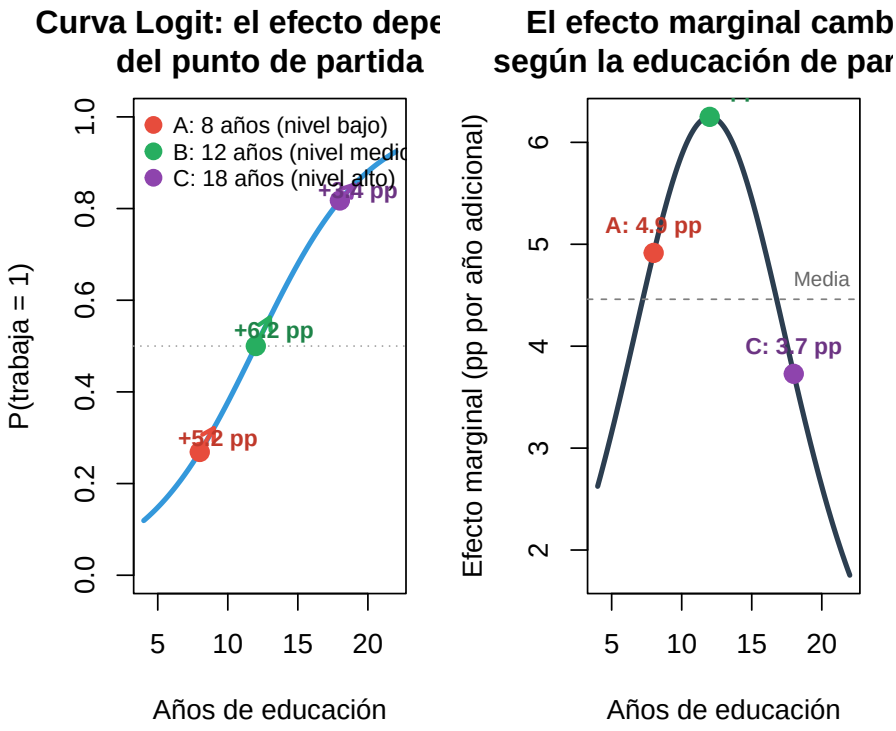

Figura 3.9: El efecto de +1 año de educación depende del punto de partida: máximo en la zona intermedia, mínimo en los extremos.

3.7.3 La fórmula general del efecto marginal

Lo que acabamos de ver con las tres personas tiene una fórmula exacta. Recordemos qué hicimos: para cada persona calculamos la probabilidad *antes* y *después* de añadir un año de educación, y restamos. Eso es una aproximación discreta de la **derivada parcial**:

$$\boxed{\frac{\partial P(y=1)}{\partial x_j} = f(x'\beta) \cdot \beta_j}$$

Vamos a desmontar esta fórmula pieza a pieza:

Pieza 1: β_j — es el coeficiente estimado de la variable x_j. Nos dice la **dirección** del efecto (positivo o negativo) y su **intensidad en la escala**

latente (en el mundo del índice $x'\beta$).

Pieza 2: $f(x'\beta)$ — es un **factor de escala** que "traduce" el efecto del mundo latente al mundo de las probabilidades. Este factor **cambia de persona a persona** porque depende de $x'\beta$, es decir, de las características de cada individuo.

¿Qué es exactamente f? Es la **función de densidad** que corresponde a la CDF del modelo:

- En el **Logit**, la CDF es $\Lambda(z)$, y su densidad es $f(z) = \Lambda(z) \cdot [1 - \Lambda(z)] = P \cdot (1 - P)$.
- En el **Probit**, la CDF es $\Phi(z)$, y su densidad es $f(z) = \phi(z)$ (la campana de Gauss).
- En el **MLP**, la CDF es la identidad, y su "densidad" es $f = 1$ siempre. Por eso en el MLP el efecto marginal es simplemente β_j.

3.7.3.1 ¿Cuánto vale ese factor de escala?

Veámoslo con el ejemplo del Logit. El factor es $f(z) = P(1 - P)$:

Probabilidad P del individuo	Factor $f = P(1 - P)$	¿Grande o pequeño?
0.05 (casi seguro que no trabaja)	$0.05 \times 0.95 = 0.048$	Muy pequeño
0.25	$0.25 \times 0.75 = 0.188$	Moderado
0.50 (máxima incertidumbre)	$0.50 \times 0.50 =$ **0.250**	**Máximo**
0.75	$0.75 \times 0.25 = 0.188$	Moderado
0.95 (casi seguro que trabaja)	$0.95 \times 0.05 = 0.048$	Muy pequeño

Intuición clave: el factor es máximo cuando $P = 0.50$ (máxima incertidumbre) y se acerca a cero en los extremos. Esto significa que **un año más de educación "mueve" más la probabilidad de las personas que están en la zona de duda** que de las que ya tienen la decisión prácticamente tomada.

3.7.3.2 Volviendo al ejemplo numérico

Retomemos las tres personas con $\beta_{\text{educacion}} = 0.25$:

- **Persona A** ($P = 0.269$): EM $= 0.269 \times 0.731 \times 0.25 = 0.049 \rightarrow$ **4.9 pp**
- **Persona B** ($P = 0.500$): EM $= 0.500 \times 0.500 \times 0.25 = 0.063 \rightarrow$ **6.3 pp** (máximo)
- **Persona C** ($P = 0.818$): EM $= 0.818 \times 0.182 \times 0.25 = 0.037 \rightarrow$ **3.7 pp**

Son exactamente los valores que habíamos calculado antes "a bruto" restando probabilidades. La fórmula simplemente nos da el atajo matemático.

3.7.4 ¿Cómo resumir el efecto en un solo número?

Ya tenemos claro que el efecto marginal es **distinto para cada individuo**. Pero cuando presentamos resultados necesitamos un solo número que diga "el efecto de la educación es de X puntos porcentuales". ¿Cómo lo obtenemos?

Hay dos estrategias. Veamos cada una con un ejemplo numérico para que quede claro qué hace cada una.

3.7.4.1 Opción 1: Efecto marginal en la media (MEM)

¿Qué hace? Inventa un "individuo promedio" — uno que tenga exactamente la educación media de la muestra, la edad media, etc. — y calcula el efecto marginal solo para él.

$$\text{MEM}_j = f(\bar{x}'\hat{\beta}) \cdot \hat{\beta}_j$$

Ejemplo: si en nuestra muestra la educación media es 13 años, la edad media es 41 años, etc., el MEM toma esa persona ficticia, calcula su $x'\beta$, obtiene su factor f, y multiplica por β_j. Un solo cálculo, un solo número.

¿Cuándo falla? El "individuo promedio" puede no existir. Por ejemplo, si el sexo medio es 0.48 (48% mujeres), ¿qué es una persona con

sexo = 0.48? No tiene sentido. Otro problema: si la distribución de probabilidades en la muestra es muy asimétrica, el individuo medio puede no ser representativo del efecto típico.

En R se obtiene con la opción `atmean = TRUE`.

3.7.4.2 Opción 2: Efecto marginal promedio (AME) □ RECOMENDADO

¿Qué hace? En lugar de inventar una persona ficticia, calcula el efecto marginal para **cada una de las N personas reales** de la muestra, y luego toma el promedio:

$$\text{AME}_j = \frac{1}{N}\sum_{i=1}^{N} \underbrace{f(x_i'\widehat{\beta})}_{\text{factor del individuo } i} \cdot \widehat{\beta}_j$$

Ejemplo con N = 5 personas (simplificado):

Individuo	P_i	Factor $f_i = P_i(1-P_i)$	$\text{EM}_i = f_i \times 0.25$
1	0.30	0.210	0.053
2	0.55	0.248	0.062
3	0.80	0.160	0.040
4	0.45	0.248	0.062
5	0.70	0.210	0.053

$$\text{AME} = \frac{0.053 + 0.062 + 0.040 + 0.062 + 0.053}{5} = 0.054 \quad (5.4\,\text{pp})$$

¿Por qué es mejor? Porque usa personas reales, no ficticias. No hay ningún "individuo promedio inventado" — simplemente se promedian los efectos de todos. Es el método **recomendado** en la literatura aplicada.

En R se obtiene con la opción `atmean = FALSE`.

3.7.4.3 ¿Y para variables categóricas (como sexo)?

La educación es continua: podemos hablar de "un año más" y calcular una derivada. Pero el sexo es una categoría: no podemos hablar de "un poquito más de mujer", ni tiene sentido calcular una derivada respecto al sexo. Entonces, **¿cómo medimos el efecto de ser mujer?**

La idea es sencilla: **simulamos el cambio**. Para cada individuo, calculamos qué probabilidad tendría si fuera hombre y qué probabilidad tendría si fuera mujer, y restamos. Veámoslo paso a paso.

Paso 1 — Tomamos un individuo cualquiera (por ejemplo, el individuo 1: 14 años de educación, 35 años, 2 hijos, etc.).

Paso 2 — Calculamos su probabilidad "como hombre": ponemos sexo = Hombre, dejamos todo lo demás igual, y evaluamos el modelo:

$$P_1^{\text{hombre}} = \Lambda(\hat{\beta}_0 + \hat{\beta}_1 \cdot 14 + \hat{\beta}_2 \cdot 35 + \hat{\beta}_3 \cdot 0 + \cdots) = 0.78$$

Paso 3 — Calculamos su probabilidad "como mujer": cambiamos *solo* el sexo a Mujer:

$$P_1^{\text{mujer}} = \Lambda(\hat{\beta}_0 + \hat{\beta}_1 \cdot 14 + \hat{\beta}_2 \cdot 35 + \hat{\beta}_3 \cdot 1 + \cdots) = 0.65$$

Paso 4 — Restamos: el efecto marginal del sexo para este individuo es:

$$\text{EM}_1 = P_1^{\text{mujer}} - P_1^{\text{hombre}} = 0.65 - 0.78 = -0.13 \quad (-13 \text{ pp})$$

Es decir, *esta persona en concreto*, si fuera mujer en lugar de hombre, tendría 13 puntos porcentuales menos de probabilidad de trabajar.

Paso 5 — Repetimos para todos y promediamos (AME): hacemos lo mismo para los 500 individuos de la muestra. Cada uno tendrá un efecto diferente (porque sus demás características son distintas). El AME es el promedio:

Individuo	P^{hombre}	P^{mujer}	Efecto del sexo
1	0.78	0.65	−13 pp
2	0.45	0.32	−13 pp
3	0.92	0.86	−6 pp
4	0.60	0.46	−14 pp
...	...	...	...
AME			**≈ −12 pp**

Fíjate que **el efecto no es igual para todos**: para el individuo 3 (que ya tenía una probabilidad muy alta) el efecto es menor (−6 pp), mientras que para el 4 (en zona intermedia) es mayor (−14 pp). Esto es coherente con todo lo que hemos visto: el efecto es mayor donde hay más incertidumbre.

> **En resumen**: para variables categóricas, el efecto marginal es la diferencia de probabilidades "encendiendo y apagando" la categoría, manteniendo todo lo demás constante. El AME promedia esa diferencia para todos los individuos.

3.7.5 Cálculo en R de los efectos marginales

Todo lo explicado anteriormente se implementa en R. Primero veremos cómo hacerlo "a mano" (para entender qué hace R por dentro) y después con el paquete `mfx` (lo que usaremos en la práctica).

3.7.5.1 Cálculo "a mano"

El procedimiento para calcular el efecto marginal de educación en el modelo Logit es:

1. Para **un individuo**: obtener su índice $x'\hat{\beta}$, calcular su probabilidad $P = \Lambda(x'\hat{\beta})$, obtener el factor $f = P(1 - P)$, y multiplicar por $\hat{\beta}_{\text{edu}}$.
2. Para **el AME**: repetir lo anterior para los N individuos de la muestra y promediar.

Internamente, R ejecuta exactamente esos dos pasos — primero para un individuo concreto y luego para todos.

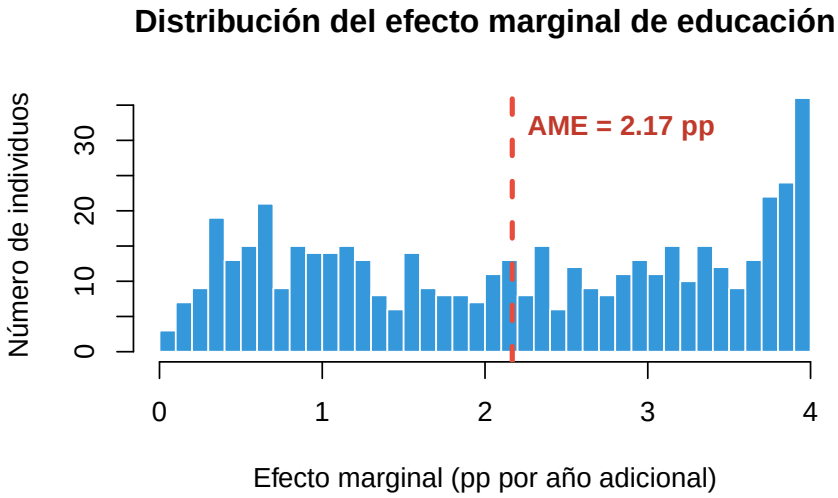

Figura 3.10: Distribución del efecto marginal de educación en la muestra: cada individuo tiene su propio efecto. El AME es el promedio.

3.7.5.2 Con el paquete `mfx` (lo que haremos en la práctica)

En la práctica no hace falta calcular nada a mano. Todo lo anterior se obtiene automáticamente con una sola línea:

3.7.5.3 Interpretación completa de los resultados

Cuadro 3.8: Efectos marginales promedio (AME) del modelo Logit

Variable	Cambio unitario	AME (pp)
Educación	+1 año educ.	+2.17
Edad	+1 año edad	+1.27
Experiencia	+1 año exp.	+0.02
Sexo (Mujer)	Mujer vs Hombre	-8.85

Variable	Cambio unitario	AME (pp)
Hijos	+1 hijo menor	-4.25
Ingreso familiar	+1.000 EUR ingreso	-0.59

Regla para recordar: en Logit/Probit, **nunca interpretes el coeficiente directamente**. Siempre calcula los efectos marginales. El coeficiente te dice la dirección $(+/-)$; el efecto marginal te dice **cuánto** cambia la probabilidad.

3.8 Odds ratios (solo Logit)

3.8.1 ¿Qué es el odds?

El **odds** es la razón entre la probabilidad de que algo ocurra y la de que no ocurra:

$$\text{Odds} = \frac{P}{1-P}$$

Probabilidad P	Odds	Lectura coloquial
0.50	1.0	"50-50", equiprobable
0.75	3.0	"3 a 1 a favor"
0.25	0.33	"1 a 3 en contra"
0.90	9.0	"9 a 1 a favor"

3.8.2 Los log-odds y el modelo Logit: demostración

El modelo Logit tiene una propiedad única que lo distingue del Probit: el índice lineal $x'\beta$ es directamente el **logaritmo del odds** (log-odds). Vamos a demostrarlo paso a paso.

3.8.2.1 Paso 1: partimos de la función logística

En el modelo Logit, la probabilidad de éxito es:

$$P = \Lambda(x'\beta) = \frac{1}{1+e^{-x'\beta}} = \frac{e^{x'\beta}}{1+e^{x'\beta}}$$

3.8.2.2 Paso 2: calculamos $1-P$

$$1 - P = 1 - \frac{e^{x'\beta}}{1+e^{x'\beta}} = \frac{1+e^{x'\beta}-e^{x'\beta}}{1+e^{x'\beta}} = \frac{1}{1+e^{x'\beta}}$$

3.8.2.3 Paso 3: formamos el odds $\frac{P}{1-P}$

$$\text{Odds} = \frac{P}{1-P} = \frac{\frac{e^{x'\beta}}{1+e^{x'\beta}}}{\frac{1}{1+e^{x'\beta}}} = e^{x'\beta}$$

Los $(1 + e^{x'\beta})$ se cancelan y queda simplemente $e^{x'\beta}$.

3.8.2.4 Paso 4: tomamos logaritmo

$$\ln\left(\frac{P}{1-P}\right) = x'\beta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$$

Resultado clave: en el modelo Logit, el logaritmo del odds es una función **lineal** de las variables explicativas. Esto NO ocurre en el Probit.

3.8.2.5 Paso 5: demostramos que e^{β_j} es el odds ratio

Queremos ver qué pasa con el odds cuando x_j aumenta en una unidad (de x_j a $x_j + 1$), manteniendo todo lo demás constante.

Odds cuando x_j toma su valor original:

$$\text{Odds}_{\text{antes}} = e^{\beta_0 + \cdots + \beta_j\, x_j + \cdots}$$

Odds cuando x_j aumenta en 1 unidad:

$$\text{Odds}_{\text{después}} = e^{\beta_0 + \cdots + \beta_j\, (x_j + 1) + \cdots}$$

El odds ratio es el cociente:

$$OR_j = \frac{\text{Odds}_{\text{después}}}{\text{Odds}_{\text{antes}}} = \frac{e^{\beta_0 + \cdots + \beta_j (x_j + 1) + \cdots}}{e^{\beta_0 + \cdots + \beta_j\, x_j + \cdots}}$$

Al dividir exponenciales con la misma base, se restan los exponentes. Todos los términos se cancelan excepto el que contiene β_j:

$$OR_j = e^{\beta_j(x_j+1)-\beta_j x_j} = e^{\beta_j x_j+\beta_j-\beta_j x_j} = \boxed{e^{\beta_j}}$$

Resultado fundamental: el odds ratio e^{β_j} **no depende del punto de evaluación** x_j. Es constante para cualquier individuo. Esta es la gran ventaja interpretativa del Logit frente al Probit.

3.8.2.6 Qué significa exactamente el odds ratio: ejemplo numérico

Supongamos que estimamos un Logit donde y = "trabaja" (1) o "no trabaja" (0), y una de las variables es **educación** (años). Obtenemos $\widehat{\beta}_{\text{edu}} = 0.30$.

El odds ratio es: $OR = e^{0.30} = 1.350$

Pregunta: ¿Qué significa exactamente $OR = 1.350$?

Imaginemos dos personas idénticas en todo (misma edad, sexo, experiencia...) excepto que la Persona B tiene **un año más** de educación que la Persona A.

	Persona A (12 años edu.)	Persona B (13 años edu.)
Probabilidad de trabajar P	0.60	?
Odds = $P/(1-P)$	$0.60/0.40 = 1.50$	$1.50 \times 1.350 = 2.025$
Probabilidad resultante	0.60	$2.025/3.025 = 0.669$

Lectura: cada año adicional de educación **multiplica** el odds de trabajar por 1.35. Es decir, el odds de la Persona B es un **35% mayor** que el de la Persona A.

3.8.2.7 Pero, ¿qué es el odds exactamente? La analogía del hipódromo

Es habitual confundir el **odds** con la **probabilidad**. No son lo mismo. Para entenderlo de forma intuitiva, pensemos en un **hipódromo**.

Un caballo tiene un 80% de probabilidades de ganar una carrera.

- **Probabilidad**: 80%. De cada 10 carreras, gana 8.
- **Odds**: 8 victorias / 2 derrotas = **4 a 1** a favor.

El odds nos dice: **"por cada vez que pierde, gana 4 veces"**. Es la ventaja a favor del evento.

Probabilidad P	Odds = $P/(1-P)$	Lectura
0.50	1.0	"50-50": gana 1 vez por cada vez que pierde
0.75	3.0	"3 a 1": gana 3 veces por cada vez que pierde
0.80	4.0	"4 a 1": gana 4 veces por cada vez que pierde
0.90	9.0	"9 a 1": gana 9 veces por cada vez que pierde

3.8.2.8 ¿Qué es entonces el odds ratio? Seguimos en el hipódromo

El **odds ratio** responde a la pregunta: **si cambio algo, ¿cuánto se multiplica esa ventaja?**

Ejemplo con OR > 1: le ponemos un **mejor jinete** al caballo. El OR del jinete es 2.0.

- **Antes** (jinete normal): odds = 4 ("gana 4 por cada 1 que pierde")
- **Después** (mejor jinete): odds = $4 \times 2.0 = 8$ ("gana 8 por cada 1 que pierde")

El mejor jinete ha **duplicado la ventaja**. Eso es $OR = 2$.

Ejemplo con OR < 1: ahora llueve. El OR de la lluvia es 0.50.

- **Antes** (seco): odds = 4 ("gana 4 por cada 1 que pierde")
- **Después** (lluvia): odds = $4 \times 0.50 = 2$ ("gana 2 por cada 1 que pierde")

La lluvia ha **reducido la ventaja a la mitad**. Eso es $OR = 0.5$.

Ejemplo con OR = 1: le cambiamos la silla de montar. El OR de la silla es 1.0.

- **Antes**: odds = 4. **Después**: odds = $4 \times 1.0 = 4$. No cambia nada.

La silla no afecta. $OR = 1$ significa "sin efecto".

3.8.2.9 Del hipódromo a la econometría

El razonamiento es exactamente el mismo. Si en un Logit de participación laboral obtenemos:

- **Educación**: $OR = 1.35$. Cada año de educación adicional **mejora la ventaja** de trabajar vs. no trabajar un 35%. Como pasar de "gano 4 a 1" a "gano 5.4 a 1".
- **Hijos**: $OR = 0.67$. Cada hijo **recorta la ventaja** de trabajar un 33%. Como pasar de "gano 4 a 1" a "gano 2.7 a 1".

Volvamos al ejemplo numérico de las Personas A y B:

- Persona A (12 años edu., $P = 0.60$): odds = $0.60/0.40 = 1.50$ ("trabaja 1.5 veces por cada vez que no trabaja")
- Persona B (13 años edu.): odds = $1.50 \times 1.35 = 2.025$ ("trabaja 2 veces por cada vez que no trabaja")
- Probabilidad resultante de B: $P = 2.025/3.025 = 0.669$

3.8.2.10 Odds ratio $\neq$ cambio en probabilidad

Atención a un punto que se presta a confusión:

$$\text{El odds subió un 35\%} \quad \neq \quad \text{la probabilidad subió un 35\%}$$

La probabilidad pasó de 60.0% a 66.9%: solo subió **~7 puntos porcentuales**. ¿Por qué? Porque odds y probabilidad están relacionados de forma **no lineal**: $P = \text{Odds}/(1 + \text{Odds})$.

El OR te dice cuánto cambia la **ventaja relativa** (la "apuesta"), no cuánto cambia la probabilidad directamente. Para conocer el cambio en probabilidad, se utilizan los **efectos marginales** (sección 7).

Regla de oro: el **OR** comunica cuánto se *multiplica la ventaja*. Los **efectos marginales** comunican cuánto cambia la *probabilidad* en puntos porcentuales. Son complementarios.

Fórmula general para interpretar el cambio porcentual del odds:

$$\text{Cambio \% en el odds} = (OR - 1) \times 100$$

3.8.2.11 Guía de interpretación según el valor del OR

Cuando $OR > 1$ (el coeficiente β_j es positivo):

- $OR = 1.10$: el odds aumenta un 10% por cada unidad adicional de x_j.
- $OR = 1.50$: el odds aumenta un 50%.
- $OR = 2.00$: el odds se **duplica**.
- $OR = 3.00$: el odds se **triplica**.

Cuando $OR < 1$ (el coeficiente β_j es negativo):

Este caso se presta a confusión. Veámoslo con cuidado.

Si $\hat{\beta}_{\text{hijos}} = -0.40$, entonces $OR = e^{-0.40} = 0.670$.

Esto significa que cada hijo adicional **multiplica** el odds por 0.670. Es decir, el nuevo odds es solo el 67% del anterior: **se reduce un 33%**.

Ejemplo numérico: supongamos que una mujer sin hijos tiene $P = 0.80$ de trabajar:

Situación	Odds	Cálculo	P resultante
Sin hijos	$0.80/0.20 = 4.00$	(partida)	0.800
Con 1 hijo	$4.00 \times 0.670 = 2.68$		$2.68/3.68 = 0.728$
Con 2 hijos	$2.68 \times 0.670 = 1.796$		$1.796/2.796 = 0.642$
Con 3 hijos	$1.796 \times 0.670 = 1.203$		$1.203/2.203 = 0.546$

Lectura: cada hijo adicional reduce el odds de trabajar un 33%. Observa que el efecto es **multiplicativo**: no se restan 33 puntos porcentuales, sino que el odds se multiplica por 0.67 cada vez.

- $OR = 0.90$: el odds se reduce un 10%.
- $OR = 0.50$: el odds se reduce un 50% (se divide por 2).
- $OR = 0.25$: el odds se reduce un 75% (se divide por 4).

Cuando $OR = 1$ (el coeficiente $\beta_j = 0$):

La variable no tiene efecto. El odds no cambia. Esto equivale a decir que la variable es irrelevante para predecir y.

> **Atención**: el odds ratio mide el cambio en el **odds** (razón $P/(1 - P)$), NO en la probabilidad directamente. Un $OR = 2$ no significa que la probabilidad se duplique. Para conocer el cambio en probabilidad, hay que calcular los efectos marginales (sección 7).
>
> **Recordatorio**: los odds ratios solo tienen interpretación directa en el modelo **Logit**, porque es el único donde $\ln(\text{Odds}) = x'\beta$ (lineal). En el Probit no se calculan odds ratios — se usan directamente los efectos marginales.

Cuadro 3.13: Odds Ratios del modelo Logit con IC al 95%

Variable	OR	IC_95_inf	IC_95_sup
(Intercept)	0.036	0.009	0.137
educacion	1.172	1.067	1.288
edad	1.098	1.011	1.192
sexoMujer	0.525	0.323	0.854
experiencia	1.001	0.923	1.085
hijos	0.733	0.599	0.896
ingreso_familiar	0.958	0.918	0.999

Ejemplo de interpretación:

Cuadro 3.14: Interpretación de los Odds Ratios del modelo Logit

Variable	OR	Cambio en odds
educacion	1.172	+17.2%
edad	1.098	+9.8%
sexoMujer	0.525	-47.5%
experiencia	1.001	+0.1%
hijos	0.733	-26.7%
ingreso_familiar	0.958	-4.2%

3.9 Bondad de ajuste: Pseudo-R² de McFadden

3.9.1 ¿Por qué no podemos usar el R² clásico?

El R^2 clásico del MCO mide la proporción de varianza explicada, pero en modelos binarios estimados por MV no existe una descomposición análoga de la varianza. En su lugar se usa el **Pseudo-R² de McFadden**:

$$\boxed{\tilde{R}^2 = 1 - \frac{\ln L_{SR}}{\ln L_R}}$$

donde:

- $\ln L_R$ es la log-verosimilitud del modelo **restringido** (solo la constante, sin variables explicativas).
- $\ln L_{SR}$ es la log-verosimilitud del modelo **sin restringir** (completo, con todas las variables).

3.9.1.1 Guía de interpretación

Pseudo-R²	Interpretación
< 0.10	Ajuste débil
$[0.10, 0.20]$	Ajuste aceptable
$[0.20, 0.40]$	Buen ajuste
> 0.40	Ajuste excelente (raro en datos sociales)

¡Cuidado! No se puede comparar directamente con el R^2 del MCO. Un pseudo-R^2 de 0.20 es un resultado perfectamente respetable en microeconometría.

3.9.2 Criterios de información: AIC y BIC

Además del pseudo-R^2, existen dos criterios que permiten comparar modelos de forma más rigurosa: el **Criterio de Información de Akaike (AIC)** y el **Criterio de Información Bayesiano (BIC)**. Ambos parten de la log-verosimilitud pero incorporan una **penalización por**

complejidad: cuantos más parámetros tenga el modelo, mayor es la penalización, lo que desincentiva el sobreajuste.

El **AIC** se define como:

$$\text{AIC} = -2 \ln L(\hat{\beta}) + 2k$$

donde $\ln L(\hat{\beta})$ es la log-verosimilitud maximizada del modelo y k es el número de parámetros estimados (incluida la constante). El primer término mide la bondad de ajuste (menor $= $ mejor) y el segundo penaliza la complejidad.

El **BIC** (también llamado criterio de Schwarz) incorpora además el tamaño muestral:

$$\text{BIC} = -2 \ln L(\hat{\beta}) + k \ln(n)$$

donde n es el número de observaciones. Dado que $\ln(n) > 2$ para cualquier muestra de más de 7 observaciones, el BIC penaliza la complejidad **más severamente** que el AIC y tiende a seleccionar modelos más parsimoniosos.

La interpretación de ambos criterios es sencilla: **menor es mejor**. Al comparar dos modelos estimados sobre los mismos datos, se prefiere el que presente un AIC (o BIC) inferior. Ambos criterios no tienen una escala absoluta — solo tienen sentido como herramienta de comparación relativa entre modelos alternativos.

En la práctica, AIC y BIC no siempre seleccionan el mismo modelo. Cuando discrepan, el AIC suele preferir modelos ligeramente más complejos, mientras que el BIC tiende a ser más conservador. La elección entre uno y otro depende de si se prioriza la capacidad predictiva (AIC) o la parsimonia (BIC).

3.9.3 Cálculo en R

Cuadro 3.16: Bondad de ajuste: Pseudo-R^2 de McFadden, AIC y BIC

Modelo	Pseudo-R^2 McFadden	AIC	BIC
Logit	0.2403	439.5	469.0
Probit	0.2394	440.0	469.5

Además, la **tabla de clasificación** proporciona una medida intuitiva de la capacidad predictiva:

Cuadro 3.17: Tabla de clasificación (umbral = 0,5). Tasa de aciertos: 81.2%%

Observado	0	1
0	56	68
1	26	350

3.10 Contrastes de hipótesis

3.10.1 Significación individual: el test z (o test de Wald individual)

Antes de contrastar grupos de variables, la pregunta más básica es: **¿es significativa esta variable concreta?** Es decir, ¿contribuye a explicar y?

3.10.1.1 Planteamiento

Para cada coeficiente β_j del modelo, contrastamos:

$$H_0 : \beta_j = 0 \qquad \text{(la variable } x_j \text{ NO influye en } y\text{)}$$
$$H_1 : \beta_j \neq 0 \qquad \text{(la variable } x_j \text{ SÍ influye en } y\text{)}$$

3.10.1.2 El estadístico

$$z_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \quad \xrightarrow{d} \quad N(0,1) \qquad \text{bajo } H_0$$

donde $\text{SE}(\hat{\beta}_j)$ es el error estándar del coeficiente estimado.

Regla de decisión: rechazamos H_0 (la variable es significativa) si $|z_j| > z_{\alpha/2}$. Para un nivel del 5%, el valor crítico es $z_{0.025} = 1.96$.

Equivalentemente, rechazamos si el **p-valor** $< \alpha$ (habitualmente $\alpha = 0.05$).

3.10.1.3 Dónde aparece en R

Al hacer `summary(modelo)`, R muestra una tabla con cuatro columnas para cada coeficiente:

Columna	Significado
`Estimate`	$\hat{\beta}_j$ (coeficiente estimado)
`Std. Error`	$\text{SE}(\hat{\beta}_j)$ (error estándar)

Columna	Significado
`z value`	El estadístico $z_j = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$
`Pr(>|z|)`	El p-valor del contraste bilateral

Los asteriscos al final de cada fila resumen la significación:

- $***$: p < 0.001 (muy significativo)
- $**$: p < 0.01
- $*$: p < 0.05
- . : p < 0.10 (significativo solo al 10%)
- (vacío) : no significativo

3.10.1.4 Tabla resumen: coeficiente, efecto marginal, odds ratio e interpretación

Para fijar ideas, supongamos un modelo Logit estimado sobre participación laboral (y = trabaja). La tabla siguiente resume los resultados estadísticos:

Variable	$\hat{\beta}$	p-valor	EM (pp)	OR
educación	+0.30	<0.001***	+5.2	1.35
sexo (Mujer)	$-$0.88	0.002**	$-$15.1	0.41
hijos	$-$0.40	0.013*	$-$6.8	0.67
experiencia	+0.05	0.230	+0.9	1.05

Interpretación de cada variable:

La **educación** es altamente significativa ($p < 0.001$). Cada año adicional de educación aumenta la probabilidad de trabajar en 5.2 puntos porcentuales y multiplica el odds por 1.35 (un incremento del 35% en la ventaja relativa).

El **sexo** también es significativo ($p = 0.002$). Ser mujer, respecto a ser hombre y manteniendo el resto constante, reduce la probabilidad de trabajar en 15.1 puntos porcentuales. El odds de trabajar de una mujer

es un 59% inferior al de un hombre con idénticas características ($OR = 0.41$).

Cada **hijo** adicional reduce la probabilidad en 6.8 puntos porcentuales y el odds en un 33% ($OR = 0.67, p = 0.013$).

La **experiencia**, en cambio, no resulta significativa ($p = 0.230$): no se detecta evidencia estadística de que influya en la participación laboral en este modelo.

> **Nota**: el coeficiente $\hat{\beta}$ indica la dirección del efecto y permite calcular el OR (exponenciando), pero su magnitud NO es directamente interpretable como cambio en probabilidad. Para eso sirven los efectos marginales.

3.10.1.5 Ejemplo en R

Cuadro 3.20: Test de significación individual (test z) — Modelo Logit

Variable	$\hat{\beta}$	SE	p	OR
educacion	0.1586	0.0481	0.0010	1.172
edad	0.0932	0.0422	0.0273	1.098
sexoMujer	-0.6437	0.2477	0.0094	0.525
experiencia	0.0012	0.0412	0.9769	1.001
hijos	-0.3111	0.1024	0.0024	0.733
ingreso_familiar	-0.0434	0.0216	0.0449	0.958

3.10.2 Test de Wald (significación conjunta)

3.10.2.1 ¿Qué pregunta responde?

El test z individual que acabamos de ver contrasta si **una sola** variable es significativa. Pero con frecuencia queremos contrastar si **un grupo de variables** es conjuntamente significativo. Por ejemplo: ¿contribuyen conjuntamente las variables demográficas (edad, sexo, hijos) a explicar la participación laboral? Es posible que ninguna de ellas sea

individualmente significativa, pero que juntas sí aporten información relevante.

El **test de Wald** responde exactamente a esta pregunta. Su hipótesis nula establece que **todos los coeficientes del grupo** son simultáneamente cero:

$$H_0 : \beta_{j_1} = \beta_{j_2} = \cdots = \beta_{j_r} = 0$$

Si rechazamos H_0, concluimos que al menos una de las variables del grupo tiene un efecto significativo sobre y.

3.10.2.2 El estadístico

El estadístico de Wald mide la distancia entre los coeficientes estimados y los valores que impone la hipótesis nula (en este caso, cero), ponderada por la precisión de la estimación:

$$W = \hat{d}' \, \hat{V}_d^{-1} \, \hat{d}$$

donde $\hat{d} = R\hat{\beta} - q$ es el vector de desviaciones respecto a H_0 (si $H_0 : \beta = 0$, entonces $\hat{d} = \hat{\beta}$) y $\hat{V}_d = R \, \widehat{\text{Var}}(\hat{\beta}) \, R'$ es la matriz de varianzas-covarianzas de esas desviaciones.

Bajo H_0, el estadístico sigue asintóticamente una distribución **chi-cuadrado** con r grados de libertad:

$$W \sim \chi^2_r \qquad \text{bajo } H_0$$

donde r es el **número de restricciones** que impone la hipótesis nula, es decir, el número de coeficientes que estamos contrastando simultáneamente. Si contrastamos que 3 variables son conjuntamente nulas, $r = 3$ y el estadístico se compara con una χ^2_3.

3.10.2.3 Ejemplo numérico

Supongamos que nuestro modelo Logit de participación laboral tiene 6 variables explicativas (educación, edad, sexo, experiencia, hijos, ingreso familiar) y queremos contrastar si **todas ellas** son conjuntamente significativas. La hipótesis nula es $H_0 : \beta_1 = \beta_2 = \cdots = \beta_6 = 0$, lo que impone $r = 6$ restricciones.

El test calcula W y lo compara con la distribución χ^2_6. Si $W = 85.3$ y el p-valor asociado es $p < 0.001$, rechazamos H_0: las variables, en conjunto, sí explican la participación laboral. Un modelo con solo la constante sería significativamente peor.

3.10.2.4 Cálculo en R

3.10.2.5 Interpretación del resultado

El output de `wald.test()` muestra el valor del estadístico W, los grados de libertad ($r = 6$, porque contrastamos 6 coeficientes) y el p-valor. Si el p-valor es inferior a 0.05, rechazamos H_0 y concluimos que el modelo en su conjunto es significativo: al menos una de las seis variables influye en la probabilidad de trabajar.

Conviene destacar que el test de Wald solo necesita estimar el modelo **completo** (sin restricciones). No requiere estimar el modelo restringido, lo que lo hace computacionalmente eficiente.

3.10.3 Test de Razón de Verosimilitud (LR)

3.10.3.1 ¿Qué pregunta responde?

El test de Razón de Verosimilitud (LR, *Likelihood Ratio*) responde a la misma pregunta que el test de Wald — ¿es significativo un grupo de variables? — pero utiliza una lógica diferente. En lugar de medir la distancia entre los coeficientes estimados y cero, el test LR **compara directamente cuánto mejora el ajuste** del modelo al incluir las variables en cuestión.

La idea es intuitiva: si añadir las variables mejora sustancialmente la

log-verosimilitud, es que aportan información relevante.

3.10.3.2 El estadístico

Se necesitan dos modelos:

- **Modelo restringido** (M_R): el modelo bajo H_0, sin las variables que queremos contrastar. Si la hipótesis es que todas las variables son nulas, el modelo restringido contiene solo la constante.
- **Modelo sin restringir** (M_{SR}): el modelo completo, con todas las variables.

El estadístico LR mide el doble de la diferencia de log-verosimilitudes:

$$LR = 2\left[\ln L(\hat{\beta}_{SR}) - \ln L(\hat{\beta}_R)\right]$$

donde $\ln L(\hat{\beta}_{SR})$ es la log-verosimilitud del modelo completo y $\ln L(\hat{\beta}_R)$ la del modelo restringido. Dado que el modelo completo siempre ajusta al menos tan bien como el restringido, esta diferencia es siempre ≥ 0. Cuanto mayor sea, más evidencia hay contra H_0.

Bajo H_0, el estadístico sigue asintóticamente una distribución chi-cuadrado:

$$LR \sim \chi^2_r \qquad \text{bajo } H_0$$

donde r es, de nuevo, el número de restricciones (parámetros que se fijan a cero bajo H_0). Los grados de libertad coinciden con la diferencia en el número de parámetros entre los dos modelos: $r = k_{SR} - k_R$.

3.10.3.3 Ejemplo numérico

Retomemos nuestro modelo Logit con 6 variables. El modelo completo tiene $k_{SR} = 7$ parámetros (6 coeficientes + la constante) y una log-verosimilitud de, por ejemplo, $\ln L_{SR} = -210.5$. El modelo restringido (solo la constante) tiene $k_R = 1$ parámetro y $\ln L_R = -253.2$.

El estadístico LR es:

$$LR = 2 \times [-210.5 - (-253.2)] = 2 \times 42.7 = 85.4$$

Los grados de libertad son $r = 7 - 1 = 6$ (las 6 variables que añadimos). El p-valor se obtiene de la distribución χ^2_6: con $LR = 85.4$, el p-valor es prácticamente cero ($p < 0.001$), por lo que rechazamos H_0 con total contundencia. Las seis variables, en conjunto, mejoran significativamente el modelo.

3.10.3.4 Cálculo en R

3.10.3.5 Wald vs LR: ¿cuál usar?

Ambos tests son **asintóticamente equivalentes**: para muestras grandes producen resultados prácticamente idénticos. Las diferencias son de carácter práctico. El test de Wald solo necesita estimar un modelo (el completo), lo que lo hace más eficiente cuando el modelo restringido es costoso de estimar. El test LR, en cambio, requiere estimar ambos modelos, pero es conceptualmente más directo y, en general, se considera ligeramente más fiable en muestras finitas.

En la práctica, la mayoría de los investigadores reportan ambos, y es habitual que conduzcan a las mismas conclusiones.

3.11 Comparación completa: MLP vs Probit vs Logit

3.11.1 Coeficientes

Los coeficientes de los tres modelos **no son directamente comparables** porque están en escalas diferentes. Lo que debe coincidir (y coincide) es:

- El **signo** de cada coeficiente.
- La **significatividad** estadística.

Cuadro 3.21: Coeficientes de los tres modelos (escalas NO comparables)

Variable	MLP	Probit	Logit
(Intercept)	0.0454	-1.9298	-3.3250
educacion	0.0231	0.0924	0.1586
edad	0.0127	0.0536	0.0932
sexoMujer	-0.0870	-0.3457	-0.6437
experiencia	0.0011	0.0000	0.0012
hijos	-0.0433	-0.1837	-0.3111
ingreso_familiar	-0.0054	-0.0233	-0.0434

3.11.2 Efectos marginales (sí son comparables)

Los efectos marginales **sí** se pueden comparar directamente entre los tres modelos:

Cuadro 3.22: Efectos marginales (pp): los tres modelos dan resultados similares

Variable	MLP_pp	Probit_pp	Logit_pp
educacion	2.31	2.21	2.17
edad	1.27	1.28	1.27
sexoMujer	-8.70	-8.30	-8.85
experiencia	0.11	0.00	0.02
hijos	-4.33	-4.39	-4.25

Variable	MLP_pp	Probit_pp	Logit_pp
ingreso_familiar	-0.54	-0.56	-0.59

3.11.3 Gráfico comparativo

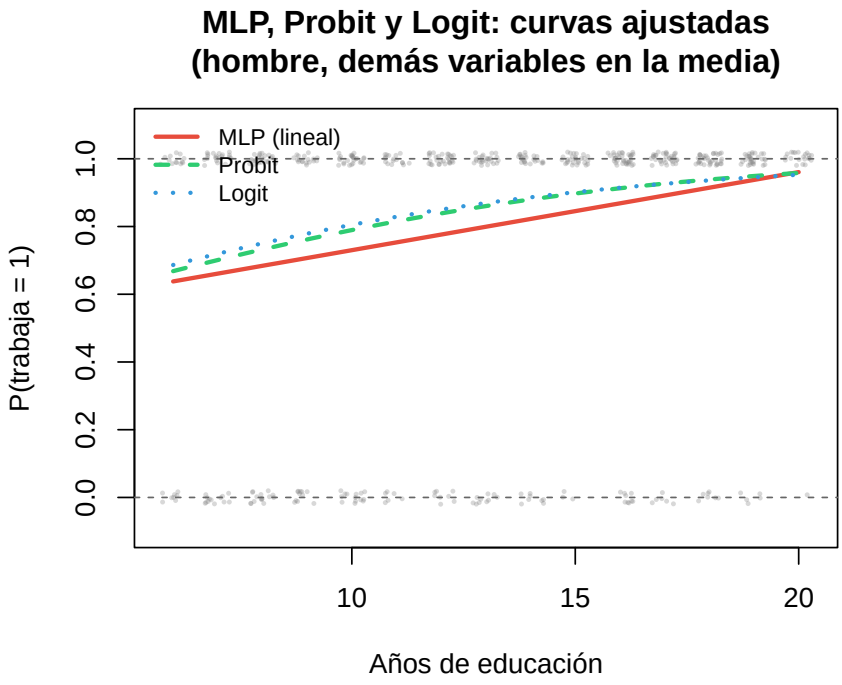

Figura 3.11: Los tres modelos ajustados sobre los datos. Probit y Logit son casi idénticos; el MLP puede salir de [0,1].

3.11.4 Resumen comparativo

MLP → Simple, rápido, pero con problemas teóricos serios (predicciones fuera de [0,1], heterocedasticidad, efecto marginal constante). Útil como referencia inicial.

Probit → Basado en la distribución Normal estándar. Teóricamente sólido. Interpretación vía efectos marginales. Habitual en economía del

trabajo.

Logit $\rightarrow$ Basado en la distribución logística. Coeficientes interpretables como log-odds. Cálculo más sencillo. El más popular en aplicaciones prácticas.

Conclusión: Probit y Logit producen resultados **prácticamente idénticos**. La elección depende de la convención del área de investigación y de si interesa interpretar odds ratios ($\rightarrow$ Logit).

3.12 Resumen: lo esencial en 10 puntos

1. **Variable aleatoria binaria** $y \in \{0, 1\} \rightarrow$ sigue una distribución Bernoulli(p).
2. **Función de densidad** $f(x)$: la probabilidad de variables continuas es el **área bajo la curva**.
3. **CDF** $F(x) = P(X \leq x)$: siempre en $[0, 1] \rightarrow$ perfecta para modelar probabilidades.
4. **Probit**: $P(y = 1) = \Phi(x'\beta)$. **Logit**: $P(y = 1) = \Lambda(x'\beta) = 1/(1 + e^{-x'\beta})$.
5. **Estimación por MV**: maximizar $\ln L(\beta) = \sum[y_i \ln P_i + (1 - y_i) \ln(1 - P_i)]$.
6. **Coeficientes** $\rightarrow$ solo indican la *dirección* del efecto ($\beta > 0 \Rightarrow \uparrow P$); NO son efectos marginales.
7. **Efectos marginales** $\rightarrow \frac{\partial P}{\partial x_j} = f(x'\beta) \cdot \beta_j$; dependen del punto de evaluación; usar AME.
8. **Odds Ratios** (solo Logit) $\rightarrow OR = e^{\beta}$; $OR > 1$ aumenta odds, $OR < 1$ reduce odds.
9. **Pseudo-R² McFadden** $\rightarrow 1 - \ln L_{SR} / \ln L_R$; valores $[0.2, 0.4]$ = buen ajuste.
10. **Contrastes** $\rightarrow$ Wald y LR $\sim \chi^2_r$ bajo H_0; asintóticamente equivalentes.

Material complementario: el script `T02_mECO_Script_Eleccion.R` y la práctica `T02_mECO_Practica_CdeA.Rmd` (en la carpeta `tema2/`) contienen la implementación paso a paso de todo lo desarrollado en estos apuntes.

3.13 Funciones esenciales en R

A continuación se recogen las funciones de R más relevantes para los modelos de elección discreta tratados en este tema. Su uso detallado se desarrolla en la práctica y el script asociados.

3.13.1 Estimación

- `glm(y ~ x1 + x2, family = binomial(link = "probit"), data = datos)` — estima un modelo **Probit**.
- `glm(y ~ x1 + x2, family = binomial(link = "logit"), data = datos)` — estima un modelo **Logit**.
- `lm(y ~ x1 + x2, data = datos)` — estima el **Modelo Lineal de Probabilidad** (MLP) por MCO.

3.13.2 Predicción

- `predict(modelo, type = "response")` — probabilidades estimadas $\hat{P}(y = 1|X)$.
- `fitted(modelo)` — equivalente a `predict()` con `type = "response"` para los datos de estimación.

3.13.3 Efectos marginales

- `margins::margins(modelo)` — calcula los **efectos marginales medios** (AME).
- `margins::margins(modelo, at = list(x1 = valor))` — efecto marginal en un punto concreto (MEM).
- `summary(margins(modelo))` — tabla con AME, errores estándar e intervalos de confianza.

3.13.4 Odds ratios (solo Logit)

- `exp(coef(modelo))` — odds ratios a partir de los coeficientes estimados.
- `exp(confint(modelo))` — intervalos de confianza para los odds ratios.

3.13.5 Bondad de ajuste

- `pscl::pR2(modelo)` — pseudo-R^2 de McFadden y otros.
- `AIC(modelo)` / `BIC(modelo)` — criterios de información.
- `logLik(modelo)` — log-verosimilitud del modelo.

3.13.6 Contrastes de hipótesis

- `summary(modelo)` — contrastes individuales de Wald (z-test) para cada coeficiente.
- `lmtest::waldtest(modelo_completo, modelo_restringido)` — contraste de

Wald conjunto.

- `lmtest::coeftest(modelo)` — tabla de contrastes con errores estándar robustos si se combinan con `sandwich::vcovHC()`.

3.13.7 Clasificación

- `ifelse(predict(modelo, type = "response") > 0.5, 1, 0)` — clasificación con umbral 0.5.
- `table(observado, predicho)` — matriz de confusión.
- `caret::confusionMatrix(factor(predicho), factor(observado))` — métricas completas (accuracy, sensibilidad, especificidad).

Código R del capítulo

El script completo de este capítulo (`T02_mECO_Script_A01_LOGIT_USA_Help_v2.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Capítulo 4

Modelos para Datos Censurados (Tobit)

4.1 Introducción: ¿por qué modelos para datos censurados?

En el Tema 2 estudiamos situaciones en las que la variable dependiente es binaria ($y \in \{0, 1\}$). Ahora damos un paso más: ¿qué ocurre cuando la variable dependiente es **continua**, pero **no podemos observar todos sus valores**?

Esto sucede con frecuencia en economía:

Cuadro 4.1: Ejemplos de datos censurados en economía

Ejemplo	Variable	Censura
Gasto en automóviles	Gasto (€)	Muchas familias gastan 0 (no compran coche)
Horas trabajadas	Horas/semana	Muchas personas reportan 0 horas
Gasto en vivienda	Gasto (€)	Hogares sin vivienda propia: gasto = 0
Donaciones benéficas	Importe (€)	Muchos contribuyentes donan 0
Aptitud académica	Puntuación	Escala limitada: mínimo 200, máximo 800

En todos estos casos, hay una **acumulación de observaciones** en un valor límite (generalmente cero). El problema es que, detrás de esas observaciones con valor cero, existe una **variable latente** y^* que puede tomar valores negativos — pero que no observamos, porque el fenómeno real está limitado.

> **Ejemplo intuitivo:** Una persona puede tener un «deseo» negativo de trabajar (preferiría no hacerlo), pero las horas trabajadas que observamos nunca son negativas. Lo que vemos es $y = 0$, aunque el valor latente $y^* < 0$.

Si aplicamos MCO directamente a estos datos, obtendremos estimaciones **sesgadas e inconsistentes**. El **modelo Tobit** (James Tobin, 1958) resuelve este problema especificando correctamente la verosimilitud para datos censurados.

En estos apuntes se abordará en primer lugar la definición precisa de la censura y sus distintas variantes (por la izquierda, por la derecha y bilateral). A continuación se planteará el modelo Tobit con su función de verosimilitud y se demostrará formalmente por qué MCO produce estimaciones sesgadas e inconsistentes cuando se aplica a datos censurados. El núcleo del capítulo lo constituye la interpretación de los coeficientes mediante las tres medias condicionales y sus correspondientes efectos marginales. El tema incluye también las pruebas de especificación necesarias para validar los supuestos del modelo, y concluye con un ejemplo práctico completo en R que ilustra todo el proceso de estimación, interpretación y diagnóstico.

4.2 Datos censurados: conceptos básicos

4.2.1 ¿Qué es la censura?

La **censura** se produce cuando el valor de la variable dependiente no se observa para parte de la muestra, aunque sí disponemos de información sobre las variables explicativas.

> **Atención:** La censura no es lo mismo que los datos faltantes. En los datos censurados, **sabemos que la observación existe** y conocemos las X, pero el valor exacto de y está limitado por un umbral. En los datos faltantes, directamente no tenemos la observación.

Formalmente, disponemos de una muestra de n individuos. Para cada individuo i:

- Observamos las variables explicativas $\mathbf{x}_i$ siempre.
- La variable dependiente y_i solo se observa en su valor real si cae dentro de cierto rango; si cae fuera, se registra en el **valor límite**.

4.2.2 Censura por la izquierda

Es el caso más habitual en economía. Se dice que los datos presentan **censura por la izquierda** cuando:

$$y_i = \begin{cases} y_i^* & \text{si } y_i^* > c \\ c & \text{si } y_i^* \leq c \end{cases}$$

donde c es el **punto de censura** (a menudo $c = 0$) y y_i^* es la **variable latente** (el valor verdadero no observado).

> **Ejemplo:** En un estudio sobre horas trabajadas, y^* es el «deseo» de trabajar. Si $y^* > 0$, observamos las horas reales. Si $y^* \leq 0$, la persona no trabaja y registramos $y = 0$.

4.2.3 Censura por la derecha

Se produce cuando la variable dependiente está **acotada superiormente**:

$$y_i = \begin{cases} y_i^* & \text{si } y_i^* < c \\ c & \text{si } y_i^* \geq c \end{cases}$$

> **Ejemplo:** En una prueba de aptitud académica con puntuación máxima de 800, los estudiantes que realmente tendrían una aptitud superior a 800 reciben todos una puntuación de 800. No sabemos cuánto más habrían puntuado si la escala no tuviera tope.

4.2.4 Censura en ambos lados

En algunos casos, la censura se produce en **ambos extremos** simultáneamente:

$$y_i = \begin{cases} a & \text{si } y_i^* \leq a \\ y_i^* & \text{si } a < y_i^* < b \\ b & \text{si } y_i^* \geq b \end{cases}$$

> **Ejemplo:** La prueba de aptitud académica con puntuación mínima 200 y máxima 800. Hay censura por la izquierda en 200 y por la derecha en 800.

4.2.5 La variable latente y^*

El concepto clave para entender la censura es la **variable latente** y^*. Esta es la variable que realmente queremos medir, pero que no siempre podemos observar.

Pensemos en ello con una analogía:

> **Analogía del termómetro:** Imagina un termómetro que solo mide entre -10°C y 50°C. Si la temperatura real es -25°C, el termómetro marca -10°C. Si es 60°C, marca 50°C. La temperatura real (y^*) existe, pero el instrumento de medición (y) la censura.

En economía, la «censura» no la produce un instrumento defectuoso, sino la propia naturaleza del fenómeno: no se pueden trabajar horas negativas, no se puede gastar menos de cero euros, etc.

4.2.6 La densidad de datos censurados: una mezcla discreta-continua

Aquí viene un punto técnicamente importante. La distribución de y (la variable observada) es una **mezcla** de:

- Una parte **continua**: para las observaciones no censuradas ($y > c$), la densidad es la habitual $f(y)$.
- Una parte **discreta**: para las observaciones censuradas ($y = c$), hay una «masa de probabilidad» concentrada en el punto c.

Para el caso de censura por la izquierda en $c = 0$ con distribución normal:

$$\text{Densidad de } y_i = \begin{cases} \frac{1}{\sigma}\phi\left(\frac{y_i - \mathbf{x}_i\beta}{\sigma}\right) & \text{si } y_i > 0 \quad \text{(parte continua)} \\ \Phi\left(\frac{-\mathbf{x}_i\beta}{\sigma}\right) & \text{si } y_i = 0 \quad \text{(masa en cero)} \end{cases}$$

donde:

- $\phi(\cdot)$ es la función de densidad de la normal estándar.

- $\Phi(\cdot)$ es la función de distribución acumulada (CDF) de la normal estándar.
- σ es la desviación típica del término de error.

  ¿Por qué $\Phi(-\mathbf{x}_i\beta/\sigma)$? Porque la probabilidad de que $y_i = 0$ es la probabilidad de que la variable latente sea negativa: $P(y_i^* \leq 0) = P(\mathbf{x}_i\beta + \varepsilon_i \leq 0) = P(\varepsilon_i \leq -\mathbf{x}_i\beta) = \Phi(-\mathbf{x}_i\beta/\sigma)$.

Este carácter **híbrido** (mezcla de discreto y continuo) es la razón por la que no podemos usar MCO directamente y necesitamos un modelo específico: el Tobit.

4.3 El modelo Tobit

4.3.1 Origen

El modelo Tobit fue propuesto por **James Tobin** en 1958, en un artículo titulado «*Estimation of relationships for limited dependent variables*» publicado en *Econometrica*. Tobin lo aplicó al estudio del **gasto en bienes de consumo duraderos** (automóviles): muchos hogares no compraban coche (gasto = 0), pero los que sí lo hacían mostraban una amplia variación en el gasto.

El nombre «Tobit» es un juego de palabras que combina «Tobin» con «Probit», ya que ambos modelos comparten el uso de la distribución normal.

4.3.2 Especificación del modelo

El modelo Tobit estándar (con censura por la izquierda en cero) se define en dos ecuaciones:

Ecuación latente:

$$y_i^* = \mathbf{x}_i\beta + \varepsilon_i, \qquad \varepsilon_i \sim N(0, \sigma^2)$$

Regla de observación:

$$y_i = \begin{cases} y_i^* & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

Supuestos clave:

1. El error ε_i se distribuye **normalmente** con media cero y varianza σ^2.
2. El error es **homocedástico** (la varianza no depende de $\mathbf{x}_i$).
3. El error es **independiente** de las variables explicativas.

> **Importante:** Si estos supuestos no se cumplen (especialmente la normalidad y la homocedasticidad), las estimaciones del modelo Tobit serán **inconsistentes**. Esto es una diferencia importante con MCO, donde la heterocedasticidad causa ineficiencia pero no inconsistencia.

4.3.3 Ejemplos económicos clásicos

4.3.3.1 Horas trabajadas (Tobin, 1958; Mroz, 1987)

El ejemplo histórico más célebre del modelo Tobit es el análisis de las horas trabajadas. La variable latente y_i^* representa el «deseo de trabajar» medido en horas semanales, que puede ser positivo, cero o incluso negativo (una persona que preferiría no trabajar en absoluto). Sin embargo, la variable observada y_i son las horas efectivamente trabajadas, que nunca pueden ser negativas. El modelo se especifica como:

$$y_i^* = \beta_0 + \beta_1 \text{ salario_potencial}_i + \beta_2 \text{ educación}_i + \beta_3 \text{ edad}_i + \beta_4 \text{ hijos}_i + \beta_5 \text{ renta_no_laboral}_i + \varepsilon_i$$

con regla de observación $y_i = \max(0, y_i^*)$. La censura es por la izquierda en cero: las personas que no trabajan ($y_i = 0$) coexisten con quienes sí lo hacen ($y_i > 0$).

4.3.3.2 Gasto en automóviles

Otro ejemplo clásico es el gasto en automóviles. La variable latente y_i^* puede interpretarse como la utilidad neta que un hogar obtiene de comprar un coche, medida en euros. Cuando esa utilidad es positiva, el hogar compra y observamos el gasto real; cuando es negativa o cero, el hogar no compra y el gasto observado es cero. El modelo adopta la forma:

$$y_i^* = \beta_0 + \beta_1 \text{ renta}_i + \beta_2 \text{ tamaño_familiar}_i + \beta_3 \text{ distancia_trabajo}_i + \varepsilon_i$$

con censura por la izquierda en cero. La proporción de hogares con gasto nulo puede ser elevada (del 30% al 60% según el país y el periodo), lo que hace especialmente relevante el uso del Tobit frente al MCO.

4.3.3.3 Aptitud académica (ejemplo que desarrollaremos en R)

El tercer ejemplo, que utilizaremos en la sección práctica, es la aptitud académica de estudiantes universitarios. La variable latente y_i^* es la aptitud real del estudiante, que en principio no tiene límites. Sin embargo, la prueba de medición asigna puntuaciones en una escala de 200 a 800, generando censura bilateral: los estudiantes con aptitud latente superior a 800 reciben todos una puntuación de 800 (censura por la derecha), y los que tendrían menos de 200 recibirían 200 (censura por la izquierda).

4.3.4 La función de log-verosimilitud

Dividimos la muestra en dos grupos:

- **Observaciones no censuradas** ($y_i > 0$): contribuyen con la densidad normal habitual.
- **Observaciones censuradas** ($y_i = 0$): contribuyen con la probabilidad de que $y_i^* \leq 0$.

4.3.4.1 Derivación componente a componente

Para formalizar el modelo, partimos de que la variable latente sigue: $y_i^* = \mathbf{x}_i\beta + \epsilon_i$ con $\epsilon_i \sim N(0, \sigma^2)$.

Para las observaciones no censuradas ($y_i > 0$, es decir, $y_i^* > 0$): - Observamos el valor real de y_i. - La contribución a la verosimilitud es la **densidad normal** evaluada en y_i:

$$f(y_i|\mathbf{x}_i) = \frac{1}{\sigma}\phi\left(\frac{y_i - \mathbf{x}_i\beta}{\sigma}\right)$$

Para las observaciones censuradas ($y_i = 0$, es decir, $y_i^* \leq 0$): - Solo sabemos que el valor latente es negativo o cero. - La contribución a la verosimilitud es la **función de distribución acumulada** (CDF):

$$P(y_i = 0|\mathbf{x}_i) = P(y_i^* \leq 0|\mathbf{x}_i) = \Phi\left(\frac{-\mathbf{x}_i\beta}{\sigma}\right)$$

4.3.4.2 La función de log-verosimilitud completa

Combinando ambos componentes:

$$\ln L(\beta, \sigma) = \sum_{i:y_i=0} \ln\left[\Phi\left(\frac{-\mathbf{x}_i\beta}{\sigma}\right)\right] + \sum_{i:y_i>0} \left\{\ln\left[\frac{1}{\sigma}\phi\left(\frac{y_i - \mathbf{x}_i\beta}{\sigma}\right)\right]\right\}$$

O, simplificada:

$$\ln L = \sum_{y_i=0} \ln\left[\Phi\left(\frac{-\mathbf{x}_i\beta}{\sigma}\right)\right] + \sum_{y_i>0} \left[-\frac{1}{2}\ln(2\pi\sigma^2) - \frac{(y_i - \mathbf{x}_i\beta)^2}{2\sigma^2}\right]$$

Interpretación intuitiva:

- **Primer sumatorio** (datos censurados): modelamos la **probabilidad discreta** de estar en el punto 0. Es exactamente como una **ecuación Probit**.
- **Segundo sumatorio** (datos no censurados): modelamos la **densidad continua** de los valores observados. Es exactamente como una **regresión MCO normal**.

El modelo Tobit es un **híbrido elegante** que combina la lógica de un modelo de respuesta binaria (Probit) para la decisión de estar censurado o no, con una regresión clásica para los valores observados.

4.3.4.3 Ejemplo numérico: cálculo paso a paso de la log-verosimilitud

Para comprender cómo funciona la log-verosimilitud del Tobit en la práctica, vamos a calcularla manualmente con una muestra mínima de tres observaciones. El objetivo es ver exactamente qué aporta cada individuo a la función que el algoritmo de optimización intenta maximizar.

Supongamos que el modelo es $y_i^* = \beta_0 + \beta_1 x_i + \varepsilon_i$ con censura en cero, y que los parámetros candidatos son $\beta_0 = 0.5$, $\beta_1 = 1.0$ y $\sigma = 2$. Nuestra muestra tiene tres individuos:

Observación 1: $x_1 = 2$, $y_1 = 0$ (la persona no trabaja — observación **censurada**).

El valor predicho de la variable latente es $\hat{y}_1^* = 0.5 + 1.0 \times 2 = 2.5$. El modelo predice que esta persona *debería* querer trabajar 2.5 horas, pero observamos 0. ¿Cómo de probable es esto? Necesitamos calcular la probabilidad de que $y^* \leq 0$, es decir, $P(\varepsilon_1 \leq -2.5)$. Estandarizando: $z_1 = -2.5/2 = -1.25$. La probabilidad es $\Phi(-1.25) = 0.1056$. Es una probabilidad baja (el modelo no predice bien esta censura con estos parámetros). La contribución a la log-verosimilitud es $\ln(0.1056) = -2.25$.

Observación 2: $x_2 = 3$, $y_2 = 5.3$ (la persona trabaja 5.3 horas — observación **no censurada**).

El valor predicho es $\hat{y}_2^* = 0.5 + 1.0 \times 3 = 3.5$. El valor observado es 5.3, así que el residuo es $5.3 - 3.5 = 1.8$. Para esta observación usamos la densidad normal, no la CDF. El residuo estandarizado es $1.8/2 = 0.9$. La contribución a la log-verosimilitud se calcula como $\ln\left[\frac{1}{\sigma}\phi\left(\frac{y_2 - \hat{y}_2^*}{\sigma}\right)\right]$, que desarrollando paso a paso da: $-\frac{1}{2}\ln(2\pi \times 4) - \frac{1.8^2}{2\times 4} = -1.84 - 0.405 = -2.245$.

Observación 3: $x_3 = 1$, $y_3 = 0$ (censurada).

El valor predicho es $\hat{y}_3^* = 0.5 + 1.0 \times 1 = 1.5$, con $z_3 = -1.5/2 = -0.75$ y $\Phi(-0.75) = 0.2266$. La probabilidad de censura es mayor que para la observación 1, porque el predictor es menor. Contribución: $\ln(0.2266) = -1.489$.

Log-verosimilitud total: sumamos las tres contribuciones: $-2.25 + (-2.245) + (-1.489) = -5.984$.

Este valor de -5.984 corresponde a los parámetros candidatos $(\beta_0 = 0.5, \beta_1 = 1.0, \sigma = 2)$. El algoritmo de estimación prueba sistemáticamente otras combinaciones de parámetros hasta encontrar aquella que produce la log-verosimilitud **más alta posible** (menos negativa). Esa combinación óptima es la estimación de máxima verosimilitud.

4.3.5 La reparametrización de Olsen (1978)

La estimación del modelo Tobit por máxima verosimilitud requiere que un algoritmo numérico encuentre los valores de β y σ que maximizan la función $\ln L(\beta, \sigma)$. A diferencia de MCO, donde existe una fórmula cerrada $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, en el Tobit no hay solución analítica: la presencia simultánea de $\Phi(\cdot)$ y $\phi(\cdot)$ en la log-verosimilitud impide despejar los parámetros. Por tanto, se recurre a métodos iterativos como Newton-Raphson o BFGS, que parten de unos valores iniciales y los van refinando hasta alcanzar el máximo.

En la práctica, la maximización directa con respecto a (β, σ) puede presentar

dificultades numéricas. Los parámetros β y σ operan en escalas muy diferentes (los coeficientes pueden valer 0.5 mientras que σ vale 3), lo que dificulta la convergencia del algoritmo. Además, cuando la proporción de observaciones censuradas es alta o la varianza es pequeña, la superficie de la log-verosimilitud puede ser muy plana en algunas direcciones, provocando que el algoritmo avance lentamente o se detenga antes de alcanzar el óptimo.

Olsen (1978) propuso una transformación que resuelve estas dificultades de forma elegante. En lugar de estimar directamente (β, σ), se definen dos nuevos parámetros:

$$\gamma = \frac{\beta}{\sigma}, \qquad \lambda = \frac{1}{\sigma}$$

La ventaja de esta transformación es que los nuevos parámetros (γ, λ) operan en escalas más similares entre sí, lo que facilita el trabajo del algoritmo de optimización. La superficie de la log-verosimilitud expresada en términos de (γ, λ) tiene una curvatura más regular, lo que permite que el algoritmo converja más rápidamente y con mayor estabilidad numérica.

Con esta reparametrización, la log-verosimilitud se reescribe como:

$$\ln L(\gamma, \lambda) = \sum_{y_i=0} \ln[\Phi(-\mathbf{x}_i\gamma)] + \sum_{y_i>0} \left\{ \ln(\lambda) - \frac{\lambda^2}{2}(y_i - \mathbf{x}_i\gamma/\lambda)^2 \right\}$$

Una vez que el algoritmo encuentra los valores óptimos $(\hat{\gamma}, \hat{\lambda})$, la recuperación de los parámetros originales es inmediata:

$$\hat{\sigma} = \frac{1}{\hat{\lambda}}, \qquad \hat{\beta} = \frac{\hat{\gamma}}{\hat{\lambda}}$$

En la práctica, el usuario no necesita preocuparse de esta transformación: los paquetes de software (como `censReg` o `AER` en R) la implementan internamente de forma transparente. El usuario especifica el modelo y obtiene directamente las estimaciones de $\hat{\beta}$ y $\hat{\sigma}$, ya reconvertidas a la escala original.

Desde una perspectiva histórica, la reparametrización de Olsen fue un avance importante en los años setenta, cuando la capacidad de cálculo era muy limitada. James Tobin había propuesto el modelo en 1958, pero su estimación práctica no fue viable hasta que Olsen resolvió los problemas numéricos. Hoy, aunque los ordenadores son incomparablemente más potentes, la reparametrización sigue siendo el método estándar porque mejora de forma significativa la velocidad y la fiabilidad de la convergencia.

4.4 ¿Por qué MCO no funciona con datos censurados?

Esta sección demuestra formalmente y con datos simulados que la estimación por MCO de un modelo con datos censurados produce resultados sesgados e inconsistentes. Comprender por qué falla MCO es esencial para justificar la necesidad del modelo Tobit.

4.4.1 El sesgo de MCO: explicación detallada

Consideremos el siguiente modelo generador de datos con censura por la izquierda en cero:

$$y_i^* = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad \varepsilon_i \sim N(0, \sigma^2)$$
$$y_i = \max(0,\ y_i^*)$$

Supongamos que los valores verdaderos son $\beta_0 = -2$, $\beta_1 = 1.5$ y $\sigma = 2$. Si aplicásemos MCO directamente a la variable observada y_i (sin tener en cuenta la censura), la estimación de la pendiente $\hat{\beta}_1^{MCO}$ resultaría sistemáticamente inferior al valor verdadero de 1.5. Este fenómeno se conoce como **sesgo de atenuación** y tiene una explicación intuitiva clara.

Cuando la variable latente y_i^* es negativa, la variable observada se registra como $y_i = 0$. MCO trata esos ceros como si fueran valores reales del fenómeno, cuando en realidad son un artefacto de la censura. Al incluir estas observaciones «aplastadas» en el cálculo, la recta de regresión se «tira hacia abajo», reduciendo la pendiente estimada. Cuanto mayor sea la proporción de observaciones censuradas, mayor será la atenuación.

El segundo problema, aún más grave, es que MCO es **inconsistente**: el sesgo no desaparece al aumentar el tamaño muestral. Por muchas observaciones que añadamos, la estimación MCO converge a un valor distinto del verdadero. Esto contrasta con otros problemas de MCO (como la heterocedasticidad en modelos lineales), donde el estimador sigue siendo consistente aunque sea ineficiente.

4.4.2 Demostración visual en R

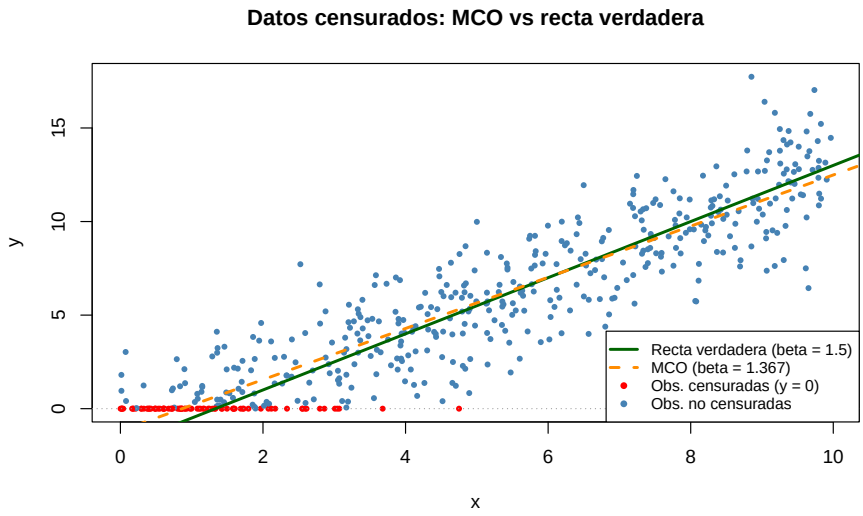

Figura 4.1: MCO subestima la pendiente con datos censurados.

Observa: Los puntos rojos son las observaciones censuradas. La recta MCO (naranja discontinua) tiene una pendiente **menor** que la verdadera (verde). Esto es el sesgo de atenuación.

4.4.3 Comparación numérica: MCO vs Tobit

Cuadro 4.2: Comparación de estimaciones: MCO vs Tobit

	Parámetro	Verdadero	MCO	Tobit
(Intercept)	Intercepto	-2.0	-1.182	-2.111
x	Pendiente (β)	1.5	1.367	1.498
	σ	2.0	1.832	2.005

Resultado esperado: El Tobit recupera valores cercanos a los verdaderos ($\beta \approx 1.5$, $\sigma \approx 2$), mientras que MCO subestima la pendiente.

4.5 Interpretación de los coeficientes

Esta es, probablemente, la sección más importante del tema para la práctica aplicada. En regresión lineal, interpretar un coeficiente es directo: «un aumento de una unidad en x_j se asocia con un cambio de β_j unidades en y». En el modelo Tobit, **la interpretación no es tan sencilla**, porque la relación entre **x** e y no es lineal debido a la censura.

> **Regla de oro:** En el Tobit, el coeficiente β_j **NO** es el efecto marginal sobre la variable observada. Hay que ajustarlo.

4.5.1 ¿Por qué los coeficientes no son directamente efectos marginales?

En regresión lineal: $E(y \mid \mathbf{x}) = \mathbf{x}\beta$, luego $\frac{\partial E(y)}{\partial x_j} = \beta_j$. Simple.

En el modelo Tobit, la censura introduce una **no linealidad**. La variable observada y no es igual a y^*: hay una «deformación» en el punto de censura. Por tanto, el efecto de x_j sobre $E(y)$ depende de:

1. **Dónde estamos** en la distribución (el valor de $\mathbf{x}\beta/\sigma$).
2. **Qué pregunta** nos hacemos (¿efecto sobre la latente? ¿sobre los no censurados? ¿sobre todos?).

Esto da lugar a **tres medias condicionales** diferentes, cada una con su propio efecto marginal.

4.5.2 Las tres medias condicionales: derivación detallada

4.5.2.1 Media condicional 1: la variable latente $E(y^* \mid \mathbf{x})$

Esta es la más sencilla. Como $y_i^* = \mathbf{x}_i\beta + \varepsilon_i$ con $E(\varepsilon_i) = 0$:

$$E(y^* \mid \mathbf{x}) = \mathbf{x}\beta$$

Efecto marginal:

$$\frac{\partial E(y^* \mid \mathbf{x})}{\partial x_j} = \beta_j$$

> **Interpretación:** Es el efecto sobre la variable *latente* (el «deseo» de trabajar, la aptitud «real»). Es exactamente como en regresión lineal, pero se refiere a una variable que **no siempre observamos**.
>
> **¿Cuándo usarla?** Cuando la pregunta de investigación se refiere al proceso latente subyacente. Por ejemplo: «¿cómo afecta la educación al *deseo* de trabajar?».

4.5.2.2 Media condicional 2: $E(y \mid \mathbf{x}, y > 0)$ — el valor esperado para los no censurados

Esta media responde a: «dado que la persona **sí trabaja** (o sí compra coche, etc.), ¿cuánto trabaja (o gasta)?».

Derivación desde los fundamentos:

Partimos de la esperanza condicional de una normal truncada. Si $y^* \sim N(\mu, \sigma^2)$ y condicionamos a $y^* > 0$:

$$E(y^* \mid y^* > 0) = \mu + \sigma \cdot \frac{\phi(\mu/\sigma)}{\Phi(\mu/\sigma)}$$

Este es un resultado estándar de la distribución normal truncada (véase Greene, 2012, Apéndice B). El término $\frac{\phi(\mu/\sigma)}{\Phi(\mu/\sigma)}$ se llama **Inverse Mills Ratio** (IMR).

Sustituyendo $\mu = \mathbf{x}\beta$:

$$\boxed{E(y \mid \mathbf{x}, y > 0) = \mathbf{x}\beta + \sigma \cdot \frac{\phi(\mathbf{x}\beta/\sigma)}{\Phi(\mathbf{x}\beta/\sigma)}}$$

¿Qué es el Inverse Mills Ratio (IMR)?

Definimos $\lambda(z) = \frac{\phi(z)}{\Phi(z)}$, donde $z = \mathbf{x}\beta/\sigma$. El IMR tiene propiedades importantes:

- Siempre es **positivo**: $\lambda(z) > 0$ para todo z.
- Es **decreciente** en z: cuanto mayor es z, menor es $\lambda(z)$.
- **Intuición:** Cuando z es grande (la persona tiene alta probabilidad de no estar censurada), el IMR es pequeño y $E(y \mid y > 0) \approx \mathbf{x}\beta$. Cuando z es bajo (alta probabilidad de censura), el IMR «empuja» la media hacia arriba, porque estamos condicionando a los que sí superan el umbral.

Efecto marginal:

$$\frac{\partial E(y \mid \mathbf{x}, y > 0)}{\partial x_j} = \beta_j \left[1 - \lambda(z)\Big(z + \lambda(z)\Big)\right]$$

El factor entre corchetes siempre está **entre 0 y 1**, por lo que el efecto sobre los no censurados es **menor** que β_j.

> **¿Cuándo usarla?** Cuando nos interesa el **margen intensivo**: «dado que la persona ya trabaja, ¿cuántas horas más trabajaría si tuviera más educación?».

4.5.2.3 Media condicional 3: $E(y \mid \mathbf{x})$ — el valor esperado para toda la muestra

Esta es la media más utilizada en la práctica, porque combina dos efectos:

1. La **probabilidad** de no estar censurado.
2. El **valor esperado** condicional a no estarlo.

Derivación:

Usando la ley de esperanzas iteradas:

$$E(y \mid \mathbf{x}) = P(y > 0 \mid \mathbf{x}) \cdot E(y \mid \mathbf{x}, y > 0) + P(y = 0 \mid \mathbf{x}) \cdot 0$$

Sabemos que $P(y > 0 \mid \mathbf{x}) = \Phi(\mathbf{x}\beta/\sigma)$ y el segundo término es cero, luego:

$$\boxed{E(y \mid \mathbf{x}) = \Phi\left(\frac{\mathbf{x}\beta}{\sigma}\right) \cdot \left[\mathbf{x}\beta + \sigma \cdot \frac{\phi(\mathbf{x}\beta/\sigma)}{\Phi(\mathbf{x}\beta/\sigma)}\right]}$$

Efecto marginal (fórmula aproximada de McDonald y Moffitt, 1980):

Se puede demostrar que:

$$\frac{\partial E(y \mid \mathbf{x})}{\partial x_j} \approx \beta_j \cdot \Phi\left(\frac{\mathbf{x}\beta}{\sigma}\right)$$

El factor $\Phi(\mathbf{x}\beta/\sigma)$ es simplemente la **probabilidad de no estar censurado**. Esto tiene una interpretación muy elegante:

> **Interpretación:** El efecto marginal total es el coeficiente β_j multiplicado por la probabilidad de que la observación esté en la zona no censurada. Si casi todos están censurados ($\Phi \approx 0$), el efecto es casi nulo. Si casi nadie está censurado ($\Phi \approx 1$), el efecto es prácticamente β_j.
>
> **¿Cuándo usarla?** Cuando nos interesa el **efecto total** para toda la población, incluyendo tanto el cambio en la probabilidad de pasar de censurado a no censurado como el cambio en la cantidad para los que ya están no censurados.

4.5.3 Tabla resumen: las tres medias condicionales

Cuadro 4.3: Resumen de las tres medias condicionales del modelo Tobit

Media	Nombre	Efecto marginal	Pregunta que responde	Ejemplo
$E(y^* \mid \mathbf{x})$	Variable latente	β_j	¿Cómo cambia el deseo latente?	Efecto de educación sobre deseo de trabajar
$E(y \mid \mathbf{x},\ y > 0)$	No censuradas (truncada)	$\beta_j \times [1 - \lambda(z + \lambda)]$	Dado que ya trabaja, ¿cuánto más?	Si ya trabaja, ¿cuántas horas más por año de educación?
$E(y \mid \mathbf{x})$	Toda la muestra	$\beta_j \times \Phi(\mathbf{x}\beta/\sigma)$	¿Cuánto cambia para TODOS?	Efecto total sobre horas trabajadas (incluye los que no trabajan)

Relación entre las tres: Siempre se cumple que el efecto marginal sobre $E(y^*)$ (latente) es **mayor** que sobre $E(y \mid y > 0)$ (no censuradas), que a su vez es **mayor** que sobre $E(y)$ (toda la muestra).

4.5.4 Relación entre $\hat{\beta}_{MCO}$ y $\hat{\beta}_{Tobit}$

Un resultado empírico bien conocido es que, casi sin excepción:

$$|\hat{\beta}_{MCO}| < |\hat{\beta}_{Tobit}|$$

¿Por qué? MCO trata las observaciones censuradas ($y = 0$) como si fueran datos reales. Estas observaciones «tiran hacia abajo» de la recta de regresión, reduciendo los coeficientes estimados. El Tobit, al modelizar correctamente la censura, «sabe» que detrás de esos ceros hay valores latentes negativos y estima pendientes más pronunciadas.

¿Cuándo es grande la diferencia?

- Si la proporción de observaciones censuradas es **alta** (>30-40%), la diferencia MCO-Tobit puede ser **sustancial**.
- Si la proporción es **baja** (<5%), ambas estimaciones serán similares.
- Los **signos** y la **significación** suelen coincidir en ambos métodos.

4.5.5 Reglas de interpretación de coeficientes

4.5.5.1 Regla 1: Variables continuas

Para una variable continua x_j (por ejemplo, años de educación):

- **Coeficiente $\hat{\beta}_j$:** «Un aumento de una unidad en x_j se asocia con un cambio de $\hat{\beta}_j$ unidades en la variable *latente* y^*».
- **Efecto marginal sobre $E(y)$:** «Un aumento de una unidad en x_j se asocia con un cambio de $\hat{\beta}_j \times \Phi(\mathbf{x}\hat{\beta}/\hat{\sigma})$ unidades en la variable observada y, evaluado en el punto $\mathbf{x}$».

4.5.5.2 Regla 2: Variables categóricas (dummies)

Para una variable dummy d_j (por ejemplo, programa vocacional vs. académico):

- **Coeficiente $\hat{\beta}_j$:** «Las observaciones con $d_j = 1$ tienen, en promedio, $\hat{\beta}_j$ unidades más (o menos) de variable latente que las de la categoría base».
- **Efecto marginal:** Se calcula como la **diferencia** en $E(y \mid \mathbf{x})$ cambiando d_j de 0 a 1 (no es simplemente $\hat{\beta}_j \times \Phi(z)$, aunque esta es una buena aproximación).

4.5.5.3 Regla 3: El signo siempre coincide

En el modelo Tobit, el signo del coeficiente $\hat{\beta}_j$ coincide con el signo del efecto marginal sobre cualquiera de las tres medias condicionales. Si $\hat{\beta}_j > 0$, el efecto es positivo en las tres.

4.5.5.4 Regla 4: La magnitud depende de $\Phi(z)$

El «factor de escala» $\Phi(\mathbf{x}\beta/\sigma)$ determina cuánto se atenúa el coeficiente:

- $\Phi(z) \approx 1$ (poca censura en ese punto): el efecto marginal $\approx \beta_j$.
- $\Phi(z) \approx 0.5$ (censura moderada): el efecto marginal $\approx 0.5 \times \beta_j$.
- $\Phi(z) \approx 0$ (mucha censura): el efecto marginal ≈ 0.

4.5.6 Ejemplo numérico detallado: horas trabajadas

Supongamos un modelo Tobit estimado para horas trabajadas con los siguientes parámetros:

- $\hat{\beta}_0 = -2$, $\hat{\beta}_1 = 0.5$ (educación), $\hat{\beta}_2 = -1.5$ (dummy: tiene hijos pequeños), $\hat{\sigma} = 3$

4.5.6.1 Persona A: mujer con 12 años de educación, sin hijos

Paso 1: Índice lineal:

$$\mathbf{x}_A\widehat{\beta} = -2 + 0.5 \times 12 + (-1.5) \times 0 = 4$$

Paso 2: Estandarización:

$$z_A = \frac{4}{3} = 1.333$$

Paso 3: Probabilidad de trabajar:

$$P(y > 0) = \Phi(1.333) = 0.909$$

Paso 4: Efectos marginales de educación:

4.5.6.2 Persona B: mujer con 8 años de educación, con hijos

Paso 1: Índice lineal:

$$\mathbf{x}_B\widehat{\beta} = -2 + 0.5 \times 8 + (-1.5) \times 1 = 0.5$$

Paso 2 y 3:

$$z_B = \frac{0.5}{3} = 0.167, \qquad \Phi(z_B) = 0.566$$

Paso 4: Efectos marginales de educación:

4.5.6.3 Comparación de las dos personas

Cuadro 4.4: Efecto marginal de la educación para dos perfiles distintos

Concepto	Persona A (educ=12, sin hijos)	Persona B (educ=8, con hijos)
Índice $\mathbf{x}\beta$	4,000	0,500
$z = \mathbf{x}\beta/\sigma$	1,333	0,167
$\Phi(z) = P(\text{trabaja})$	0,909	0,566
EM latente (β_1)	0,500	0,500
EM total ($\beta_1 \times \Phi$)	0,454	0,283

Lección clave: El efecto marginal de la educación es **el mismo** sobre la variable latente (0.5 para ambas), pero **diferente** sobre la variable observada: 0.454 para la Persona A vs. 0.283 para la Persona B. ¿Por qué? Porque la Persona B tiene mayor probabilidad de estar censurada (Φ = 0.566 vs. 0.909), así que el efecto «se diluye» más.

4.5.7 Efecto de una variable dummy: tener hijos

Para la Persona A (sin hijos → con hijos):

$$\Delta E(y) \approx \hat{\beta}_2 \times \Phi(z_A) = -1.5 \times 0.909 = -1.364$$

Interpretación: Tener hijos pequeños se asocia con una reducción de 1.36 horas trabajadas para la Persona A.

Para alguien con el perfil de la Persona B pero sin hijos (z = 1.167):

$$\Delta E(y) \approx -1.5 \times \Phi(1.167) = -1.5 \times 0.878 = -1.318$$

4.5.8 Tabla resumen de interpretación (modelo de horas trabajadas)

Cuadro 4.5: Tabla resumen de interpretación de coeficientes y efectos marginales

Variable	Coeficiente	EM latente	EM observado	Perfil	Interpretación
Educación (continua)	$\beta_1 = 0{,}50$	0,500	0,454	Persona A ($\Phi = 0{,}91$)	+1 año educ: +0,45 horas
Educación (continua)	$\beta_1 = 0{,}50$	0,500	0,283	Persona B ($\Phi = 0{,}57$)	+1 año educ: +0,28 horas
Hijos (dummy)	$\beta_2 = -1{,}50$	$-1{,}500$	$-1{,}364$	Persona A ($\Phi = 0{,}91$)	Tener hijos: $-1{,}36$ horas
Hijos (dummy)	$\beta_2 = -1{,}50$	$-1{,}500$	$-0{,}849$	Persona B ($\Phi = 0{,}57$)	Tener hijos: $-0{,}85$ horas

Conclusión: El mismo coeficiente produce efectos marginales **diferentes** según el perfil del individuo. Por eso, en la práctica, se suelen reportar los efectos marginales **promedio** (Average Marginal Effects, AME), calculados promediando los efectos individuales para toda la muestra.

4.5.9 Proporción de censura

Antes de interpretar cualquier resultado, el primer dato que debe calcularse es la **proporción de censura** de la muestra. Se define como la fracción de observaciones en las que la variable dependiente se encuentra en el límite de censura:

$$\text{Proporción de censura} = \frac{\text{Número de observaciones con } y_i = c}{n}$$

Por ejemplo, si en una muestra de 500 individuos hay 150 con $y_i = 0$ (horas trabajadas = 0), la proporción de censura es $150/500 = 0{,}30$ (un 30%). En R, este cálculo es inmediato: `mean(datos$y == 0)` devuelve directamente la proporción.

Este dato es fundamental porque condiciona la magnitud de la diferencia entre el coeficiente β_j y el efecto marginal sobre la variable observada. Cuanto mayor sea la proporción de censura, mayor será la discrepancia entre ambos, y más imprescindible resulta el cálculo explícito de los efectos marginales.

4.5.10 Guía de interpretación

A modo de síntesis, conviene recordar que el signo del coeficiente Tobit indica directamente la dirección del efecto, pero su magnitud se refiere a la variable latente y^*, no a la variable observada y. Para traducir el coeficiente en un efecto sobre la variable observada es necesario multiplicar por el factor $\Phi(\mathbf{x}\beta/\sigma)$, que refleja la probabilidad de no estar censurado.

La importancia práctica de este ajuste depende del grado de censura de la muestra. Cuando la proporción de observaciones censuradas es reducida (inferior al 5%), el coeficiente y el efecto marginal observado son prácticamente idénticos, porque casi todos los individuos se encuentran en la zona no censurada. En cambio, cuando la proporción de censura es elevada (superior al 30%), el efecto marginal sobre la variable observada resulta sustancialmente inferior al coeficiente, y la diferencia entre ambos no puede ignorarse.

En el caso de variables dummy, la interpretación del efecto marginal no se basa en la derivada parcial, sino en la diferencia de valores esperados $E(y)$ entre las dos categorías, manteniendo constantes las demás variables. En la práctica aplicada es recomendable reportar siempre los **efectos marginales promedio (AME)**.

La tabla siguiente resume las reglas prácticas de interpretación:

Cuadro 4.6: Guía rápida de interpretación de coeficientes Tobit

Pregunta	Respuesta
¿En qué dirección va el efecto?	Mira el signo de $\hat{\beta}_j$: positivo = aumenta, negativo = disminuye
¿Cuál es el efecto sobre la latente?	Directamente $\hat{\beta}_j$ (como en MCO)
¿Cuál es el efecto sobre la observada?	$\hat{\beta}_j \times \Phi(\mathbf{x}\beta/\sigma)$
¿Importa mucho el ajuste?	Sí, si la censura supera el 30%. Con censura $<$5%, $\hat{\beta}_j \approx$ EM
¿Y para variables dummy?	Calcular $\Delta E(y)$ cambiando la dummy de 0 a 1

Pregunta	Respuesta
¿Qué reportar siempre?	Efectos marginales promedio (AME) junto con los coeficientes

4.6 Pruebas de especificación

En el modelo Tobit, es **crucial** verificar los supuestos distribucionales, porque (a diferencia de MCO) la violación de estos supuestos produce **inconsistencia**, no solo ineficiencia.

4.6.1 La idea central del diagnóstico: modelos anidados

Antes de describir los tests concretos, es necesario entender un concepto que aparece constantemente en los diagnósticos: el de **modelos anidados**.

Decimos que un modelo M_R (restringido) está **anidado** dentro de otro M_{SR} (sin restringir) cuando M_R es un caso particular de M_{SR} que se obtiene imponiendo restricciones sobre algunos parámetros. Dicho de otro modo: el modelo restringido es el modelo general con ciertas simplificaciones.

Para ilustrarlo con un ejemplo concreto, consideremos nuestro modelo Tobit de horas trabajadas:

$$y_i^* = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{hijos}_i + \varepsilon_i, \qquad \varepsilon_i \sim N(0, \sigma^2)$$

Este es el **modelo completo** (M_{SR}). Si queremos contrastar si la variable *hijos* aporta información al modelo, el **modelo restringido** (M_R) sería el que impone $\beta_2 = 0$:

$$y_i^* = \beta_0 + \beta_1 \text{educ}_i + \varepsilon_i$$

El modelo restringido es un caso particular del completo (se obtiene fijando $\beta_2 = 0$), por lo que decimos que M_R está anidado en M_{SR}. El test de razón de verosimilitud (LR) compara las log-verosimilitudes de ambos modelos: si M_{SR} ajusta significativamente mejor que M_R, concluimos que la restricción $\beta_2 = 0$ no es sostenible y la variable *hijos* es significativa.

Esta lógica se extiende a cualquier tipo de restricción. En el diagnóstico del Tobit, el caso más importante es el de la **heterocedasticidad**: el Tobit estándar (con σ constante) se anida dentro de un Tobit generalizado que permite que σ varíe con las observaciones.

4.6.2 Diagnóstico práctico: los tres contrastes esenciales

En la práctica aplicada, el diagnóstico de un modelo Tobit se organiza en torno a tres preguntas:

Pregunta 1: ¿Las variables incluidas son conjuntamente significativas?

Esta pregunta se responde con el **test de razón de verosimilitud (LR)**. Se estiman dos modelos: el modelo completo (con todas las variables) y el modelo restringido (solo con la constante). Si la diferencia de log-verosimilitudes es grande, las variables en conjunto aportan información significativa. El estadístico es $LR = 2(\ln L_{SR} - \ln L_R)$ y sigue

una χ^2 con grados de libertad iguales al número de variables contrastadas.

En R, el cálculo es directo:

```
LR <- 2 * (logLik(modelo_completo) - logLik(modelo_reducido))

pchisq(LR, df = diferencia_parametros, lower.tail = FALSE)
```

Pregunta 2: ¿Son los errores homocedásticos?

Esta pregunta es crucial porque, como se ha explicado, la heterocedasticidad provoca inconsistencia en el Tobit. El contraste se realiza anidando el Tobit estándar dentro de un **Tobit heterocedástico**, que permite que la varianza del error dependa de las variables explicativas:

$$\sigma_i^2 = \sigma^2 \exp(\mathbf{z}_i \alpha)$$

donde $\mathbf{z}_i$ son variables que se sospecha pueden influir en la dispersión (por ejemplo, la renta: hogares con mayor renta podrían tener mayor variabilidad en sus horas de trabajo). Cuando $\alpha = 0$, la varianza es constante y se recupera el Tobit estándar. Cuando $\alpha \neq 0$, la varianza varía entre individuos.

El contraste se formula como:

$$\begin{aligned} H_0 : \alpha = 0 \qquad & (\text{homocedasticidad} \rightarrow \text{Tobit estándar válido}) \\ H_1 : \alpha \neq 0 \qquad & (\text{heterocedasticidad} \rightarrow \text{Tobit estándar inconsistente}) \end{aligned}$$

Se puede aplicar un test LR (estimando ambos modelos), un test de Wald (solo el modelo generalizado) o un test del multiplicador de Lagrange (solo el modelo restringido). El estadístico sigue una χ^2 con grados de libertad iguales al número de variables en $\mathbf{z}$. Si se rechaza H_0, debe considerarse un modelo Tobit heterocedástico o, alternativamente, métodos semiparamétricos que no impongan la homocedasticidad.

Pregunta 3: ¿Son los errores normales?

Esta pregunta se aborda con los tests de Shapiro-Wilk y Jarque-Bera, que se describen en detalle en la sección siguiente.

4.6.3 Test del multiplicador de Lagrange para heterocedasticidad

El test más habitual en la práctica es el de **heterocedasticidad**, porque la homocedasticidad es un supuesto fuerte.

Consideremos el modelo Tobit heterocedástico:

$$\sigma_i^2 = \sigma^2 \exp(\mathbf{z}_i \alpha)$$

donde $\mathbf{z}_i$ son variables que pueden causar heterocedasticidad.

Hipótesis:

- $H_0 : \alpha = 0$ (homocedasticidad → Tobit estándar válido).
- $H_1 : \alpha \neq 0$ (heterocedasticidad → Tobit estándar inconsistente).

El estadístico LM se calcula a partir de los residuos del modelo Tobit homocedástico, y sigue una distribución χ^2 con grados de libertad iguales al número de variables en **z**.

> **En la práctica:** Si el test rechaza H_0, se debe considerar un modelo Tobit heterocedástico o métodos semiparamétricos.

4.6.3.1 Test de Bartlett: alternativa práctica para la homocedasticidad

Además del test LM, existe una alternativa más sencilla y directa cuando se sospecha que la varianza del error difiere entre **subgrupos** definidos por alguna variable categórica del modelo (por ejemplo, el tipo de programa educativo, el sector de actividad o el sexo). Se trata del **test de Bartlett** (1937).

El test de Bartlett contrasta si las varianzas de una variable continua (en este caso, los residuos del modelo) son iguales en K subgrupos:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_K^2 \qquad \text{(homocedasticidad entre grupos)}$$

El estadístico del test compara la varianza ponderada del conjunto con las varianzas individuales de cada grupo. Bajo H_0, sigue una distribución χ^2 con $K - 1$ grados de libertad. Un p-valor inferior a 0.05 indica que las varianzas difieren significativamente entre los grupos, lo que constituye evidencia de heterocedasticidad.

Conviene señalar que el test de Bartlett es **sensible a la no normalidad**: si los residuos no son normales, puede rechazar H_0 incluso cuando las varianzas son iguales. Por esta razón, debe aplicarse después de verificar la normalidad, o complementarse con el test de Levene (más robusto a desviaciones de la normalidad).

En R, el test se ejecuta con `bartlett.test(residuos ~ grupo, data = datos)`, donde `grupo` es la variable categórica que define los subgrupos.

4.6.4 Test de normalidad de los errores

4.6.4.1 ¿Por qué la normalidad es crítica en el Tobit?

La normalidad de los errores es un supuesto mucho más importante en el modelo Tobit que en la regresión lineal clásica. En MCO, el Teorema Central del Límite garantiza que los estimadores son asintóticamente normales con independencia de la distribución del error: la normalidad es conveniente pero no imprescindible. En el modelo Tobit, en cambio, toda la función de verosimilitud depende explícitamente de la forma funcional de la densidad $f(\varepsilon)$ y de la distribución acumulada $F(\varepsilon)$ del error. Si la distribución

no es normal, las probabilidades de censura están mal calculadas, las densidades de los no censurados también, y en consecuencia los estimadores resultan **inconsistentes**. No se trata de un problema de eficiencia que pueda resolverse con errores robustos: es un error fundamental de especificación.

Por esta razón, verificar formalmente la normalidad de los residuos es un paso imprescindible en el diagnóstico de cualquier modelo Tobit.

4.6.4.2 Test de Shapiro-Wilk

El test de **Shapiro-Wilk** (1965) es uno de los contrastes de normalidad más utilizados y potentes. Su hipótesis nula es que los datos provienen de una población distribuida normalmente:

$$H_0 : \varepsilon_i \sim N(\mu, \sigma^2)$$

El estadístico del test, denominado W, se construye a partir de la relación entre la varianza estimada mediante una combinación lineal de los estadísticos de orden y la varianza muestral clásica:

$$W = \frac{\left(\sum_{i=1}^{n} a_i \, x_{(i)}\right)^2}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

donde $x_{(i)}$ son los datos ordenados de menor a mayor y a_i son constantes tabuladas que dependen del tamaño muestral. El estadístico W toma valores entre 0 y 1: cuanto más cercano a 1, mayor compatibilidad con la normalidad. Valores significativamente inferiores a 1 indican desviaciones de la normalidad.

La regla de decisión es sencilla: si el p-valor del test es inferior a 0.05, se rechaza H_0 y se concluye que hay evidencia estadística contra la normalidad. Conviene tener en cuenta que el test de Shapiro-Wilk es muy potente con muestras de tamaño moderado (hasta $n = 5000$ aproximadamente), lo que significa que detecta desviaciones pequeñas de la normalidad. En muestras muy grandes, incluso desviaciones triviales pueden resultar estadísticamente significativas.

En R, el test se ejecuta con `shapiro.test(x)`, que devuelve el estadístico W y su p-valor.

4.6.4.3 Test de Jarque-Bera

El test de **Jarque-Bera** (1980) adopta un enfoque diferente: en lugar de comparar la distribución completa con la normal, se centra en dos características específicas: la **asimetría** y la **curtosis**. La distribución normal se caracteriza por una asimetría igual a cero (simetría perfecta) y una curtosis igual a 3 (mesocúrtica). Cualquier desviación de estos dos valores sugiere no normalidad.

El estadístico de Jarque-Bera combina ambas medidas en un único indicador:

$$JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right)$$

donde S es el coeficiente de asimetría muestral (tercer momento estandarizado) y K es la curtosis muestral (cuarto momento estandarizado). Bajo la hipótesis nula de normalidad, el estadístico JB sigue asintóticamente una distribución χ^2 con 2 grados de libertad (un grado por la asimetría y otro por la curtosis).

Un valor elevado de JB (con p-valor inferior a 0.05) indica que la distribución presenta una asimetría, una curtosis, o ambas, incompatibles con la normalidad. Si el p-valor es superior a 0.05, no se rechaza H_0 y los datos son compatibles con la distribución normal.

El test de Jarque-Bera es especialmente útil en muestras grandes, donde el estadístico asintótico tiene buenas propiedades. En muestras pequeñas, el test de Shapiro-Wilk suele ser preferible. En R, se calcula con `tseries::jarque.bera.test(x)`.

4.6.4.4 Precaución importante sobre los residuos en modelos censurados

Conviene subrayar una dificultad específica del diagnóstico de normalidad en el contexto del modelo Tobit. Los residuos convencionales ($e_i = y_i - \hat{y}_i$) no se distribuyen normalmente **ni siquiera cuando el modelo está correctamente especificado**, porque la censura distorsiona su distribución: los residuos de las observaciones censuradas tienen una estructura diferente a los de las no censuradas. Por esta razón, los tests de normalidad deben aplicarse exclusivamente a los **residuos de las observaciones no censuradas** ($y_i > 0$), para las cuales el modelo se reduce a una regresión normal estándar.

4.6.5 Tablas resumen: pruebas de especificación del modelo Tobit

Los tests de diagnóstico del Tobit se agrupan en dos categorías: los que evalúan la **significación** de las variables incluidas y los que verifican los **supuestos distribucionales** del modelo.

Cuadro 4.7: Tests de significación de variables

Test	H_0	Distribución	Criterio
Wald	$\beta_j = 0$	$z \sim N(0,1)$	Rechazar si $p < 0{,}05$

Test	H_0	Distribución	Criterio
Razón de verosimilitud (LR)	Grupo de $\beta = 0$	$\chi^2(q)$	Rechazar si $p < 0{,}05$

Cuadro 4.8: Tests de supuestos distribucionales (normalidad y homocedasticidad)

Test	Supuesto	H_0	Si se rechaza
LM (Lagrange)	Homocedasticidad	$\alpha = 0$	Tobit inconsistente
Bartlett	Homocedasticidad	$\sigma_1^2 = \cdots = \sigma_K^2$	Varianzas desiguales
Shapiro-Wilk	Normalidad	Residuos normales	Tobit inconsistente
Jarque-Bera	Normalidad	Asimetría y curtosis normales	Tobit inconsistente

Recordatorio: la violación de normalidad o homocedasticidad en el Tobit produce **inconsistencia**, no solo ineficiencia. Si alguno de estos tests rechaza H_0, las estimaciones del modelo no son fiables.

4.7 Ejemplo práctico completo en R

4.7.1 El problema: aptitud académica censurada

En este ejemplo aplicamos el modelo Tobit a un problema concreto: la modelización de la **aptitud académica** de estudiantes universitarios. La variable dependiente (`apt`) se mide en una escala de 200 a 800 puntos. Las variables explicativas son la puntuación en una prueba de lectura (`read`), la puntuación en una prueba de matemáticas (`math`) y el tipo de programa educativo (`prog`: académico, general o vocacional).

El modelo Tobit que estimaremos es:

$$\text{apt}_i^* = \beta_0 + \beta_1 \,\text{read}_i + \beta_2 \,\text{math}_i + \beta_3 \, D_i^{\text{general}} + \beta_4 \, D_i^{\text{vocacional}} + \varepsilon_i, \qquad \varepsilon_i \sim N(0, \sigma^2)$$

donde apt_i^* es la aptitud latente (sin restricciones de escala) y la variable observada es $\text{apt}_i = \min(\max(\text{apt}_i^*, 200), 800)$.

La censura aparece en la cota superior de la escala: los estudiantes cuya aptitud latente supera los 800 puntos reciben todos una puntuación de 800, sin que podamos distinguir entre ellos. En el extremo inferior, la escala tiene un mínimo de 200 puntos, aunque en esta muestra concreta no se observan observaciones censuradas por la izquierda (el valor mínimo registrado es 352).

4.7.2 Carga y exploración de datos

> **Observación:** Hay 17 observaciones con `apt = 800` (censura por la derecha, un 8.5%) y ninguna con `apt = 200`. El valor mínimo observado es 352, por lo que en la práctica solo hay censura por la derecha.

4.7.3 Análisis gráfico

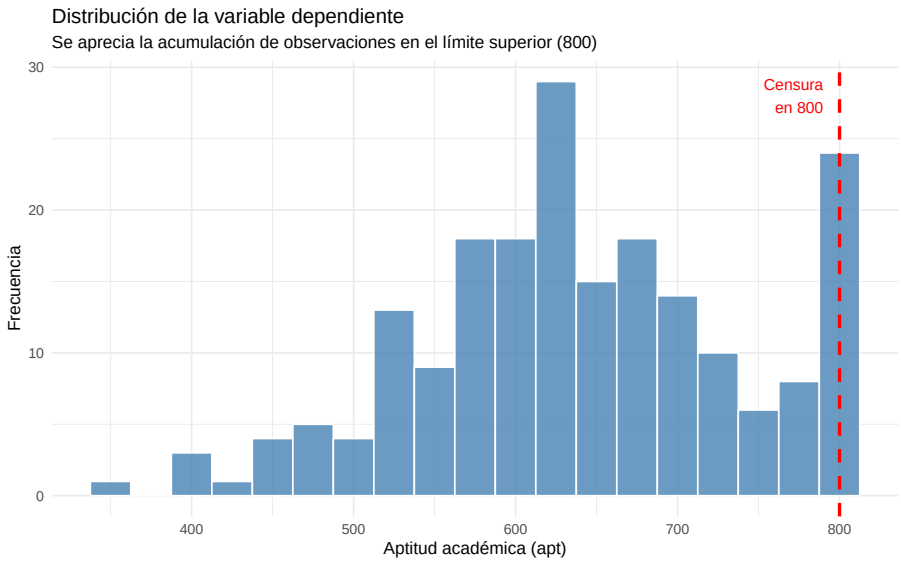

Figura 4.2: Distribución de la aptitud académica. Nótese la acumulación en apt = 800.

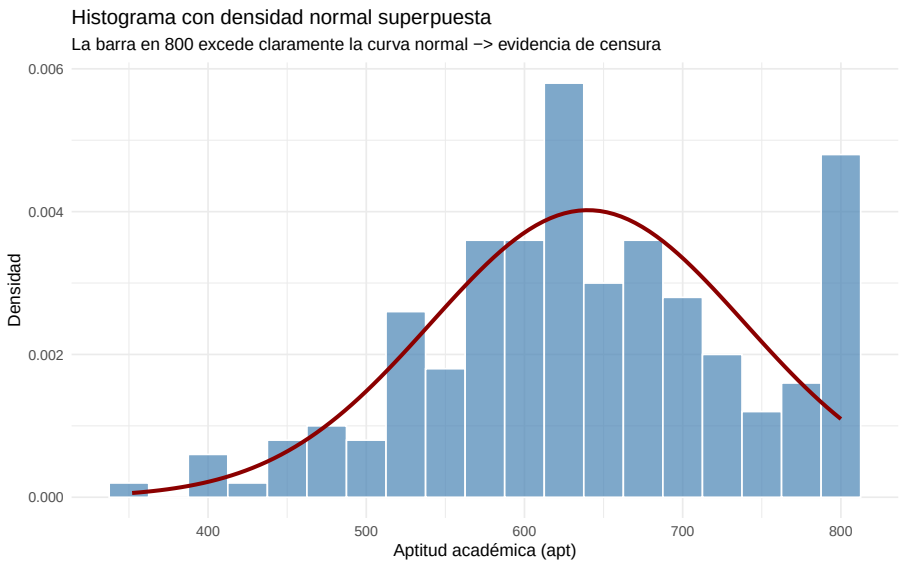

Figura 4.3: Histograma con densidad normal superpuesta. La acumulación en 800 queda fuera de la curva normal.

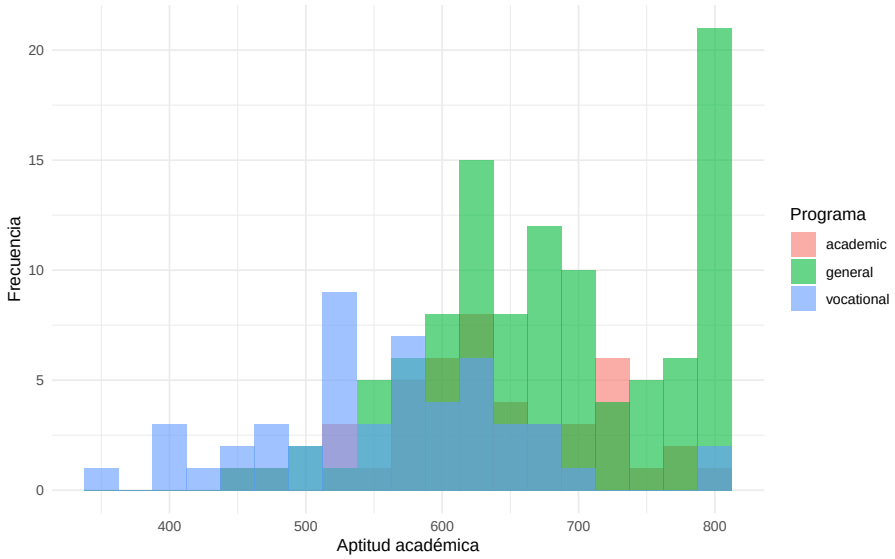

Figura 4.4: Distribución de apt por tipo de programa.

4.7.4 Estimación del modelo Tobit

Usaremos dos paquetes para estimar el modelo y comparar resultados:

4.7.4.1 Con `censReg`

4.7.4.2 Con `VGAM`

> **Nota sobre las diferencias:** Los resultados de `censReg()` y `vglm()` pueden diferir ligeramente porque utilizan **métodos diferentes** para maximizar la verosimilitud. `censReg` usa Newton-Raphson, mientras que `vglm` usa Fisher scoring. Las diferencias son generalmente menores.
>
> **¿Qué es `(Intercept):2` en `vglm`?** Es $\log(\hat{\sigma})$, un parámetro auxiliar que estima la desviación típica del error. En `censReg` aparece como `logSigma`.

4.7.5 Interpretación de los coeficientes

Cuadro 4.9: Coeficientes del modelo Tobit

	Estimate	Std. error	t value	Pr(> t)
(Intercept)	209.5660	32.7720	6.3947	0.0000
read	2.6979	0.6188	4.3599	0.0000
math	5.9145	0.7098	8.3324	0.0000
proggeneral	-12.7148	12.4065	-1.0249	0.3054
progvocational	-46.1439	13.7242	-3.3622	0.0008
logSigma	4.1847	0.0530	78.9457	0.0000

Interpretación de cada coeficiente:

Los coeficientes del modelo Tobit se interpretan como el efecto sobre la **variable latente** y^* (aptitud real, sin censura):

- **read = 2.698:** Un aumento de un punto en la prueba de lectura se asocia con un aumento de 2.70 puntos en la aptitud latente, *ceteris paribus*. Estadísticamente significativo ($p < 0.001$).
- **math = 5.915:** Un aumento de un punto en la prueba de matemáticas se asocia con un aumento de 5.91 puntos en la aptitud latente. Estadísticamente significativo ($p < 0.001$). Las matemáticas tienen **más del doble de efecto** que la lectura.
- **proggeneral = −12.71:** Los estudiantes en programa general tienen, en promedio, 12.71 puntos menos de aptitud latente que los del programa académico (categoría base). **No significativo** ($p = 0.305$).

- **progvocational = −46.14:** Los estudiantes en programa vocacional tienen, en promedio, 46.14 puntos menos de aptitud latente que los del programa académico. **Significativo** ($p < 0.001$).

  Recuerda: Estos son efectos sobre la variable **latente** y^*. El efecto sobre la variable **observada** y es ligeramente menor, porque hay que multiplicar por $\Phi(\mathbf{x}\hat{\beta}/\hat{\sigma})$.

4.7.6 Cálculo de p-valores

Cuadro 4.10: Coeficientes con p-valores ajustados

	Estimate	Std. Error	z value	Pr(>|z|)	p-value (t)
(Intercept):1	209.5596	32.5459	6.4389	0.0000	0.0000
(Intercept):2	4.1848	0.0523	79.9439	0.0000	0.0000
read	2.6980	0.6193	4.3566	0.0000	0.0000
math	5.9146	0.7054	8.3849	0.0000	0.0000
proggeneral	-12.7146	12.4086	-1.0247	0.3055	0.3062
progvocational	-46.1433	13.7067	-3.3665	0.0008	0.0008

¿Por qué usamos la distribución t? En muestras finitas, la distribución t proporciona p-valores más conservadores que la normal. Con 200 observaciones, la diferencia es pequeña.

4.7.7 Significación de variables categóricas: Test de razón de verosimilitud

Para evaluar si la variable `prog` (tipo de programa) es significativa **en su conjunto** (no solo una categoría), comparamos dos modelos:

Interpretación: El p-valor del test LR es 0.003 (< 0.05), por lo que rechazamos la hipótesis nula de que los coeficientes de `prog` son conjuntamente cero. **El tipo de programa es significativo** para explicar la aptitud académica.

4.7.8 Bondad de ajuste

4.7.8.1 Análisis de residuos

Para evaluar si nuestro modelo se ajusta correctamente a los datos, examinamos **seis gráficos de diagnóstico**. Cada uno revela un aspecto diferente del ajuste.

Antes de ver los gráficos, conviene entender los dos tipos de residuos que usamos:

- **Residuos de respuesta** ($e_i = y_i - \hat{y}_i$): la diferencia simple entre el valor observado y el ajustado. Son los más intuitivos.
- **Residuos de Pearson** ($r_i = e_i/\hat{\sigma}$): los residuos de respuesta estandarizados por la desviación típica estimada. Permiten comparar la magnitud relativa de los errores y detectar outliers (valores $|r_i| > 2{-}3$ son sospechosos).

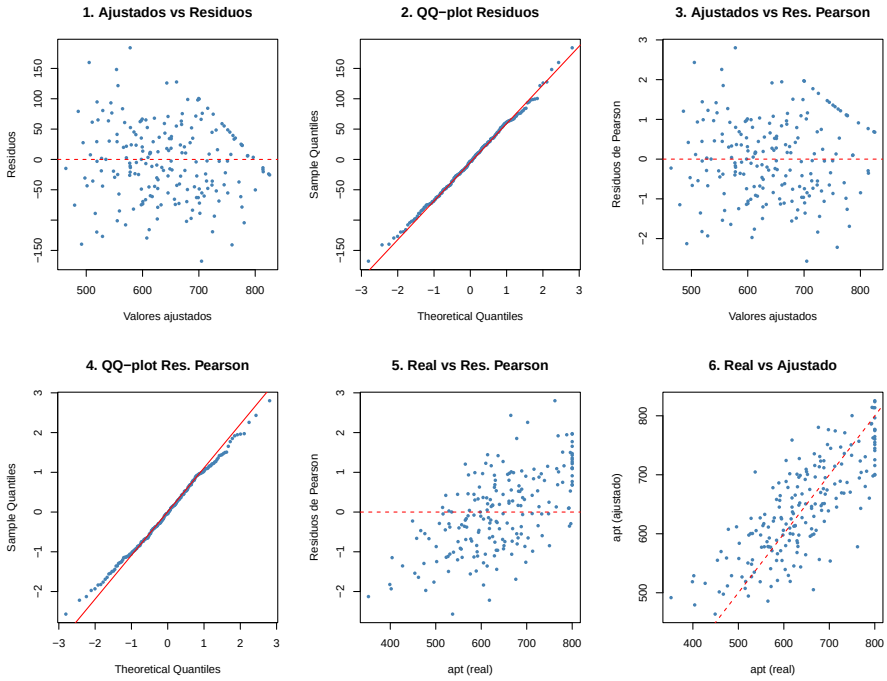

Figura 4.5: Diagnósticos de residuos del modelo Tobit.

4.7.8.2 Guía de lectura de cada gráfico

Gráfico 1 — Ajustados vs. Residuos de respuesta: Comprueba si los residuos se distribuyen **aleatoriamente** alrededor de cero. ¿Qué buscar? Una nube de puntos sin patrón sistemático. Si se observa un patrón de «embudo» (los residuos se abren a medida que aumentan los valores ajustados), hay indicios de **heterocedasticidad**. Si se observa una curvatura, el modelo puede no captar una relación no lineal. En nuestro ejemplo, la nube es razonablemente uniforme.

Gráfico 2 — QQ-plot de residuos de respuesta: Compara la distribución empírica de los residuos con una distribución normal teórica. ¿Qué buscar? Los puntos deben seguir la **línea recta roja**. Desviaciones en las colas (los extremos se alejan de la recta) indican **colas pesadas** o **asimetría**, lo que cuestiona el supuesto de normalidad.

Recordemos que en el Tobit la normalidad es un supuesto **crítico**: su violación produce inconsistencia (no solo ineficiencia, como en MCO).

Gráfico 3 — Ajustados vs. Residuos de Pearson: Similar al gráfico 1, pero con los residuos **estandarizados** (divididos por $\hat{\sigma}$). La ventaja es que los valores están en unidades de desviaciones típicas. Residuos con $|r_i| > 2$ merecen atención; con $|r_i| > 3$ son posibles **outliers**. Se busca la misma ausencia de patrones que en el gráfico 1.

Gráfico 4 — QQ-plot de residuos de Pearson: Igual que el gráfico 2, pero con los residuos estandarizados. Proporciona una evaluación más limpia de la normalidad porque elimina el efecto de la escala. Es el gráfico más fiable para diagnosticar desviaciones de normalidad.

Gráfico 5 — Valor real (apt) vs. Residuos de Pearson: Permite detectar si los errores del modelo son sistemáticamente mayores para ciertos rangos de la variable dependiente. En el caso de datos censurados, es normal ver una concentración de residuos negativos en los valores altos de `apt` (las observaciones censuradas en 800 tienen un valor ajustado por debajo de 800, generando residuos positivos). Un patrón claro (por ejemplo, los residuos crecen linealmente con `apt`) indicaría mala especificación.

Gráfico 6 — Valor real vs. Valor ajustado: Es la medida más intuitiva del ajuste: ¿cuánto se parecen las predicciones a los valores reales? Los puntos deben distribuirse cerca de la **línea de 45°** (recta discontinua roja, donde $\hat{y} = y$). Puntos muy alejados de esta recta son predicciones malas. En nuestro ejemplo, se observa la acumulación característica en `apt = 800` (censura), donde el modelo predice valores por debajo del tope.

> **Resumen para nuestro ejemplo:** Los gráficos muestran un ajuste razonable. No hay patrones claros de heterocedasticidad (gráficos 1 y 3). El QQ-plot (gráficos 2 y 4) revela una ligera desviación en la cola derecha, consecuencia esperable de la censura en 800. El gráfico 6 confirma que el modelo predice bien en el rango central pero, como es lógico, no puede predecir valores por encima de 800.

4.7.8.3 Correlación y R² aproximado

> **Nota:** El modelo Tobit no tiene un R^2 formal como la regresión lineal. La correlación al cuadrado entre valores ajustados y observados es una medida aproximada de bondad de ajuste.

4.7.9 Comparación final: MCO vs Tobit

Cuadro 4.11: Comparación MCO vs Tobit: coeficientes y p-valores

Variable	MCO_coef	MCO_pval	Tobit_coef	Tobit_pval
(Intercepto)	242.735	0.0000	209.566	0.0000
read	2.553	0.0000	2.698	0.0000
math	5.383	0.0000	5.914	0.0000
proggeneral	-13.741	0.2434	-12.715	0.3054
progvocational	-48.835	0.0002	-46.144	0.0008

Observación esperada: Los coeficientes de MCO son menores en valor absoluto que los de Tobit, consistente con el sesgo de atenuación. Sin embargo, las conclusiones cualitativas (qué variables son significativas) son similares.

4.7.10 Efectos marginales

En la sección teórica derivamos que el coeficiente $\hat{\beta}_j$ mide el efecto sobre la variable **latente** y^*, no sobre la variable **observada** y. Calculemos ahora los **Efectos Marginales Promedio** (AME, *Average Marginal Effects*) para verificar esta diferencia en la práctica.

Cuadro 4.12: Coeficientes Tobit vs Efectos Marginales Promedio (AME)

Variable	$\hat{\beta}$ (efecto sobre y^*)	AME (efecto sobre y observada)	$\bar{\Phi}$ media	AME como % de $\hat{\beta}$
read	2.698	2.501	0.927	92.7%
math	5.914	5.482	0.927	92.7%
proggeneral	-12.715	-11.785	0.927	92.7%
progvocational	-46.144	-42.770	0.927	92.7%

Lectura de la tabla:

- $\hat{\beta}$ es el efecto de cada variable sobre la aptitud **latente** (la que mediríamos si el test no tuviera techo en 800).
- **AME** es el efecto sobre la aptitud **observada**, teniendo en cuenta que algunos estudiantes están «pegados» al techo de 800. Se calcula como $\hat{\beta}_j \times \bar{\Phi}$, donde $\bar{\Phi}$ es la probabilidad media de no estar censurado.
- Φ **media** es el promedio de $\Phi\left(\frac{c-\mathbf{x}\hat{\beta}}{\hat{\sigma}}\right)$ en la muestra: la fracción del efecto latente que «pasa» a la variable observada.
- **AME como % de** $\hat{\beta}$: un ratio cercano al 100% indica poca censura efectiva; un ratio bajo señala que la censura «absorbe» gran parte del efecto.

En nuestro ejemplo: Como la proporción de observaciones censuradas es relativamente baja (~8.5%), los AME son cercanos a los coeficientes. En un modelo con censura intensa (>30%), la diferencia sería mucho mayor.

4.7.11 Pruebas de especificación del modelo estimado

Tras estimar el modelo Tobit e interpretar sus coeficientes, el paso final consiste en verificar que los supuestos del modelo se cumplen razonablemente en los datos. Como se ha explicado en la sección de pruebas de especificación, los dos supuestos críticos del Tobit son la **normalidad** y la **homocedasticidad** de los errores. Si alguno de estos supuestos se viola, los estimadores son inconsistentes y las interpretaciones pierden validez.

A continuación aplicamos los tests de Shapiro-Wilk (normalidad) y Bartlett (homocedasticidad) a nuestro modelo de aptitud académica. Es importante recordar que ambos tests se aplican exclusivamente a las **observaciones no censuradas** (apt < 800), porque la censura distorsiona la distribución de los residuos incluso cuando el modelo está correctamente especificado.

4.7.11.1 Test de normalidad de Shapiro-Wilk

El primer diagnóstico evalúa si los residuos del modelo siguen una distribución normal. Para ello, seleccionamos únicamente las observaciones cuya aptitud no está censurada en 800 y aplicamos el test de Shapiro-Wilk a sus residuos. La hipótesis nula es que los residuos provienen de una población normal; un p-valor inferior a 0.05 indicaría evidencia contra la normalidad y, por tanto, un posible problema de especificación del modelo.

4.7.11.2 Test de homocedasticidad de Bartlett

El segundo diagnóstico evalúa si la varianza de los errores es constante entre subgrupos de la muestra. En nuestro caso, la variable `prog` (tipo de programa: académico, general o vocacional) define subgrupos naturales. Si la dispersión de los residuos difiere significativamente entre estos tres grupos, hay indicios de que la varianza del error depende de las características del individuo, lo que violaría el supuesto de homocedasticidad.

El test de Bartlett contrasta la hipótesis nula de igualdad de varianzas entre los grupos: $H_0 : \sigma^2_{\text{acad}} = \sigma^2_{\text{gen}} = \sigma^2_{\text{voc}}$. Un p-valor inferior a 0.05 indicaría que las varianzas difieren y que el modelo Tobit estándar podría ser inconsistente, requiriendo un modelo heterocedástico o errores robustos.

4.7.11.3 Resumen de resultados diagnósticos

La tabla siguiente recoge los resultados de todos los diagnósticos aplicados al modelo Tobit estimado: el test de normalidad (Shapiro-Wilk), el test de homocedasticidad (Bartlett), el test de significación conjunta de la variable `prog` (razón de verosimilitud) y la correlación entre valores ajustados y observados como indicador global de ajuste.

Cuadro 4.13: Resumen de diagnósticos del modelo Tobit estimado

Prueba	¿Qué evalúa?	Estadístico	P-valor	Conclusión
Shapiro-Wilk	Normalidad de los errores	W = 0.9957	0.8871	Compatible con normalidad
Bartlett	Homocedasticidad entre programas	$\chi^2 = 4.3574$	0.1132	Compatible con homocedasticidad
LR (prog conjuntamente)	Significación conjunta de prog	LR = 11.5174	0.0032	prog es significativo
Correlación ajustado-real	Bondad de ajuste global	$R^2 \approx 0.6123$	—	Ajuste aceptable

Valoración global: Si el modelo supera estas pruebas (no se rechaza normalidad ni homocedasticidad), las estimaciones Tobit y sus interpretaciones son fiables. En caso contrario, habría que considerar un modelo Tobit heterocedástico, métodos semiparamétricos o, si la censura responde a un proceso de selección, el modelo de Heckman.

4.8 Extensiones del modelo Tobit

4.8.1 El método de Heckman en dos etapas

Cuando la censura se debe a un **proceso de selección** (por ejemplo, solo observamos salarios de personas que deciden trabajar), el modelo Tobit estándar puede no ser apropiado. En estos casos, se utiliza el **modelo de Heckman** (1979), que separa:

1. **Ecuación de selección** (Probit): ¿participa el individuo? ($d_i = 1$ si participa, $d_i = 0$ si no).
2. **Ecuación de resultado**: $y_i = \mathbf{x}_i\beta + \varepsilon_i$ (solo observada si $d_i = 1$).

El método de Heckman corrige el sesgo de selección incluyendo el **Inverse Mills Ratio** ($\widehat{\lambda}_i$), estimado a partir de la ecuación de selección, como regresor adicional en la ecuación de resultado.

> **Diferencia clave:** El Tobit asume que la decisión de censurar y el resultado siguen el mismo proceso ($y^* > 0 \Leftrightarrow$ observamos y). El modelo de Heckman permite que sean procesos **diferentes** con errores potencialmente correlacionados.

4.8.2 Modelo Tobit generalizado

El modelo Tobit se puede generalizar para incluir:

- **Censura en ambos lados** (como en el ejemplo de aptitud).
- **Heterocedasticidad** (σ_i varía con las observaciones).
- **Distribuciones no normales** del error.

Estas generalizaciones requieren funciones de verosimilitud más complejas, pero están implementadas en paquetes de R como `VGAM`, `AER` y `sampleSelection`.

4.9 Resumen: lo esencial en 10 puntos

1. **¿Qué son datos censurados?** Datos donde la variable dependiente no se observa más allá de cierto umbral, aunque las variables explicativas sí están disponibles.
2. **Censura $\neq$ datos faltantes.** En la censura sabemos que la observación existe y conocemos las X; en datos faltantes no tenemos la observación.
3. **Variable latente y^*.** Es el valor verdadero que queremos medir pero no siempre observamos. La variable observada y es una versión «recortada» de y^*.
4. **El modelo Tobit** especifica: $y^* = \mathbf{x}\beta + \varepsilon$ con $\varepsilon \sim N(0, \sigma^2)$, y $y = \max(0, y^*)$ para censura por la izquierda.
5. **MCO es inconsistente** con datos censurados: subestima los coeficientes (sesgo de atenuación).
6. **La verosimilitud Tobit es un híbrido** Probit + regresión normal: las observaciones censuradas contribuyen con una probabilidad (como en Probit) y las no censuradas con una densidad (como en regresión).
7. **Tres medias condicionales.** El efecto parcial depende de si nos interesa la variable latente, los no censurados o toda la muestra. El coeficiente β_j es el efecto sobre y^*; para $E(y \mid \mathbf{x})$ hay que multiplicar por $\Phi(\mathbf{x}\beta/\sigma)$.
8. **Los supuestos importan mucho.** La normalidad y homocedasticidad no son solo deseables: su violación produce inconsistencia. Siempre hay que realizar pruebas de especificación.
9. **En R:** `censReg()` y `vglm()` son las funciones principales. `censReg` es más sencilla; `vglm` es más flexible.
10. **Extensiones:** Cuando la censura proviene de un proceso de selección diferente al resultado, se debe usar el modelo de **Heckman** en lugar del Tobit.

4.10 Funciones esenciales en R

A continuación se recogen, organizadas por tarea, las funciones de R más utilizadas en el análisis de modelos Tobit. Esta sección es una referencia rápida; la explicación detallada de cada paso se encuentra en las secciones anteriores.

4.10.1 Estimación

- `censReg::censReg(y ~ x1 + x2, left = 0, right = Inf, data = datos)` — Estima un modelo Tobit. Los argumentos `left` y `right` definen los puntos de censura. Si solo hay censura por la derecha, usar `left = -Inf`.
- `VGAM::vglm(y ~ x1 + x2, VGAM::tobit(Lower = 0, Upper = Inf), data = datos)` — Alternativa más flexible. Permite extensiones (heterocedasticidad, distribuciones alternativas).
- `AER::tobit(y ~ x1 + x2, left = 0, right = Inf, data = datos)` — Otra alternativa, basada internamente en `survival::survreg`.

4.10.2 Extracción de resultados

- `summary(modelo)` — Tabla completa: coeficientes, errores estándar, z-values, p-valores.
- `coef(modelo)` — Vector de coeficientes estimados ($\widehat{\beta}$ y $\log \widehat{\sigma}$).
- `logLik(modelo)` — Log-verosimilitud del modelo estimado.
- `vcov(modelo)` — Matriz de varianzas-covarianzas de los estimadores.

4.10.3 Efectos marginales

- `censReg::margEff(modelo)` — Calcula $\partial E(y \mid \mathbf{x})/\partial x_j$ para cada observación.
- `colMeans(margEff(modelo))` — **Efectos Marginales Promedio** (AME): el efecto medio sobre la variable observada.

4.10.4 Diagnósticos y residuos

- `fitted(modelo)` — Valores ajustados ($\widehat{y}$).
- `resid(modelo, type = "response")` — Residuos de respuesta ($y - \widehat{y}$).
- `resid(modelo, type = "pearson")` — Residuos de Pearson (estandarizados por $\widehat{\sigma}$).
- `shapiro.test(residuos)` — Test de normalidad de Shapiro-Wilk (H_0: normalidad).
- `bartlett.test(residuos ~ grupo, data)` — Test de igualdad de varianzas entre grupos (H_0: homocedasticidad).

4.10.5 Comparación de modelos

- `2 * (logLik(m_completo) - logLik(m_reducido))` — Estadístico de razón de verosimilitud (LR).
- `pchisq(LR, df = q, lower.tail = FALSE)` — P-valor del test LR con q restricciones.
- `AIC(modelo)` / `BIC(modelo)` — Criterios de información (menor = mejor ajuste relativo).

4.10.6 Comparación MCO vs Tobit

- `lm(y ~ x1 + x2, data = datos)` — Estimación MCO (ignorando la censura, como referencia).
- Los coeficientes MCO serán menores en valor absoluto que los Tobit (sesgo de atenuación).

Código R del capítulo

El script completo de este capítulo (`T03_mECO_Script_Tobit.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Capítulo 5

Modelos para Datos de Recuento

5.1 Introducción: ¿Por qué modelos para datos de recuento?

En los temas anteriores hemos estudiado modelos para distintos tipos de variables dependientes: variables continuas sin restricciones (Tema 1), variables binarias (Tema 2) y variables continuas limitadas por censura (Tema 3). Ahora abordamos un nuevo y muy relevante tipo de variables dependientes: aquellas que toman valores **enteros no negativos** (0, 1, 2, 3, ...), es decir, **datos de recuento** o **count data**.

Este tipo de datos es extremadamente frecuente en aplicaciones económicas, empresariales y de política pública:

Cuadro 5.1: Ejemplos de variables de recuento en economía

Contexto	Variable	Rango	Características
Salud	Visitas al médico/año	0-50+	Muchos ceros
Innovación	Patentes solicitadas	0-100+	Sobredispersión
Laboral	Accidentes laborales	0-10+	Datos raros
Financiero	Quejas de clientes	0-1000+	Exceso ceros
Educativo	Faltas de asistencia	0-180	Límite superior
Demográfico	Número de hijos	0-15+	Distribución asimétrica

Este tipo de datos presenta características que hacen inadecuado el uso de la regresión lineal clásica. En primer lugar, la variable dependiente solo toma valores **enteros no negativos**: no tiene sentido predecir 2.7 visitas al médico o -1 accidentes laborales. Sin embargo, MCO puede generar predicciones fraccionarias e incluso negativas, lo que viola la naturaleza del fenómeno. En segundo lugar, la **distribución** de los datos de

recuento es típicamente asimétrica, con una acumulación de observaciones en valores bajos (muchos ceros y unos) y una cola derecha que se extiende hacia valores altos. La distribución normal, que MCO asume implícitamente, no captura esta forma. En tercer lugar, existe una **relación intrínseca entre la media y la varianza**: en datos de recuento, los individuos con media alta tienden a mostrar también mayor variabilidad. Esta heterocedasticidad es estructural, no un defecto del modelo, y MCO la ignora.

Si aplicamos MCO directamente a datos de recuento, obtendremos estimaciones **sesgadas e inconsistentes**, intervalos de confianza incorrectos, y predicciones que pueden violar las restricciones naturales del problema.

5.1.1 El modelo Poisson: concepto fundamental

El **modelo de Poisson** y la **regresión Binomial Negativa** son herramientas diseñadas específicamente para modelar datos de recuento. El Poisson fue propuesto inicialmente para estos problemas porque proporciona un marco probabilístico natural basado en la distribución de Poisson.

En estos apuntes se presenta en primer lugar la distribución de Poisson y sus propiedades, con especial énfasis en el concepto de equidispersión. A continuación se desarrolla el modelo de regresión de Poisson, su especificación, estimación por máxima verosimilitud e interpretación de los coeficientes. El tema aborda después el problema de la sobredispersión, frecuente en datos reales, y presenta el modelo Binomial Negativo como extensión flexible del Poisson. La sección de inferencia estadística incluye los tests de hipótesis, la comparación de modelos y las medidas de bondad de ajuste, todos ilustrados con ejemplos numéricos resueltos paso a paso.

5.2 Conceptos fundamentales de datos de recuento

5.2.1 ¿Qué es un dato de recuento?

Una variable de **recuento** (count data) mide el número de ocurrencias de un evento en un período o contexto determinado. Formalmente:

$$Y_i \in \{0, 1, 2, 3, ...\}$$

El espacio de la variable es el conjunto de números enteros no negativos. No hay límite superior teórico, aunque en la práctica los datos pueden estar acotados.

Ejemplos intuitivos:

- **Número de visitas al médico en un año**: Un paciente puede no visitar al médico (0 visitas), o tener múltiples visitas según su estado de salud.
- **Número de patentes solicitadas por una empresa**: Mide la innovación. Muchas empresas no solicitan patentes, pero las que innovan lo hacen múltiples veces.
- **Número de accidentes laborales**: En una empresa pequeña puede haber 0 accidentes; en una fábrica grande pueden ocurrir varios.
- **Número de empresas competidoras en un mercado local**: Define la estructura de mercado.

5.2.2 Propiedades estadísticas clave

Para una variable de recuento Y_i, necesitamos entender cuatro propiedades fundamentales:

5.2.2.1 1. Media y Varianza

- **Media**: $E[Y_i]$ = promedio del número de ocurrencias. Si modelamos visitas al médico, $E[Y_i] = 3$ significa que en promedio un paciente visita 3 veces.
- **Varianza**: $\text{Var}(Y_i)$ = dispersión alrededor de la media. Mide cómo varían los recuentos entre individuos.

5.2.2.2 2. Equidispersión

En la distribución de Poisson existe una propiedad especial: **media igual a varianza**.

$$E[Y_i] = \text{Var}(Y_i) = \lambda$$

Esto significa que, en Poisson, si el promedio de eventos es 3, la varianza también debe ser 3. Esta es la **equidispersión**.

5.2.2.3 3. Sobredispersión

En datos reales, **frecuentemente la varianza excede la media**:

$$\text{Var}(Y_i) > E[Y_i]$$

Esto ocurre cuando hay heterogeneidad no observada entre individuos, variables omitidas, o errores de especificación.

> **Ejemplo intuitivo**: Si algunas personas tienen predisposición genética a ciertas enfermedades (no observada), tendrán visitas al médico más variables que lo predicho por Poisson puro. Dos personas con $E[Y_i] = 3$ pueden tener realidades muy diferentes: una visita casi siempre (poco variable), otra va cuando está enferma (muy variable).

5.2.2.4 4. Subdispersión

Menos común, pero posible: $\text{Var}(Y_i) < E[Y_i]$. Ocurre cuando los datos están fuertemente acotados o cuando hay mecanismos reguladores.

5.3 La distribución de Poisson

5.3.1 Concepto y propiedades matemáticas

La **distribución de Poisson** es el modelo probabilístico natural para datos de recuento. Describe el número de eventos que ocurren en un intervalo fijo de tiempo o espacio, bajo condiciones específicas.

5.3.1.1 Condiciones para una distribución Poisson

Para que un proceso genere datos Poisson deben cumplirse:

1. **Independencia**: Los eventos ocurren **independientemente**. El que ocurra un evento no afecta la probabilidad de otro.
2. **Tasa constante**: Existe una **tasa promedio constante** de ocurrencia, denotada λ (lambda).
3. **No simultaneidad**: Es **prácticamente imposible** que dos eventos ocurran exactamente al mismo tiempo.
4. **Estacionariedad**: La tasa λ no cambia durante el período observado.

En la práctica, estas condiciones son idealizaciones, pero muchos procesos reales se aproximan a ellas.

5.3.1.2 Definición matemática

Una variable Y sigue una **distribución de Poisson** con parámetro $\lambda > 0$ si su función de probabilidad es:

$$P(Y = y) = \frac{e^{-\lambda}\lambda^y}{y!}, \quad y = 0, 1, 2, ...$$

donde $e \approx 2.71828$ es la base del logaritmo natural, y $y!$ es el factorial.

5.3.1.3 Propiedades fundamentales

Media:

$$E[Y] = \lambda$$

Varianza:

$$\text{Var}(Y) = \lambda$$

Función característica recursiva:

$$P(Y = y + 1) = \frac{\lambda}{y + 1} P(Y = y)$$

Esta última propiedad es útil computacionalmente: permite calcular probabilidades de forma recursiva.

5.3.1.4 Interpretación de λ

El parámetro λ es la **intensidad** o **tasa** del proceso:

- Si $\lambda = 2$, en promedio ocurren 2 eventos por unidad de tiempo.
- Si $\lambda = 0.5$, en promedio ocurre medio evento (o equivalentemente, 1 evento cada 2 unidades).

Visualmente, cuando λ es pequeño (ej. $\lambda = 1$), la distribución está concentrada en valores bajos (muchos ceros). Cuando λ es grande (ej. $\lambda = 10$), la distribución se extiende más y parece más simétrica.

5.3.2 Ejemplos de cálculo

Supongamos que el número de accidentes laborales por mes en una fábrica sigue una distribución Poisson con $\lambda = 2.5$.

Probabilidad de exactamente 3 accidentes:

$$P(Y = 3) = \frac{e^{-2.5} \cdot 2.5^3}{3!} = \frac{0.0821 \cdot 15.625}{6} = 0.2138$$

Es decir, hay aproximadamente un 21.4% de probabilidad de observar exactamente 3 accidentes.

5.4 Modelo de regresión de Poisson

5.4.1 Especificación del modelo

El modelo de **regresión de Poisson** extiende la distribución de Poisson para permitir que el parámetro λ dependa de variables explicativas.

5.4.1.1 Forma básica

Sea y_i el recuento observado para la unidad i, y sea $\mathbf{x}_i = (x_{i1}, \dots, x_{iK})^T$ el vector de variables explicativas.

Distribución condicional:

$$y_i|\mathbf{x}_i \sim \text{Poisson}(\lambda_i)$$

Función de esperanza condicional (no-lineal):

$$E[y_i|\mathbf{x}_i] = \lambda_i = e^{\mathbf{x}_i\beta}$$

Forma logarítmica (lineal en parámetros):

$$\ln(\lambda_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_K x_{iK} = \mathbf{x}_i\beta$$

5.4.1.2 Interpretación de la forma logarítmica

La forma logarítmica es crucial porque:

1. **Garantiza positividad**: Como $\lambda_i = e^{\mathbf{x}_i\beta}$ siempre es positivo (exponencial), nunca obtenemos predicciones negativas.
2. **Link canónico**: Es la "función de enlace" natural para la distribución Poisson.
3. **Interpretación elasticidad**: Un cambio de 1 unidad en x_j aumenta $\ln(\lambda_i)$ en β_j, lo que corresponde a un cambio multiplicativo de e^{β_j} en λ_i.

5.4.2 Estimación por máxima verosimilitud

El modelo Poisson se estima por **máxima verosimilitud** (MV), no por MCO.

5.4.2.1 Función de verosimilitud

Para una muestra de n observaciones:

$$L(\beta) = \prod_{i=1}^{n} \frac{e^{-\lambda_i}\lambda_i^{y_i}}{y_i!}$$

5.4.2.2 Log-verosimilitud

Es más conveniente trabajar con la log-verosimilitud:

$$\ell(\beta) = \sum_{i=1}^{n} [y_i \ln(\lambda_i) - \lambda_i - \ln(y_i!)]$$

Sustituyendo $\lambda_i = e^{\mathbf{x}_i \beta}$:

$$\ell(\beta) = \sum_{i=1}^{n} [y_i(\mathbf{x}_i \beta) - e^{\mathbf{x}_i \beta} - \ln(y_i!)]$$

5.4.2.3 Condiciones de primer orden

El estimador MV $\hat{\beta}$ satisface:

$$\frac{\partial \ell}{\partial \beta} = \sum_{i=1}^{n} (y_i - \lambda_i)\mathbf{x}_i = \mathbf{0}$$

Equivalentemente:

$$\sum_{i=1}^{n} (y_i - \hat{\lambda}_i) x_{ij} = 0, \quad j = 0, 1, \dots, K$$

Esto significa que el residuo medio ponderado por cada variable explicativa debe ser cero.

5.4.2.4 Propiedades del estimador MV

Bajo especificación correcta del modelo Poisson:

1. **Consistencia**: $\hat{\beta} \xrightarrow{p} \beta_0$ cuando $n \to \infty$.
2. **Normalidad asintótica**: $\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, \mathbf{I}^{-1})$, donde $\mathbf{I}$ es la matriz de información.
3. **Eficiencia**: Es el estimador de menor varianza entre estimadores consistentes.

Sin embargo, estas propiedades dependen de que el modelo esté **correctamente especificado**. Si hay sobredispersión, los errores estándar seran demasiado pequeños.

5.4.3 Interpretación de coeficientes

Esta es una sección crucial para la práctica.

5.4.3.1 Efecto marginal

El **efecto marginal** de un cambio unitario en x_j en la media condicional es:

$$\frac{\partial E[y_i|\mathbf{x}_i]}{\partial x_{ij}} = \beta_j \cdot \lambda_i = \beta_j \cdot E[y_i|\mathbf{x}_i]$$

Nota importante: El efecto marginal **no es constante**; depende del nivel de λ_i (o equivalentemente, del nivel de las otras variables).

> **Ejemplo**: Si $\hat{\beta}_{\text{edad}} = 0.03$ en un modelo de visitas al médico, y la media predicha para un individuo es $\hat{\lambda} = 4$, entonces aumentar 1 año de edad aumenta el número esperado de visitas en $0.03 \times 4 = 0.12$ visitas. Para otro individuo con $\hat{\lambda} = 2$, el efecto sería solo $0.03 \times 2 = 0.06$ visitas.

5.4.3.2 Efecto en logaritmos (semi-elasticidad)

Como $\ln(\lambda_i) = \mathbf{x}_i\beta$:

$$\frac{\partial \ln(\lambda_i)}{\partial x_{ij}} = \beta_j$$

Esto se interpreta como: **un cambio de 1 unidad en x_j causa un cambio de $100 \cdot \beta_j$ por ciento en la media predicha**.

> **Ejemplo**: Si $\hat{\beta}_{\text{edad}} = 0.03$, entonces cada año adicional de edad aumenta el número esperado de visitas al médico en un 3% (aproximadamente; exactamente es $(e^{0.03} - 1) \times 100\% = 3.05\%$).

5.4.3.3 Elasticidad

Si x_j es continua, la **elasticidad** es:

$$\varepsilon_j = \frac{\partial E[y_i]}{\partial x_j} \cdot \frac{x_j}{E[y_i]} = \beta_j \cdot x_j$$

Esto mide el **cambio porcentual en la media** resultante de un **cambio porcentual de 1%** en x_j.

5.5 Modelo de regresión Binomial Negativa

5.5.1 Motivación: El problema de la sobredispersión

5.5.1.1 Cuando Poisson falla

En la práctica, los datos reales con frecuencia violan el supuesto de equidispersión de Poisson. Cuando **observamos que la varianza muestral excede la media muestral**, decimos que hay **sobredispersión**.

$$\text{Var}(y_i) > E[y_i]$$

5.5.1.2 Causas de la sobredispersión

Existen varias razones por las que podemos observar sobredispersión:

1. **Heterogeneidad no observada**: Los individuos difieren en características que no observamos (predisposiciones genéticas, preferencias latentes, etc.). Esto introduce variabilidad adicional.
2. **Variables omitidas**: Si el modelo verdadero tiene más variables explicativas que las que incluimos, los residuos capturan esa variabilidad no modelada.
3. **Datos agregados**: Si los datos representan sumas sobre períodos o grupos, la variabilidad será mayor que la de datos individuales.
4. **Errores de especificación**: Forma funcional incorrecta del modelo, distribución asimétrica no capturada, etc.
5. **Exceso de ceros**: Muchos datos de recuento tienen proporción de ceros superior a la predicha por Poisson. Esto se trata con modelos hurdle o zero-inflated.

5.5.1.3 Consecuencias de ignorar la sobredispersión

Si estimamos un modelo Poisson cuando los datos presentan sobredispersión, las consecuencias son asimétricas. Los coeficientes estimados $\widehat{\beta}$ siguen siendo **consistentes**, lo que significa que convergen a sus valores verdaderos al aumentar la muestra. Esta es la buena noticia. La mala noticia es que los **errores estándar quedan sesgados a la baja**: el modelo Poisson, al imponer que la varianza sea igual a la media, subestima la verdadera dispersión de los datos y, en consecuencia, calcula errores estándar demasiado pequeños. Esto provoca que los intervalos de confianza resulten artificialmente estrechos y que los p-valores sean menores de lo que deberían. El resultado práctico es un exceso de **falsos positivos** (errores de Tipo I): el investigador concluye que una variable es significativa cuando en realidad no lo es, simplemente porque la inferencia está basada en una varianza infraestimada.

Por esta razón, detectar y corregir la sobredispersión es un paso ineludible en el análisis de datos de recuento.

5.5.2 Especificación del modelo Binomial Negativo

El modelo **Binomial Negativo** es una generalización del Poisson que permite sobredispersión.

5.5.2.1 Forma básica

Se define el modelo condicional como:

$$y_i|\mathbf{x}_i \sim \text{NB}(\lambda_i, \alpha)$$

con función de esperanza condicional:

$$E[y_i|\mathbf{x}_i] = \lambda_i = e^{\mathbf{x}_i\beta}$$

(igual que en Poisson) y función de varianza condicional:

$$\text{Var}(y_i|\mathbf{x}_i) = \lambda_i + \alpha\lambda_i^2 = \lambda_i(1 + \alpha\lambda_i)$$

donde $\alpha \geq 0$ es el **parámetro de dispersión**.

5.5.2.2 Relación con Poisson

Observemos qué ocurre en casos límite:

- Si $\alpha = 0$: $\text{Var}(y_i) = \lambda_i$, recuperamos el modelo Poisson (equidispersión).
- Si $\alpha > 0$: $\text{Var}(y_i) = \lambda_i + \alpha\lambda_i^2 > \lambda_i$, tenemos sobredispersión.

Cuanto mayor sea α, mayor es la sobredispersión relativa.

5.5.2.3 Parametrización alternativa

A veces el NB se parametriza con el "tamaño" $\theta = 1/\alpha$:

$$\text{Var}(y_i) = \lambda_i + \frac{\lambda_i^2}{\theta}$$

Con esta parametrización, cuanto **menor** sea θ, mayor es la sobredispersión (cuando $\theta \to \infty$, recuperamos Poisson).

5.5.3 Estimación del modelo NB

5.5.3.1 Log-verosimilitud

La función de log-verosimilitud del NB es más compleja que la del Poisson, pero el principio es el mismo: máxima verosimilitud.

Los parámetros β y α se estiman simultáneamente maximizando:

$$\ell(\beta, \alpha) = \sum_{i=1}^{n} [y_i \ln(\lambda_i) - (y_i + 1/\alpha) \ln(1 + \alpha\lambda_i) + \text{términos en factoriales}]$$

5.5.3.2 Propiedades

Bajo especificación correcta:

- El estimador MV es **consistente, asintóticamente normal y eficiente**.
- La **matriz de covarianzas** de $(\widehat{\beta}, \widehat{\alpha})$ se estima consistentemente usando el Hessiano.

5.6 Inferencia estadística y comparación de modelos

En esta sección explicamos con detalle los principales contrastes de hipótesis para modelos de recuento. Cada test se presenta con su **planteamiento formal**, **fórmula**, **ejemplo numérico resuelto paso a paso** y **criterio de decisión**.

Para los ejemplos usaremos unos resultados hipotéticos (pero realistas) de un modelo de **visitas al médico** ($n = 4406$), que luego replicaremos con datos reales en la sección práctica:

Cuadro 5.2: Resultados hipotéticos del modelo Poisson (visitas al médico)

Variable	$\hat{\beta}$	Error estándar	z	p-valor
(Intercepto)	1.028	0.065	15.82	<0.001
edad	0.019	0.004	4.75	<0.001
cronico	0.245	0.012	20.42	<0.001
seguro	0.306	0.043	7.12	<0.001
educacion	-0.028	0.005	-5.60	<0.001

Además, supongamos las siguientes log-verosimilitudes:

- Modelo Poisson completo: $\ell_{Poisson} = -12\,215.6$ (con 5 parámetros: intercepto + 4 variables).
- Modelo NB completo: $\ell_{NB} = -11\,478.3$ (con 6 parámetros: 5 + α).
- Modelo Poisson sin `cronico` ni `seguro`: $\ell_R = -12\,540.2$ (con 3 parámetros).
- Modelo solo con constante: $\ell_0 = -13\,890.1$ (con 1 parámetro).

5.6.1 Test de Wald (significación individual)

5.6.1.1 Planteamiento del contraste

El test de Wald evalúa si **una variable individual** contribuye significativamente al modelo.

Hipótesis:

- $H_0 : \beta_j = 0$ (la variable x_j **no** tiene efecto sobre el recuento esperado).
- $H_1 : \beta_j \neq 0$ (la variable x_j **sí** tiene efecto).

Estadístico:

$$W_j = \frac{\hat{\beta}_j}{\text{se}(\hat{\beta}_j)}$$

Distribución bajo H_0: $W_j \sim^a N(0,1)$ (equivalentemente, $W_j^2 \sim^a \chi_1^2$).

Regla de decisión (al nivel $\alpha = 0.05$): Rechazamos H_0 si $|W_j| > z_{0.025} = 1.96$. Equivalentemente, rechazamos si el p-valor < 0.05.

5.6.1.2 Ejemplo 1: ¿Es significativa la variable `cronico`?

Datos del problema: $\hat{\beta}_{\text{cronico}} = 0.245$, se$(\hat{\beta}_{\text{cronico}}) = 0.012$.

Paso 1. Planteamos las hipótesis:

- $H_0 : \beta_{\text{cronico}} = 0$ (las condiciones crónicas no afectan las visitas).
- $H_1 : \beta_{\text{cronico}} \neq 0$ (sí afectan).

Paso 2. Calculamos el estadístico:

$$W = \frac{0.245}{0.012} = 20.42$$

Paso 3. Comparamos con el valor crítico:

$$|20.42| > 1.96 \implies \text{Rechazamos } H_0$$

Paso 4. Conclusión: La variable `cronico` es **altamente significativa** ($p < 0.001$). Cada condición crónica adicional aumenta significativamente el número de visitas al médico.

5.6.1.3 Ejemplo 2: ¿Es significativa la variable `educacion`?

Datos: $\hat{\beta}_{\text{educ}} = -0.028$, se $= 0.005$.

$$W = \frac{-0.028}{0.005} = -5.60$$

$$|-5.60| > 1.96 \implies \text{Rechazamos } H_0$$

Conclusión: `educacion` es significativa ($p < 0.001$). El signo negativo indica que más años de educación se asocian con **menos** visitas al médico.

> **Nota importante:** El test de Wald evalúa variables **una a una**. Para evaluar si un **grupo de variables** es conjuntamente significativo, necesitamos el test de razón de verosimilitud.

5.6.2 Test de razón de verosimilitud (significación conjunta)

5.6.2.1 Planteamiento del contraste

El test LR compara un modelo **completo** (sin restricciones) con un modelo **reducido** (restringido) para evaluar si un grupo de variables contribuye significativamente.

Hipótesis:

- $H_0 : \beta_{j_1} = \beta_{j_2} = \cdots = \beta_{j_q} = 0$ (las q variables no aportan nada al modelo).
- H_1 : al menos uno de los $\beta_{j_k} \neq 0$ (al menos una variable es relevante).

Estadístico:

$$LR = 2\left[\ell(\widehat{\beta}_U) - \ell(\widehat{\beta}_R)\right]$$

donde ℓ_U es la log-verosimilitud del modelo completo y ℓ_R la del modelo reducido.

Distribución bajo H_0: $LR \sim^a \chi^2_q$, donde q es el número de restricciones (variables eliminadas).

Regla de decisión: Rechazamos H_0 si $LR > \chi^2_{q,\alpha}$, donde $\chi^2_{q,\alpha}$ es el valor crítico de la distribución chi-cuadrado con q grados de libertad al nivel α.

5.6.2.2 Ejemplo: ¿Son `cronico` y `seguro` conjuntamente significativas?

Datos del problema:

- Modelo completo (con `cronico` y `seguro`): $\ell_U = -12\,215.6$, $k_U = 5$ parámetros.
- Modelo reducido (sin `cronico` ni `seguro`): $\ell_R = -12\,540.2$, $k_R = 3$ parámetros.
- Número de restricciones: $q = k_U - k_R = 5 - 3 = 2$.

Paso 1. Planteamos las hipótesis:

- $H_0 : \beta_{\text{cronico}} = \beta_{\text{seguro}} = 0$.
- H_1 : al menos uno es distinto de cero.

Paso 2. Calculamos el estadístico LR:

$$LR = 2\left[(-12\,215.6) - (-12\,540.2)\right] = 2 \times 324.6 = 649.2$$

Paso 3. Buscamos el valor crítico $\chi^2_{2,0.05} = 5.991$:

$$649.2 > 5.991 \implies \text{Rechazamos } H_0$$

Paso 4. Conclusión: Las variables `cronico` y `seguro` son **conjuntamente muy significativas**. El estadístico (649.2) excede enormemente el valor crítico (5.99), lo que indica que su contribución al modelo es muy importante.

> **¿Cuándo usar LR en vez de Wald?** El test LR es preferible cuando se quiere evaluar la significación **conjunta** de varias variables. Para variables individuales, ambos tests dan resultados muy similares, pero el LR es más fiable en muestras pequeñas.

5.6.3 Test de sobredispersión: Poisson vs Binomial Negativo

5.6.3.1 Planteamiento del contraste

Este es uno de los tests más importantes en modelos de recuento. Evalúa si la **varianza de los datos excede la media** (sobredispersión), lo que invalidaría los errores estándar del modelo Poisson.

Hipótesis:

- $H_0 : \alpha = 0$ (equidispersión → el modelo **Poisson** es adecuado).
- $H_1 : \alpha > 0$ (sobredispersión → el modelo **Binomial Negativo** es necesario).

Recordemos que en el NB: $\text{Var}(y_i) = \lambda_i + \alpha\lambda_i^2$. Si $\alpha = 0$, la varianza es λ_i (Poisson).

5.6.3.2 Método 1: Test LR (Poisson vs NB)

Estadístico:

$$LR = 2\left[\ell_{NB} - \ell_{Poisson}\right]$$

Distribución bajo H_0: Aproximadamente χ^2_1 (un grado de libertad porque solo se restringe α).

5.6.3.3 Ejemplo de cálculo

Datos:

- $\ell_{Poisson} = -12\,215.6$
- $\ell_{NB} = -11\,478.3$

Paso 1. Calculamos:

$$LR = 2\left[(-11\,478.3) - (-12\,215.6)\right] = 2 \times 737.3 = 1\,474.6$$

Paso 2. Valor crítico $\chi^2_{1,0.05} = 3.841$:

$$1\,474.6 \gg 3.841 \implies \text{Rechazamos } H_0 \text{ rotundamente}$$

Paso 3. Conclusión: La sobredispersión es **masiva**. El modelo Poisson es completamente inadecuado para estos datos; el Binomial Negativo es muy superior.

5.6.3.4 Método 2: Estadístico de dispersión de Pearson

Una forma rápida y visual de detectar sobredispersión:

$$\text{Dispersión} = \frac{\sum_{i=1}^{n} \frac{(y_i - \hat{\lambda}_i)^2}{\hat{\lambda}_i}}{n-k}$$

Regla práctica:

- ≈ 1: equidispersión (Poisson OK).
- > 1.5: sobredispersión moderada.
- > 2: sobredispersión importante → usar NB o quasi-Poisson.

5.6.3.5 Método 3: Test de Cameron y Trivedi (1990)

Contrasta formalmente la equidispersión regresando una función de los residuos:

$$\frac{(y_i - \hat{\lambda}_i)^2 - y_i}{\hat{\lambda}_i} = \alpha_0 + \alpha_1 \hat{\lambda}_i + \varepsilon_i$$

- $H_0 : \alpha_1 = 0$ (equidispersión).
- $H_1 : \alpha_1 > 0$ (sobredispersión).

Se contrasta con un test t ordinario sobre $\hat{\alpha}_1$. En R: `dispersiontest(modelo_poisson)` del paquete `AER`.

5.6.4 Medidas de bondad de ajuste

En modelos de regresión lineal clásica, el coeficiente de determinación R^2 mide la proporción de variabilidad explicada por el modelo. Sin embargo, en modelos de recuento (Poisson, Binomial Negativo), **el R^2 clásico no es apropiado** por dos razones fundamentales:

1. **La función media condicional es no lineal**: $E[y_i|\mathbf{x}_i] = \exp(\mathbf{x}_i\beta)$, por lo que la descomposición $TSS = ESS + RSS$ no se mantiene.
2. **Heterocedasticidad inherente**: en Poisson, $\text{Var}(y_i) = \lambda_i = E[y_i]$; los residuos no son homocedásticos.

Por ello, se han desarrollado medidas alternativas de bondad de ajuste específicas para modelos de recuento, que presentamos a continuación de menor a mayor sofisticación.

5.6.4.1 Desviación (Deviance)

La **desviación** (deviance) es la medida fundamental de bondad de ajuste en modelos lineales generalizados. Compara el modelo estimado con el **modelo saturado** (aquel que tiene tantos parámetros como observaciones y ajusta perfectamente los datos).

5.6.4.1.1 Definición formal Para una observación individual i, la **contribución a la desviación** es:

$$d_i = 2\left[y_i \ln\left(\frac{y_i}{\hat{\lambda}_i}\right) - (y_i - \hat{\lambda}_i)\right]$$

donde por convención $0 \cdot \ln(0) = 0$. Nótese que $d_i \geq 0$ siempre, y $d_i = 0$ solo cuando $y_i = \hat{\lambda}_i$ (ajuste perfecto).

La **desviación total** (o deviance residual) del modelo es la suma:

$$D = \sum_{i=1}^{n} d_i = 2\sum_{i=1}^{n}\left[y_i \ln\left(\frac{y_i}{\hat{\lambda}_i}\right) - (y_i - \hat{\lambda}_i)\right]$$

Interpretación intuitiva: La desviación mide cuánto "se pierde" al usar el modelo estimado en lugar del modelo saturado. Es análoga a la suma de cuadrados residual (RSS) en regresión lineal, pero para modelos GLM.

5.6.4.1.2 Desviación nula y desviación residual

- **Desviación nula** (D_0): desviación del modelo que solo incluye la constante (sin variables explicativas). Mide la variabilidad total a explicar.
- **Desviación residual** (D): desviación del modelo completo con las k variables. Mide la variabilidad **no explicada** por el modelo.

La diferencia $D_0 - D$ mide cuánta variabilidad explican las variables incluidas.

5.6.4.1.3 Test de bondad de ajuste basado en la desviación Si el modelo Poisson es correcto, la desviación residual sigue **aproximadamente** una distribución chi-cuadrado:

$$D \sim \chi^2(n-k) \quad \text{(bajo } H_0\text{: modelo correctamente especificado)}$$

Contraste:

- H_0: El modelo se ajusta adecuadamente a los datos.
- H_1: El modelo no se ajusta bien (posible sobredispersión o mala especificación).
- **Criterio:** Rechazar H_0 si $D > \chi^2_{n-k,\alpha}$.

> **Precaución:** Este test tiene baja potencia en muestras pequeñas y es sensible a la presencia de muchos ceros. Un rechazo puede deberse a sobredispersión (no necesariamente a una mala elección de variables).

5.6.4.1.4 Ejemplo de cálculo manual Supongamos nuestro modelo Poisson con $n = 4{,}406$ observaciones y $k = 5$ parámetros.

Datos reportados por R:

- Desviación nula: $D_0 = 8{,}127.5$ con $n - 1 = 4{,}405$ grados de libertad.
- Desviación residual: $D = 6{,}531.2$ con $n - k = 4{,}401$ grados de libertad.

Test:

$$D = 6{,}531.2 \quad \text{vs} \quad \chi^2_{4401,0.05} \approx 4{,}401 + 2\sqrt{2 \times 4{,}401} \approx 4{,}538.8$$

$$6{,}531.2 \gg 4{,}538.8 \implies \text{Rechazamos } H_0$$

Conclusión: El modelo Poisson **no** se ajusta bien. La desviación residual es mucho mayor que los grados de libertad, lo cual indica **sobredispersión** (la varianza observada supera la predicha por Poisson). La razón $D/(n-k) = 6{,}531.2/4{,}401 = 1.484$ confirma que la varianza es un 48% mayor que la media.

> **Regla rápida:** Si $D/(n-k) \approx 1$, el modelo Poisson es adecuado. Si $D/(n-k) \gg 1$, hay sobredispersión y se debería considerar el modelo Binomial Negativo.

5.6.4.2 Estadístico χ^2 de Pearson

El estadístico chi-cuadrado de Pearson es la alternativa clásica a la desviación. Mientras que la desviación se basa en la log-verosimilitud, el estadístico de Pearson se basa directamente en la **diferencia entre valores observados y esperados**.

5.6.4.2.1 Definición

$$X^2 = \sum_{i=1}^{n} \frac{(y_i - \hat{\lambda}_i)^2}{\hat{\lambda}_i}$$

Este es el **estadístico clásico de Pearson**, idéntico conceptualmente al χ^2 usado en tablas de contingencia. Bajo H_0 (modelo correcto):

$$X^2 \sim \chi^2(n-k)$$

5.6.4.2.2 Relación con la desviación Ambas medidas convergen a la misma distribución asintóticamente, pero difieren en muestras finitas:

- La **desviación** pondera más las observaciones con y_i grande.
- El χ^2 **de Pearson** es más sensible a observaciones con $\hat{\lambda}_i$ pequeño (donde un residuo incluso moderado genera un cociente grande).

En la práctica, ambas suelen dar resultados similares. Los programas como R reportan la desviación por defecto, pero el χ^2 de Pearson se obtiene fácilmente:

En R, el estadístico se calcula con `sum(residuals(modelo, type = "pearson")^2)` y su p-valor con `pchisq(X2, df = modelo$df.residual, lower.tail = FALSE)`.

5.6.4.2.3 Ejemplo de cálculo manual Con $X^2 = 6{,}582.7$ y $n-k = 4{,}401$:

$$\frac{X^2}{n-k} = \frac{6{,}582.7}{4{,}401} = 1.495$$

Dado que $1.495 > 1$, se confirma la presencia de sobredispersión. Este valor es consistente con el obtenido vía desviación (1.484), lo cual es habitual.

5.6.4.3 Medidas de R^2 para modelos de recuento

Aunque el R^2 clásico no es aplicable, se han propuesto diversas adaptaciones. Presentamos tres, de menor a mayor sofisticación.

5.6.4.3.1 R^2 basado en residuos estandarizados Una primera aproximación, propuesta como extensión directa del R^2 lineal:

$$R^2_{res} = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{\lambda}_i)^2/\hat{\lambda}_i}{\sum_{i=1}^{n}(y_i - \bar{y})^2/\bar{y}}$$

Esta medida compara el ajuste del modelo completo (numerador) con el de un modelo que solo incluye la constante (denominador).

Ventajas: Intuitivo, análogo al R^2 clásico.

Limitaciones:

- Puede ser **negativo** (si el modelo ajusta peor que la media).
- Puede **aumentar** al eliminar variables relevantes.

5.6.4.3.2 Pseudo R^2 de McFadden

Es la medida más utilizada en la práctica:

$$R^2_{McF} = 1 - \frac{\ell(\hat{\beta})}{\ell(\hat{\beta}_0)}$$

donde $\ell(\hat{\beta})$ es la log-verosimilitud del modelo completo y $\ell(\hat{\beta}_0)$ es la del modelo solo con constante.

Interpretación: Proporción de la log-verosimilitud explicada por las variables del modelo. Está acotado superiormente por 1 (ajuste perfecto), pero **nunca alcanza 1** en la práctica, porque $\ell < 0$ siempre.

Ejemplo de cálculo:

Con $\ell(\hat{\beta}) = -11{,}478.3$ (NB completo) y $\ell(\hat{\beta}_0) = -13{,}890.1$ (solo constante):

$$R^2_{McF} = 1 - \frac{-11{,}478.3}{-13{,}890.1} = 1 - 0.8263 = 0.1737$$

Interpretación: El modelo explica aproximadamente un 17.4% de la variación en la log-verosimilitud. En modelos de recuento con datos microeconómicos, **valores entre 0.10 y 0.25 son habituales y aceptables**.

> **Referencia:** En regresión lineal, un $R^2 = 0.17$ se consideraría bajo. Pero en modelos de recuento, la heterogeneidad individual no observada hace que las predicciones puntuales sean intrínsecamente más difíciles, por lo que estos valores son normales y no indican un modelo deficiente.

5.6.4.3.3 R^2 de Cameron y Windmeijer (1993)

Cameron y Windmeijer propusieron una medida basada en la desviación que está **acotada entre 0 y 1**:

$$R^2_{Dev} = \frac{D_0 - D}{D_0^*}$$

donde:

- D_0: desviación del modelo nulo (solo constante).
- D: desviación del modelo completo.
- D_0^*: desviación máxima posible (mejora máxima sobre un ajuste perfecto).

Esta medida es equivalente al pseudo-R^2 reportado por muchos paquetes estadísticos y puede reescribirse como:

$$R^2_{Dev} = 1 - \frac{D}{D_0}$$

Ejemplo de cálculo:

Con $D_0 = 8{,}127.5$ y $D = 6{,}531.2$:

$$R^2_{Dev} = 1 - \frac{6{,}531.2}{8{,}127.5} = 1 - 0.8035 = 0.1965$$

El modelo reduce la desviación en un 19.7% respecto al modelo nulo.

Ventajas sobre McFadden: Está acotada entre 0 y 1 y aumenta monótonamente al añadir variables relevantes, lo que la hace más interpretable.

5.6.4.4 Criterio de Información de Akaike (AIC)

5.6.4.4.1 Fundamento teórico El AIC fue propuesto por Akaike (1973) basándose en la **divergencia de Kullback-Leibler (K-L)**, que mide la "distancia" entre la distribución verdadera (desconocida) de los datos y la distribución estimada por nuestro modelo.

Akaike demostró que un estimador asintóticamente insesgado de la divergencia K-L esperada es:

$$\text{AIC} = 2k - 2\ell(\widehat{\beta})$$

donde:

- k = número de parámetros estimados (incluida la constante).
- $\ell(\widehat{\beta})$ = log-verosimilitud evaluada en los estimadores de máxima verosimilitud.

5.6.4.4.2 Interpretación de los componentes El AIC equilibra dos objetivos contrapuestos:

- $-2\ell(\widehat{\beta})$**: Bondad de ajuste.** Cuanto mayor la verosimilitud, menor este término. Mide lo bien que el modelo se ajusta a los datos observados.
- $2k$**: Penalización por complejidad.** Cada parámetro adicional suma 2 al AIC. Previene el sobreajuste: un modelo con muchas variables puede ajustar bien los datos de entrenamiento pero predecir mal datos nuevos.

  Intuición: El AIC busca el modelo que mejor **predecirá** datos futuros generados por el mismo proceso, no el que mejor ajuste los datos actuales.

5.6.4.4.3 Ejemplo detallado de cálculo manual

Modelo Poisson ($k = 5$, $\ell = -12{,}215.6$):

$$\text{AIC}_{Poisson} = 2(5) - 2(-12{,}215.6) = 10 + 24{,}431.2 = 24{,}441.2$$

Desglose: penalización = 10 (por 5 parámetros), ajuste = 24,431.2 (peor ajuste → mayor valor).

Modelo Binomial Negativo ($k = 6$, $\ell = -11{,}478.3$):

$$\text{AIC}_{NB} = 2(6) - 2(-11{,}478.3) = 12 + 22{,}956.6 = 22{,}968.6$$

Desglose: penalización = 12 (un parámetro más, α), ajuste = 22,956.6 (mejor ajuste).

Comparación:

$$\Delta\text{AIC} = 24{,}441.2 - 22{,}968.6 = 1{,}472.6$$

Regla práctica de Burnham y Anderson (2002):

- $\Delta\text{AIC} < 2$: ambos modelos son igualmente plausibles.
- $2 < \Delta\text{AIC} < 7$: el modelo con menor AIC es moderadamente mejor.
- $\Delta\text{AIC} > 10$: el modelo con mayor AIC tiene **soporte prácticamente nulo**.

En nuestro ejemplo, $\Delta = 1{,}472.6 \gg 10$: el NB es **abrumadoramente** superior.

5.6.4.4.4 Limitaciones del AIC

1. **No tiene interpretación absoluta**: solo sirve para comparar modelos ajustados a los **mismos datos**.
2. **Tiende a seleccionar modelos complejos** en muestras grandes, porque la penalización $2k$ no crece con n.
3. **No indica si el modelo es "bueno"**: un modelo con el menor AIC puede seguir siendo inadecuado.

5.6.4.5 Criterio de Información Bayesiano (BIC)

5.6.4.5.1 Fundamento teórico

El BIC (también llamado criterio de Schwarz, 1978) surge de la **selección bayesiana de modelos**. Aproxima el logaritmo del factor de Bayes, que mide la evidencia relativa a favor de un modelo sobre otro.

$$\text{BIC} = k\ln(n) - 2\ell(\hat{\beta})$$

5.6.4.5.2 Diferencia clave con el AIC

La penalización del BIC es $k\ln(n)$ en lugar de $2k$. Puesto que $\ln(n) > 2$ cuando $n > 7$ (es decir, **casi siempre en la práctica**):

$$\text{Penalización BIC} = k\ln(n) > 2k = \text{Penalización AIC} \quad \text{para } n > 7$$

Esto significa que el BIC **penaliza más la complejidad** y tiende a seleccionar modelos más parsimoniosos (con menos variables) que el AIC.

5.6.4.5.3 Ejemplo detallado de cálculo manual

Con $n = 4{,}406$, $\ln(4{,}406) = 8.39$:

Modelo Poisson ($k = 5$):

$$\text{BIC}_{Poisson} = 5 \times 8.39 - 2(-12{,}215.6) = 41.95 + 24{,}431.2 = 24{,}473.2$$

Modelo NB ($k = 6$):

$$\text{BIC}_{NB} = 6 \times 8.39 - 2(-11{,}478.3) = 50.34 + 22{,}956.6 = 23{,}006.9$$

Comparación: $\Delta\text{BIC} = 24{,}473.2 - 23{,}006.9 = 1{,}466.3$

Escala de evidencia de Kass y Raftery (1995):

- $\Delta\text{BIC} < 2$: evidencia débil (apenas vale la pena mencionarlo).
- $2 < \Delta\text{BIC} < 6$: evidencia positiva.
- $6 < \Delta\text{BIC} < 10$: evidencia fuerte.
- $\Delta\text{BIC} > 10$: evidencia **muy fuerte**.

En nuestro ejemplo, $\Delta\text{BIC} = 1{,}466.3 \gg 10$: evidencia **abrumadora** a favor del NB.

5.6.4.5.4 ¿Cuándo usar AIC y cuándo BIC?

- **AIC**: Cuando el objetivo es **predicción**. El AIC selecciona el modelo que minimiza el error de predicción esperado.
- **BIC**: Cuando el objetivo es **identificar el modelo verdadero**. Si el verdadero modelo está entre los candidatos, el BIC lo selecciona con probabilidad $\to 1$ cuando $n \to \infty$ (propiedad de consistencia).
- **En la práctica**: Si ambos criterios coinciden, la decisión es clara. Si discrepan, el AIC suele preferir un modelo más complejo y el BIC uno más parsimonioso. En microeconometría, se reportan ambos.

5.6.4.6 Tabla resumen de medidas de bondad de ajuste

Cuadro 5.3: Resumen de medidas de bondad de ajuste para modelos de recuento

Medida	Fórmula	Uso principal	Ejemplo
Desviación residual (D)	$2\sum[y_i \cdot \ln(y_i/\hat{\lambda}_i) - (y_i - \hat{\lambda}_i)]$	Test GOF: $D \sim \chi^2(n-k)$	6.531,2 (ratio 1,48)
χ^2 de Pearson	$\sum(y_i - \hat{\lambda}_i)^2/\hat{\lambda}_i$	Test GOF: $X^2 \sim \chi^2(n-k)$	6.582,7 (ratio 1,50)
R^2 residual	$1-[\sum(y_i-\hat{\lambda}_i)^2/\hat{\lambda}_i]$ / $[\sum(y_i-\bar{y})^2/\bar{y}]$	Ajuste relativo (puede ser < 0)	—
R^2 McFadden	$1 - \ell(\hat{\beta})/\ell(\hat{\beta}_0)$	Proporción de ℓ explicada	0,174
R^2 Cameron-Windmeijer	$1 - D/D_0$	Ajuste relativo (0 a 1)	0,197
AIC	$2k - 2\ell$	Comparar modelos (menor = mejor)	22.968,6 (NB)
BIC	$k \cdot \ln(n) - 2\ell$	Comparar modelos (penaliza más)	23.006,9 (NB)

5.6.5 Procedimiento completo de comparación Poisson vs Binomial Negativo

En la práctica, la comparación de modelos sigue estos **cinco pasos**:

1. **Estimar el modelo Poisson** y calcular el estadístico de dispersión de Pearson. Si ≈ 1, Poisson puede ser suficiente; si > 1.5, hay indicios de sobredispersión.
2. **Estimar el modelo Binomial Negativo** con las mismas variables explicativas.
3. **Test LR formal**: Calcular $LR = 2(\ell_{NB} - \ell_{Poisson})$. Si $p < 0.05$, la sobredispersión es significativa.
4. **Comparar AIC y BIC**: El modelo con valores menores es preferido. Si la diferencia es grande ($\Delta > 10$), la evidencia es clara.
5. **Decisión**: Si los pasos 3 y 4 coinciden → la decisión es clara. Si discrepan (raro), priorizar el test LR para modelos anidados.

5.6.6 Tablas resumen

Los contrastes y medidas de diagnóstico para modelos de recuento se organizan en tres grupos: tests de significación, tests de sobredispersión y medidas de bondad de ajuste.

Cuadro 5.4: Tests de significación de variables

Test	H_0	Distribución	Criterio
Wald	$\beta_j = 0$	$z \sim N(0,1)$	Rechazar si $p < 0{,}05$
LR (conjunto)	$\beta_1 = \cdots = \beta_q = 0$	$\chi^2(q)$	Rechazar si $p < 0{,}05$

Cuadro 5.5: Tests de sobredispersión (Poisson vs Binomial Negativo)

Test	H_0	Criterio de decisión
LR: NB vs Poisson	$\alpha = 0$	$LR > 3{,}84 \Rightarrow$ NB
Dispersión de Pearson	Dispersión $= 1$	$> 1{,}5 \Rightarrow$ sobredispersión
Cameron-Trivedi	$\alpha_1 = 0$	$p < 0{,}05 \Rightarrow$ sobredispersión

Cuadro 5.6: Medidas de bondad de ajuste y comparación de modelos

Medida	Fórmula	Interpretación
AIC	$2k - 2\ell$	Menor es mejor
BIC	$k \cdot \ln(n) - 2\ell$	Menor es mejor (penaliza más)
Pseudo R^2 McFadden	$1 - \ell(\hat{\beta})/\ell(\hat{\beta}_0)$	Mayor es mejor (0,10–0,25 típico)

Consejo práctico: En un informe o trabajo, reporta siempre: (1) el test de Wald para cada variable individual (sale directamente del `summary()`), (2) el test LR para comparar Poisson vs NB, (3) AIC y BIC de ambos modelos, y (4) el pseudo R^2. Con estos cuatro elementos, el lector puede evaluar completamente la especificación del modelo.

5.7 Extensiones y temas avanzados

5.7.1 Sobredispersión: detección y corrección

5.7.1.1 Diagnósticos de sobredispersión

1. Estadístico de dispersión de Pearson:

$$\text{Disp} = \frac{\sum_i (y_i - \hat{\lambda}_i)^2 / \hat{\lambda}_i}{n-k}$$

Si $> 1 \rightarrow$ sobredispersión. Si $\gg 1 \rightarrow$ importante.

2. Deviance/grados de libertad:

$$\text{Deviance Ratio} = \frac{D}{n-k}$$

Similares resultados (cercano a 1 → ajuste bueno).

5.7.1.2 Correcciones de la sobredispersión

Cuando se detecta sobredispersión, existen tres estrategias principales. La primera y más recomendada es estimar un **modelo Binomial Negativo**, que incorpora un parámetro de dispersión α que permite que la varianza exceda la media. Es el enfoque estándar en la literatura econométrica y se estima en R con `MASS::glm.nb()`.

La segunda opción es el modelo **Quasi-Poisson**, que mantiene la estructura del modelo Poisson pero ajusta los errores estándar multiplicándolos por un factor de dispersión estimado a partir de los datos. No requiere especificar una nueva distribución, sino que utiliza un enfoque de cuasi-verosimilitud. En R se estima con `family = quasipoisson`.

La tercera opción consiste en mantener el modelo Poisson pero calcular **errores estándar robustos** (tipo sandwich), que son válidos incluso cuando la varianza no coincide con la media. En R se obtienen combinando `coeftest()` del paquete `lmtest` con `vcovHC()` del paquete `sandwich`.

5.7.2 Datos con exceso de ceros

En muchos contextos económicos, los datos de recuento presentan una proporción de observaciones con valor cero considerablemente mayor de la que predeciría un modelo Poisson o Binomial Negativo. Este fenómeno se denomina **exceso de ceros** (zero inflation) y aparece cuando existen dos procesos generadores de datos superpuestos: uno que determina si el evento puede ocurrir en absoluto, y otro que gobierna cuántas veces ocurre condicionado a que sea posible. Por ejemplo, en el gasto en ocio, algunas personas nunca gastan (cero estructural, por preferencias o restricciones), mientras que las que sí gastan presentan un recuento variable. De forma similar, en el número

de hijos, hay parejas que han decidido no tener hijos (cero deliberado) frente a las que simplemente aún no los han tenido (cero circunstancial).

Para modelar estos datos existen dos familias de modelos. Los modelos **Zero-Inflated** (ZIP para Poisson, ZINB para Binomial Negativo) asumen que los ceros provienen de dos fuentes: una masa puntual en cero (modelada con un Logit) y el proceso de recuento habitual. Los modelos **Hurdle** adoptan un enfoque secuencial: primero modelan si $y > 0$ o no (con un modelo binario), y luego, condicionado a $y > 0$, modelan el recuento con una distribución truncada en cero. Ambos enfoques se implementan en R con el paquete `pscl`.

5.7.3 Variables de offset

Para modelar **tasas** en lugar de recuentos absolutos, usamos variables de offset.

Ejemplo: Si y_i son accidentes y queremos ajustar por horas trabajadas:

$$\ln(\lambda_i/\text{horas}_i) = \mathbf{x}_i\beta$$

equivalentemente:

$$\ln(\lambda_i) = \ln(\text{horas}_i) + \mathbf{x}_i\beta$$

En R: `glm(..., offset = log(horas), ...)`

5.8 Resumen: lo esencial en 10 puntos

1. Los **datos de recuento** toman valores enteros no negativos ($y \in \{0, 1, 2, ...\}$). Ejemplos: visitas al médico, patentes, accidentes laborales.
2. La **distribución de Poisson** es el punto de partida natural. Su propiedad fundamental es la **equidispersión**: $E[Y] = \text{Var}(Y) = \lambda$.
3. El **modelo de regresión de Poisson** especifica $\ln(\lambda_i) = \mathbf{x}_i\beta$. La función exponencial garantiza que $\lambda_i > 0$ siempre.
4. Los coeficientes se interpretan como **semi-elasticidades**: un cambio de 1 unidad en x_j multiplica la media esperada por e^{β_j}. Esto equivale a un cambio porcentual de $(e^{\beta_j} - 1) \times 100\%$.
5. El **efecto marginal** no es constante: $\partial E[y]/\partial x_j = \beta_j \cdot \lambda_i$. Depende del nivel de λ_i.
6. En datos reales, la varianza frecuentemente **excede la media** (sobredispersión). Si se ignora, los errores estándar del Poisson son demasiado pequeños y se generan falsos positivos.
7. El **modelo Binomial Negativo** corrige la sobredispersión añadiendo un parámetro de dispersión α: $\text{Var}(y_i) = \lambda_i + \alpha\lambda_i^2$. Cuando $\alpha = 0$, se recupera el Poisson.
8. El **test LR de sobredispersión** compara Poisson con NB: $LR = 2(\ell_{NB} - \ell_{Poisson}) \sim \chi^2_1$. Si se rechaza H_0, el NB es preferible.
9. La bondad de ajuste se evalúa con la **desviación** ($D/(n-k) \approx 1$ indica buen ajuste), el **pseudo-R^2 de McFadden** (0.10–0.25 típico en recuento) y los criterios **AIC** y **BIC** (menor es mejor).
10. Para datos con **exceso de ceros**, se utilizan modelos Zero-Inflated (ZIP/ZINB) o modelos Hurdle, que distinguen entre ceros estructurales y ceros del proceso de recuento.

5.9 Funciones esenciales en R

5.9.1 Estimación de modelos

- `glm(y ~ x1 + x2, family = poisson(link = "log"), data = datos)` — modelo de regresión Poisson.
- `MASS::glm.nb(y ~ x1 + x2, data = datos)` — modelo Binomial Negativo (estima α automáticamente).
- `glm(..., family = quasipoisson)` — modelo Quasi-Poisson (corrige errores estándar por sobredispersión).

5.9.2 Extracción de resultados

- `summary(modelo)` — tabla de coeficientes, errores estándar, z-valores y p-valores.
- `coef(modelo)` — vector de coeficientes $\widehat{\beta}$.
- `exp(coef(modelo))` — coeficientes exponenciados (tasas de incidencia, IRR).
- `confint(modelo)` — intervalos de confianza.
- `vcov(modelo)` — matriz de varianzas-covarianzas.

5.9.3 Bondad de ajuste y comparación

- `logLik(modelo)` — log-verosimilitud.
- `AIC(modelo)`, `BIC(modelo)` — criterios de información.
- `deviance(modelo)` — desviación residual.
- `modelo$df.residual` — grados de libertad residuales.
- `residuals(modelo, type = "pearson")` — residuos de Pearson (para el estadístico χ^2).
- `residuals(modelo, type = "deviance")` — residuos de la desviación.

5.9.4 Test de razón de verosimilitud (manual)

- `lr <- 2 * (logLik(m_completo) - logLik(m_reducido))` — estadístico LR.
- `pchisq(lr, df = diferencia_parametros, lower.tail = FALSE)` — p-valor.

5.9.5 Predicción

- `predict(modelo, newdata = df, type = "response")` — predicción del valor esperado $\widehat{\lambda}$.
- `predict(modelo, newdata = df, type = "link")` — predicción del predictor lineal $\mathbf{x}\widehat{\beta}$.

5.9.6 Modelos con exceso de ceros

- `pscl::zeroinfl(y ~ x1 + x2 | z1 + z2, dist = "poisson", data = datos)` — Zero-Inflated Poisson.
- `pscl::zeroinfl(..., dist = "negbin")` — Zero-Inflated Binomial Negativo.
- `pscl::hurdle(y ~ x1 + x2, dist = "poisson", data = datos)` — modelo Hurdle.

5.9.7 Offset (tasas)

- `glm(y ~ x1 + x2, family = poisson, offset = log(exposicion), data = datos)` — modelo para tasas.

Código R del capítulo

El script completo de este capítulo (`T04_mECO_Script_Recuento.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Capítulo 6

Datos de Panel

6.1 Introducción: ¿por qué datos de panel?

En los temas anteriores hemos trabajado con datos de **corte transversal**: una única observación por individuo en un momento determinado del tiempo. Este capítulo da un paso fundamental al incorporar la **dimensión temporal**: los datos de panel (también llamados datos longitudinales) contienen observaciones de los mismos n individuos (personas, empresas, países) a lo largo de T períodos de tiempo.

Esta estructura aporta ventajas decisivas frente al corte transversal. La más importante es la capacidad de **controlar la heterogeneidad no observada**. En muchas aplicaciones económicas, existen características individuales que afectan al comportamiento pero que no podemos medir directamente: la habilidad innata de un trabajador, la cultura organizativa de una empresa, la calidad institucional de un país. Si estas características están correlacionadas con las variables explicativas, la estimación por MCO en corte transversal produce resultados sesgados e inconsistentes. Los datos de panel permiten resolver este problema explotando la variación temporal de cada individuo.

Además, al combinar la variación *entre* individuos (variación *between*) con la variación *dentro* de cada individuo a lo largo del tiempo (variación *within*), los datos de panel proporcionan más información, mayor variabilidad y, en consecuencia, estimadores más precisos. También permiten estudiar efectos dinámicos: cómo cambian las variables de un individuo a lo largo del tiempo.

El modelo econométrico que desarrollaremos en este capítulo es:

$$y_{it} = \alpha_i + \mathbf{x}_{it}'\beta + \varepsilon_{it}$$

donde α_i es un efecto individual que captura la heterogeneidad no observada. La pregunta central del tema es **cómo tratar** α_i: si como un parámetro fijo a estimar (efectos fijos) o como una variable aleatoria (efectos aleatorios). Esta elección determina el estimador apropiado y condiciona toda la inferencia posterior.

6.2 Conceptos básicos

6.2.1 Estructura de los datos

Un conjunto de datos de panel tiene dos índices. El primero, $i = 1, \dots, n$, identifica al **individuo** (persona, empresa, país, región). El segundo, $t = 1, \dots, T_i$, identifica el **período** de tiempo (año, trimestre, mes). Cada observación se denota $(y_{it}, \mathbf{x}_{it})$ y contiene tanto la variable dependiente como las variables explicativas del individuo i en el período t. El número total de observaciones es $N = \sum_{i=1}^{n} T_i$.

6.2.2 Panel corto y panel largo

En función de la relación entre n y T, los paneles se clasifican en dos categorías. Un **panel corto** (o micropanel) tiene muchos individuos observados durante pocos períodos (n grande, T pequeño). Es la estructura habitual en microeconometría: por ejemplo, 5.000 trabajadores observados durante 5 años. Un **panel largo** (o macropanel) presenta la situación inversa: pocos individuos con muchos períodos (n pequeño, T grande). Es típico de la macroeconometría: por ejemplo, 30 países observados durante 50 años.

En este curso nos centramos en **paneles cortos**, donde las propiedades asintóticas de los estimadores se derivan haciendo $n \to \infty$ con T fijo.

6.2.3 Panel balanceado y no balanceado

Un panel es **balanceado** cuando todos los individuos se observan exactamente en los mismos T períodos, de modo que el número total de observaciones es $n \times T$. Un panel es **no balanceado** cuando algunos individuos tienen más observaciones que otros, habitualmente porque abandonan la muestra antes del final del estudio (fenómeno conocido como **atrición**). Los estimadores de panel se adaptan sin dificultad a paneles no balanceados, pero la atrición puede introducir sesgo de selección si la salida de la muestra está relacionada con la variable dependiente.

6.2.4 Descomposición de la variación: within, between y overall

Esta descomposición es fundamental para comprender qué información explotan los distintos estimadores y constituye una de las ideas más importantes del análisis de datos de panel.

Para cualquier variable x_{it}, podemos escribir:

$$x_{it} = \underbrace{\bar{x}_i}_{\text{componente between}} + \underbrace{(x_{it} - \bar{x}_i)}_{\text{componente within}}$$

donde $\bar{x}_i = \frac{1}{T}\sum_{t=1}^{T} x_{it}$ es la media temporal del individuo i.

La **variación between** mide las diferencias entre las medias de los distintos individuos: ¿ganan más las empresas grandes que las pequeñas? La **variación within** mide los cambios a lo largo del tiempo dentro de cada individuo: ¿ha aumentado la facturación de esta empresa concreta respecto a su propia media? La **variación overall** es la variación total, que combina ambas fuentes.

Cuadro 6.1: Descomposición within/between: tres empresas, tres años

Empresa	Año	Ingresos (x_{it})	Media ($\bar{x}_i$)	Within ($x_{it} - \bar{x}_i$)
A	2021	100	105	-5
A	2022	110	105	5
A	2023	105	105	0
B	2021	200	210	-10
B	2022	210	210	0
B	2023	220	210	10
C	2021	150	150	0
C	2022	140	150	-10
C	2023	160	150	10

En este ejemplo, la variación between se aprecia en las diferencias entre medias (105, 210, 150): las empresas tienen niveles de ingresos muy distintos. La variación within se aprecia en la columna derecha: la empresa A oscila $\{-5, +5, 0\}$ alrededor de su media de 105, mientras que la empresa C oscila $\{-10, +10, 0\}$ con mayor amplitud.

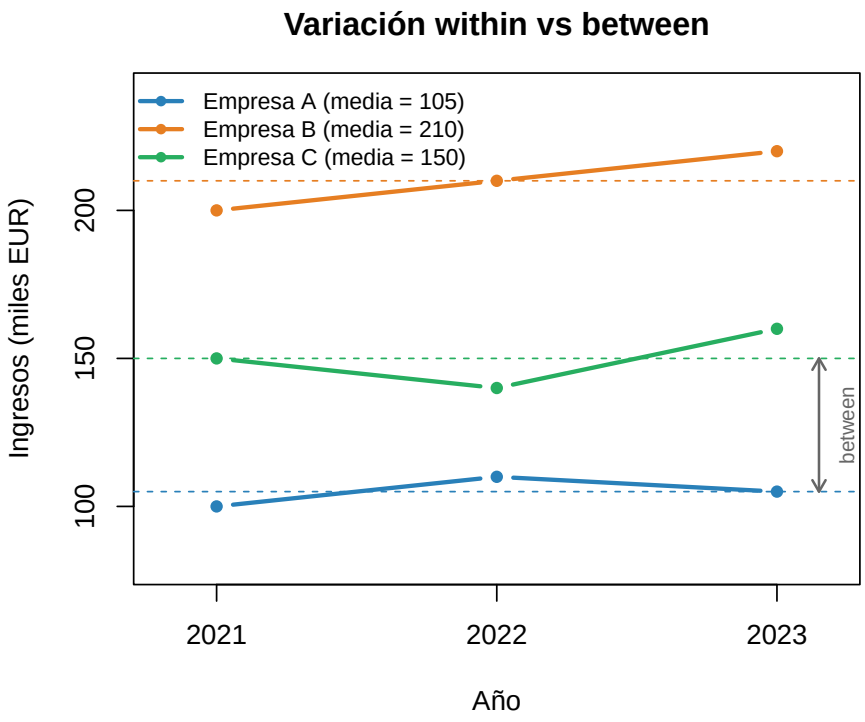

Figura 6.1: Descomposición visual: la distancia entre las líneas discontinuas es la variación between; las oscilaciones de cada línea alrededor de su media son la variación within.

Esta descomposición tiene implicaciones directas para la estimación. El estimador de **efectos fijos** (within) utiliza exclusivamente la variación within, eliminando las diferencias entre individuos. El estimador **between** utiliza solo las medias individuales. El estimador de **efectos aleatorios** combina ambas fuentes de forma óptima bajo ciertos supuestos.

6.3 El modelo general de datos de panel

6.3.1 Especificación

El modelo lineal de datos de panel se formula como:

$$y_{it} = \alpha_i + \mathbf{x}'_{it}\beta + \varepsilon_{it}, \qquad i = 1, \dots, n; \quad t = 1, \dots, T$$

donde:

- y_{it} es la variable dependiente del individuo i en el período t.
- $\mathbf{x}_{it}$ es un vector $k \times 1$ de variables explicativas que varían tanto entre individuos como a lo largo del tiempo.
- β es el vector de coeficientes de interés, común a todos los individuos y períodos.
- α_i es el **efecto individual** no observado, constante en el tiempo para cada individuo.
- ε_{it} es la perturbación idiosincrática, con $E[\varepsilon_{it}] = 0$ y $\text{Var}(\varepsilon_{it}) = \sigma^2_\varepsilon$.

El efecto individual α_i captura todas las características del individuo i que son constantes en el tiempo y que no están incluidas en $\mathbf{x}_{it}$: la habilidad innata de un trabajador, la localización geográfica de una empresa, la cultura institucional de un país. Es la pieza central del análisis de panel.

6.3.2 ¿Efectos fijos o efectos aleatorios?

La distinción fundamental del análisis de panel reside en cómo se trata el efecto individual α_i. Existen dos enfoques.

En el enfoque de **efectos fijos** (EF), se trata α_i como un parámetro desconocido a estimar (o, de forma equivalente, a eliminar mediante transformación). No se hace ningún supuesto sobre la relación entre α_i y las variables explicativas $\mathbf{x}_{it}$: se permite que estén correlacionados. Esta es la opción conservadora y robusta.

En el enfoque de **efectos aleatorios** (EA), se trata α_i como una variable aleatoria extraída de una distribución con media cero y varianza σ^2_α. El supuesto clave es que α_i **no está correlacionado** con las variables explicativas: $E[\alpha_i | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}] = 0$. Esta condición es fuerte y, si se viola, el estimador de efectos aleatorios es inconsistente.

La elección entre ambos enfoques se resuelve empíricamente con el **test de Hausman**, que se desarrolla más adelante.

6.4 Estimador Pooled OLS

6.4.1 Concepto

El estimador Pooled OLS (MCO agrupado) es el enfoque más sencillo: **ignora la estructura de panel** y trata todas las nT observaciones como si fueran un único corte transversal. El modelo que estima es:

$$y_{it} = \alpha + \mathbf{x}_{it}'\beta + u_{it}$$

donde $u_{it} = \alpha_i + \varepsilon_{it}$ es un error compuesto que incluye tanto el efecto individual como la perturbación idiosincrática.

6.4.2 Cuándo es válido

Pooled OLS produce estimaciones consistentes de β en dos situaciones. La primera es que no exista heterogeneidad individual ($\alpha_i = \alpha$ para todo i), de modo que los individuos son homogéneos y el panel se comporta como un corte transversal grande. La segunda es que el efecto individual exista pero sea estrictamente independiente de las variables explicativas ($\text{Cov}(\alpha_i, \mathbf{x}_{it}) = 0$), que es el supuesto de efectos aleatorios.

6.4.3 El problema fundamental

Si el efecto individual α_i está correlacionado con alguna de las variables explicativas —lo cual es frecuente en la práctica —, Pooled OLS es **inconsistente**. El error compuesto $u_{it} = \alpha_i + \varepsilon_{it}$ queda correlacionado con $\mathbf{x}_{it}$, violando la exogeneidad estricta de MCO. La consecuencia es un sesgo por variable omitida: α_i actúa como una variable relevante no incluida en el modelo.

Además, incluso cuando Pooled OLS es consistente, los errores estándar clásicos son **incorrectos** porque el error compuesto u_{it} presenta autocorrelación dentro de cada individuo (el componente α_i es común a todos los períodos de un mismo individuo). Por esta razón, siempre que se reporte un modelo Pooled OLS en datos de panel, deben utilizarse **errores estándar agrupados** (*clustered*) por individuo.

6.5 Modelo de efectos fijos (estimador within)

6.5.1 Intuición

La idea del estimador de efectos fijos es elegante en su sencillez: si el efecto individual α_i contamina la estimación porque es constante en el tiempo y está correlacionado con los regresores, la solución es **eliminarlo**. Para ello se aplica la **transformación within**, que consiste en restar a cada observación la media temporal del individuo:

$$y_{it} - \bar{y}_i = (\mathbf{x}_{it} - \bar{\mathbf{x}}_i)'\beta + (\varepsilon_{it} - \bar{\varepsilon}_i)$$

Al restar las medias, el efecto individual α_i desaparece de la ecuación (porque $\alpha_i - \alpha_i = 0$). Las variables transformadas se denotan con tilde: $\tilde{y}_{it} = y_{it} - \bar{y}_i$, $\tilde{\mathbf{x}}_{it} = \mathbf{x}_{it} - \bar{\mathbf{x}}_i$. El modelo transformado es:

$$\tilde{y}_{it} = \tilde{\mathbf{x}}'_{it}\beta + \tilde{\varepsilon}_{it}$$

El estimador de efectos fijos es simplemente MCO aplicado a estos datos transformados:

$$\hat{\beta}_{EF} = \left(\sum_{i=1}^{n} \sum_{t=1}^{T} \tilde{\mathbf{x}}_{it} \tilde{\mathbf{x}}'_{it} \right)^{-1} \left(\sum_{i=1}^{n} \sum_{t=1}^{T} \tilde{\mathbf{x}}_{it} \tilde{y}_{it} \right)$$

6.5.2 Ejemplo numérico paso a paso

Para comprender la mecánica del estimador, consideremos un panel mínimo con 2 individuos y 3 períodos. El modelo es $y_{it} = \alpha_i + \beta x_{it} + \varepsilon_{it}$.

Cuadro 6.2: Ejemplo numérico: transformación within con 2 individuos y 3 períodos

i	t	y_{it}	x_{it}	$\bar{y}_i$	$\bar{x}_i$	$\tilde{y}_{it}$	$\tilde{x}_{it}$
1	1	10	2	12	3	-2	-1
1	2	12	3	12	3	0	0
1	3	14	4	12	3	2	1
2	1	20	5	22	6	-2	-1
2	2	22	6	22	6	0	0
2	3	24	7	22	6	2	1

Paso 1. Calculamos las medias temporales: $\bar{y}_1 = (10 + 12 + 14)/3 = 12$, $\bar{x}_1 = (2 + 3 + 4)/3 = 3$; $\bar{y}_2 = 22$, $\bar{x}_2 = 6$.

Paso 2. Restamos las medias (transformación within): $\tilde{y}_{11} = 10 - 12 = -2$, $\tilde{x}_{11} = 2 - 3 = -1$, etc.

Paso 3. Estimamos β por MCO sobre los datos transformados:

$$\hat{\beta}_{EF} = \frac{\sum \tilde{x}_{it}\tilde{y}_{it}}{\sum \tilde{x}_{it}^2} = \frac{(-1)(-2) + (0)(0) + (1)(2) + (-1)(-2) + (0)(0) + (1)(2)}{1 + 0 + 1 + 1 + 0 + 1} = \frac{8}{4} = 2$$

El efecto estimado es $\hat{\beta}_{EF} = 2$: cada unidad adicional de x se asocia con un aumento de 2 unidades en y, una vez controlada la heterogeneidad individual. Obsérvese que los efectos individuales (α_1 y α_2) no aparecen en el cálculo: han sido eliminados por la transformación.

6.5.3 Propiedades

El estimador de efectos fijos es **consistente** independientemente de que α_i esté o no correlacionado con $\mathbf{x}_{it}$. Esta robustez es su gran fortaleza y la razón por la que es la opción por defecto en microeconometría aplicada.

Sin embargo, el estimador de efectos fijos tiene una **limitación importante**: no puede identificar el efecto de variables que no varían en el tiempo para cada individuo (sexo, raza, región de nacimiento, sector de actividad si es constante). Esto se debe a que la transformación within elimina todo lo que es constante en t: si z_i no varía en el tiempo, entonces $\tilde{z}_{it} = z_i - z_i = 0$, y la variable desaparece de la regresión transformada.

6.5.4 Equivalencia con variables dummy (LSDV)

Existe una forma equivalente de obtener el estimador de efectos fijos: incluir una variable dummy para cada individuo en la regresión original. Este enfoque se denomina LSDV (*Least Squares Dummy Variables*):

$$y_{it} = \sum_{j=1}^{n} \alpha_j d_{ij} + \mathbf{x}'_{it}\beta + \varepsilon_{it}$$

Ambos métodos producen exactamente el mismo $\hat{\beta}$. La ventaja de LSDV es que además estima los efectos individuales $\hat{\alpha}_i$. Su inconveniente es que, con muchos individuos, requiere estimar un número elevado de parámetros (uno por individuo), lo que es computacionalmente costoso.

6.5.5 El R^2 en datos de panel

En datos de panel existen tres medidas de R^2 que corresponden a las tres fuentes de variación. El R^2 within mide qué proporción de la variación temporal (within) de y explica el modelo. El R^2 between mide la capacidad del modelo para explicar las

diferencias entre medias individuales. El R^2 overall es una medida global de ajuste. El estimador de efectos fijos maximiza el R^2 within.

6.6 Estimador en primeras diferencias

Una alternativa al estimador within para eliminar el efecto individual α_i consiste en tomar **primeras diferencias** de la ecuación original:

$$y_{it} - y_{i,t-1} = (\mathbf{x}_{it} - \mathbf{x}_{i,t-1})'\beta + (\varepsilon_{it} - \varepsilon_{i,t-1})$$

$$\Delta y_{it} = \Delta \mathbf{x}'_{it}\beta + \Delta\varepsilon_{it}$$

Al restar la observación del período anterior, el efecto individual α_i desaparece (porque $\alpha_i - \alpha_i = 0$), de forma análoga a la transformación within. La diferencia es que aquí se resta el período previo, no la media temporal.

Cuando el panel tiene solo dos períodos ($T = 2$), los estimadores de primeras diferencias y de efectos fijos son **idénticos**. Cuando $T > 2$ y los errores son independientes e idénticamente distribuidos, el estimador within es más eficiente que primeras diferencias. Sin embargo, si se sospecha que los errores siguen un paseo aleatorio, primeras diferencias puede ser preferible porque produce errores $\Delta\varepsilon_{it}$ que no están autocorrelacionados.

6.7 Modelo de efectos aleatorios (GLS)

6.7.1 El supuesto clave

El modelo de efectos aleatorios trata α_i como una variable aleatoria con $E[\alpha_i] = 0$ y $\text{Var}(\alpha_i) = \sigma_\alpha^2$. El supuesto fundamental es la **ausencia de correlación** entre el efecto individual y las variables explicativas:

$$E[\alpha_i | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}] = 0$$

Este supuesto es fuerte. Significa que la heterogeneidad no observada no está relacionada con ninguna de las variables del modelo. En la práctica, esta condición se viola con frecuencia: por ejemplo, la habilidad innata (no observada) está correlacionada con la educación (observada).

6.7.2 La transformación cuasi-within

El estimador de efectos aleatorios se obtiene mediante una transformación que resta una **fracción** θ de la media individual, en lugar de restarla completamente como en efectos fijos:

$$y_{it} - \theta \bar{y}_i = (1 - \theta)\alpha + (\mathbf{x}_{it} - \theta \bar{\mathbf{x}}_i)'\beta + \text{error transformado}$$

El parámetro θ se calcula a partir de las varianzas de los dos componentes del error:

$$\theta = 1 - \sqrt{\frac{\sigma_\varepsilon^2}{\sigma_\varepsilon^2 + T\sigma_\alpha^2}}$$

La interpretación de θ es reveladora. Cuando σ_α^2 es muy grande (mucha heterogeneidad individual), θ se acerca a 1 y el estimador de efectos aleatorios converge al de efectos fijos (se resta casi toda la media). Cuando σ_α^2 es muy pequeña (poca heterogeneidad), θ se acerca a 0 y el estimador converge a Pooled OLS. El estimador de efectos aleatorios es, por tanto, un **promedio ponderado** entre efectos fijos y Pooled OLS, donde los pesos dependen de la importancia relativa de la heterogeneidad individual.

6.7.3 Ventajas e inconvenientes

La ventaja principal del estimador de efectos aleatorios es que, a diferencia del estimador within, **puede estimar el efecto de variables invariantes en el tiempo** (sexo, región, sector). Esto se debe a que la transformación no elimina completamente la media individual.

El inconveniente es que, si el supuesto de no correlación entre α_i y $\mathbf{x}_{it}$ no se cumple,

el estimador es **inconsistente**. En la práctica, cuando hay duda, la opción segura es siempre efectos fijos.

6.8 Test de Hausman: ¿efectos fijos o aleatorios?

6.8.1 Lógica del test

El test de Hausman (1978) proporciona un criterio formal para elegir entre efectos fijos y efectos aleatorios. Su lógica es la siguiente.

Bajo la hipótesis nula (H_0: el supuesto de efectos aleatorios es correcto, es decir, α_i no está correlacionado con $\mathbf{x}_{it}$), ambos estimadores — EF y EA — son consistentes. El de efectos aleatorios es, además, más eficiente. Bajo la hipótesis alternativa (H_1: el supuesto se viola), solo el estimador de efectos fijos sigue siendo consistente; el de efectos aleatorios no.

Si ambos estimadores son consistentes, deberían producir resultados similares. Si difieren significativamente, es evidencia de que α_i está correlacionado con los regresores, lo que invalida el estimador de efectos aleatorios.

6.8.2 El estadístico

El estadístico de Hausman mide la distancia entre ambos estimadores, ponderada por la diferencia de sus matrices de varianzas:

$$H = (\hat{\beta}_{EF} - \hat{\beta}_{EA})' \left[\widehat{\text{Var}}(\hat{\beta}_{EF}) - \widehat{\text{Var}}(\hat{\beta}_{EA})\right]^{-1} (\hat{\beta}_{EF} - \hat{\beta}_{EA})$$

Bajo H_0, el estadístico sigue asintóticamente una distribución χ^2 con k grados de libertad, donde k es el número de coeficientes comparados (sin incluir la constante ni los efectos individuales).

6.8.3 Regla de decisión

La regla de decisión es directa:

- Si el p-valor del test es **inferior a 0.05**, se rechaza H_0: hay evidencia de correlación entre α_i y $\mathbf{x}_{it}$, y debe utilizarse el estimador de **efectos fijos**.
- Si el p-valor es **superior a 0.05**, no se rechaza H_0: el estimador de **efectos aleatorios** es adecuado (y preferible por ser más eficiente).

6.8.4 Ejemplo numérico

Supongamos que estimamos un modelo de salarios con datos de panel y obtenemos:

$$\hat{\beta}_{EF}^{\text{educación}} = 0.065 \qquad \hat{\beta}_{EA}^{\text{educación}} = 0.092$$

Los coeficientes difieren considerablemente. El test de Hausman arroja $H = 18.7$ con $k = 4$ grados de libertad, lo que corresponde a un p-valor de 0.0009. Se rechaza H_0 con contundencia: la habilidad no observada (α_i) está correlacionada con la educación, y

debe utilizarse el estimador de efectos fijos.

En R, el test se calcula con `phtest(modelo_fe, modelo_re)` del paquete `plm`.

6.9 Diagnóstico en datos de panel

Una vez seleccionado el estimador apropiado, es necesario verificar que los supuestos del modelo se cumplen. Los diagnósticos en datos de panel se organizan en torno a cuatro cuestiones.

6.9.1 ¿Hay efectos individuales? (Test F)

Antes de aplicar efectos fijos, conviene confirmar que la heterogeneidad individual existe. El **test F de efectos individuales** contrasta:

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_n \qquad \text{(no hay heterogeneidad; Pooled OLS es suficiente)}$$

Si se rechaza H_0, los efectos individuales son significativos y Pooled OLS es inadecuado. En R se calcula con `pFtest(modelo_fe, modelo_pooled)`.

6.9.2 ¿Hay efectos aleatorios? (Test de Breusch-Pagan)

De forma análoga, el **test LM de Breusch-Pagan** contrasta si la varianza del efecto individual es significativamente distinta de cero:

$$H_0 : \sigma_\alpha^2 = 0 \qquad \text{(no hay efectos aleatorios; Pooled OLS es suficiente)}$$

En R se calcula con `plmtest(modelo_pooled, type = "bp")`.

6.9.3 ¿Hay autocorrelación serial?

El **test de Wooldridge** evalúa si los errores idiosincrásticos ε_{it} están autocorrelacionados a lo largo del tiempo. La autocorrelación serial invalida los errores estándar clásicos y requiere correcciones (errores robustos agrupados o estimadores específicos).

$$H_0 : \text{no hay autocorrelación de primer orden en } \varepsilon_{it}$$

En R: `pwartest(modelo_fe)`.

6.9.4 ¿Hay heterocedasticidad?

La heterocedasticidad en datos de panel puede manifestarse de dos formas: varianzas distintas entre individuos ($\sigma_i^2 \neq \sigma_j^2$) o varianzas que dependen de las variables explicativas. El test de **Breusch-Pagan** adaptado a panel detecta estas situaciones.

6.9.5 Errores robustos agrupados

En la práctica, la recomendación estándar es reportar siempre **errores estándar agrupados** (*clustered*) por individuo, que corrigen simultáneamente por heterocedasticidad

y por autocorrelación dentro de cada individuo:

En R: `coeftest(modelo, vcov = vcovHC(modelo, type = "HC1", cluster = "group"))`

6.10 Ejemplo práctico completo en R

6.10.1 Los datos

Utilizamos el dataset clásico de **Grunfeld** (1958), que contiene datos de inversión de 10 grandes empresas estadounidenses observadas durante 20 años (1935-1954). Las variables son:

- `inv`: inversión bruta de la empresa (variable dependiente).
- `value`: valor de mercado de la empresa.
- `capital`: stock de capital (planta y equipos).

El modelo que estimaremos es:

$$\text{inv}_{it} = \alpha_i + \beta_1 \text{ value}_{it} + \beta_2 \text{ capital}_{it} + \varepsilon_{it}$$

Cuadro 6.3: Estadísticos descriptivos del dataset Grunfeld (n=10 empresas, T=20 años)

Variable	Media	D.E.	Mín.	Máx.
inv	146.0	216.9	0.9	1486.7
value	1081.7	1314.5	58.1	6241.7
capital	276.0	301.1	0.8	2226.3

6.10.2 Estimación de los tres modelos

Cuadro 6.4: Comparación de coeficientes: Pooled, EF y EA

Variable	Pooled OLS	Efectos Fijos	Efectos Aleatorios
value	0.1156	0.1101	0.1098
capital	0.2307	0.3101	0.3081

6.10.3 Test de Hausman

El test de Hausman arroja un estadístico $H = 2.33$ con p-valor =0.3119. No se rechaza H_0: el estimador de **efectos aleatorios** es adecuado.

6.10.4 Diagnósticos

El test F de efectos individuales arroja un estadístico $F = 49.18$ con p-valor =0.0000, lo que confirma que los efectos individuales son altamente significativos: las 10 empresas difieren sustancialmente entre sí.

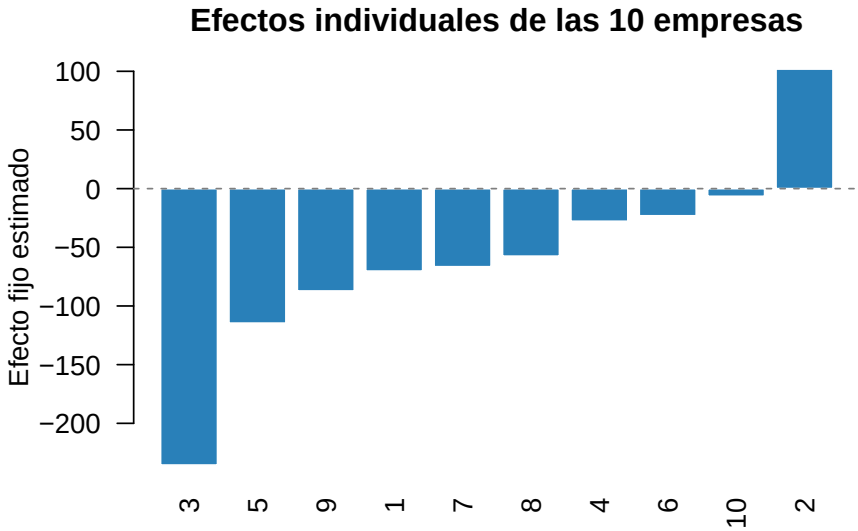

Figura 6.2: Efectos fijos individuales estimados: cada empresa tiene un nivel de inversión base distinto.

6.11 Extensiones

6.11.1 Efectos fijos bidireccionales

En muchas aplicaciones es conveniente incluir efectos fijos tanto **individuales** como **temporales**:

$$y_{it} = \alpha_i + \lambda_t + \mathbf{x}'_{it}\beta + \varepsilon_{it}$$

Los efectos temporales λ_t capturan perturbaciones comunes a todos los individuos en un período determinado: crisis económicas, cambios legislativos, fluctuaciones macroeconómicas. En R se implementan añadiendo `factor(año)` a la fórmula o con la opción `effect = "twoways"` en `plm()`.

6.11.2 Difference-in-Differences (DiD)

El diseño de Diferencias en Diferencias es una de las aplicaciones más importantes de los datos de panel en evaluación de políticas. El modelo estándar es:

$$y_{it} = \alpha + \gamma \cdot \text{tratado}_i + \delta \cdot \text{post}_t + \tau \cdot (\text{tratado}_i \times \text{post}_t) + \varepsilon_{it}$$

El coeficiente τ estima el **efecto causal del tratamiento** bajo el supuesto de **tendencias paralelas**: en ausencia del tratamiento, el grupo tratado habría evolucionado de forma paralela al grupo de control.

6.11.3 Paneles dinámicos

Cuando la variable dependiente actual depende de su propio valor pasado ($y_{it} = \rho y_{i,t-1} + \mathbf{x}'_{it}\beta + \alpha_i + \varepsilon_{it}$), el estimador de efectos fijos es sesgado en paneles cortos (sesgo de Nickell). La solución estándar es el estimador de **Arellano-Bond** (1991), que utiliza valores retardados como instrumentos tras tomar primeras diferencias. En R se implementa con `pgmm()` del paquete `plm`.

6.12 Resumen: lo esencial en 10 puntos

1. Los **datos de panel** observan a los mismos individuos a lo largo del tiempo. Su estructura bidimensional (i, t) permite controlar la heterogeneidad no observada.
2. La variación total se descompone en **within** (cambios dentro de cada individuo) y **between** (diferencias entre individuos). Los estimadores de panel explotan una u otra según sus supuestos.
3. El **modelo general** es $y_{it} = \alpha_i + \mathbf{x}'_{it}\beta + \varepsilon_{it}$, donde α_i es el efecto individual no observado.
4. **Pooled OLS** ignora la estructura de panel. Es inconsistente si α_i está correlacionado con $\mathbf{x}_{it}$.
5. El estimador de **efectos fijos** (within) elimina α_i restando las medias individuales. Es consistente siempre, pero no identifica variables invariantes en el tiempo.
6. El estimador de **efectos aleatorios** supone $\text{Cov}(\alpha_i, \mathbf{x}_{it}) = 0$ y combina variación within y between. Es más eficiente que EF si el supuesto se cumple, pero inconsistente si se viola.
7. El **test de Hausman** compara EF y EA. Si rechaza H_0 $(p < 0.05)$, usar efectos fijos. Si no rechaza, efectos aleatorios es preferible.
8. Los **diagnósticos** esenciales son: test F (existencia de efectos), test LM de Breusch-Pagan, test de Wooldridge (autocorrelación) y errores robustos agrupados.
9. Los **efectos fijos bidireccionales** añaden dummies temporales para controlar perturbaciones comunes a todos los individuos.
10. En **paneles dinámicos** ($y_{i,t-1}$ como regresor), el estimador within es sesgado. Se utiliza GMM (Arellano-Bond, Blundell-Bond).

6.13 Funciones esenciales en R

6.13.1 Estimación

- `plm(y ~ x1 + x2, data = datos_panel, model = "pooling")` — Pooled OLS
- `plm(y ~ x1 + x2, data = datos_panel, model = "within")` — efectos fijos
- `plm(y ~ x1 + x2, data = datos_panel, model = "random")` — efectos aleatorios
- `plm(y ~ x1 + x2, data = datos_panel, model = "fd")` — primeras diferencias

6.13.2 Efectos individuales

- `fixef(modelo_fe)` — efectos fijos estimados
- `ranef(modelo_re)` — efectos aleatorios predichos

6.13.3 Tests

- `pFtest(modelo_fe, modelo_pooled)` — F: pooled vs EF
- `plmtest(modelo_pooled, type = "bp")` — LM: pooled vs EA
- `phtest(modelo_fe, modelo_re)` — Hausman

6.13.4 Diagnóstico

- `pwartest(modelo_fe)` — autocorrelación (Wooldridge)
- `pbgtest(modelo_fe)` — autocorrelación (Breusch-Godfrey)
- `pcdtest(modelo_fe, test = "cd")` — dependencia transversal

6.13.5 Errores robustos

- `coeftest(modelo, vcov = vcovHC(modelo, type = "HC1", cluster = "group"))`

6.13.6 Paneles dinámicos

- `pgmm(y ~ lag(y, 1) + x1 | lag(y, 2:99), data = datos_panel, effect = "twoways", model = "twosteps")`

Código R del capítulo

El script completo de este capítulo (`T05_mECO_Script_Panel.R`) está disponible en el repositorio de material complementario del manual:

https://github.com/carlanta/MicroEconometrics

El alumno puede descargar el script directamente desde la carpeta `scripts/` del repositorio y ejecutarlo en RStudio de forma interactiva.

Bibliografía

Referencias generales de microeconometría

- Cameron, A. C. y Trivedi, P. K. (2005). *Microeconometrics: Methods and Applications*. Cambridge University Press.
- Greene, W. H. (2018). *Econometric Analysis* (8ª ed.). Pearson.
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*. MIT Press.
- Wooldridge, J. M. (2019). *Introductory Econometrics: A Modern Approach* (7ª ed.). Cengage.
- Stock, J. H. y Watson, M. W. (2019). *Introduction to Econometrics* (4ª ed.). Pearson.
- Long, J. S. y Freese, J. (2014). *Regression Models for Categorical Dependent Variables Using Stata* (3ª ed.). Stata Press.

Modelos de elección discreta (Capítulo 2)

- McFadden, D. (1974). "Conditional Logit Analysis of Qualitative Choice Behavior". En Zarembka, P. (ed.), *Frontiers in Econometrics*. Academic Press.

Modelos para datos censurados (Capítulo 3)

- Tobin, J. (1958). "Estimation of Relationships for Limited Dependent Variables". *Econometrica*, 26(1), 24-36.
- Heckman, J. J. (1979). "Sample Selection Bias as a Specification Error". *Econometrica*, 47(1), 153-161.
- Olsen, R. J. (1978). "Note on the Uniqueness of the Maximum Likelihood Estimator for the Tobit Model". *Econometrica*, 46(5), 1211-1215.
- McDonald, J. F. y Moffitt, R. A. (1980). "The Uses of Tobit Analysis". *Review of Economics and Statistics*, 62(2), 318-321.

Modelos para datos de recuento (Capítulo 4)

- Cameron, A. C. y Trivedi, P. K. (2013). *Regression Analysis of Count Data* (2ª ed.). Cambridge University Press.
- Hausman, J. A., Hall, B. H. y Griliches, Z. (1984). "Econometric Models for Count Data with an Application to the Patents-R&D Relationship". *Econometrica*, 52(4), 909-938.

- Akaike, H. (1973). "Information Theory and an Extension of the Maximum Likelihood Principle". En Petrov, B. N. y Csáki, F. (eds.), *2nd International Symposium on Information Theory*. Akadémiai Kiadó.
- Schwarz, G. (1978). "Estimating the Dimension of a Model". *Annals of Statistics*, 6(2), 461-464.
- Burnham, K. P. y Anderson, D. R. (2002). *Model Selection and Multimodel Inference* (2ª ed.). Springer.

Datos de panel (Capítulo 5)

- Baltagi, B. H. (2021). *Econometric Analysis of Panel Data* (6ª ed.). Springer.
- Arellano, M. (2003). *Panel Data Econometrics*. Oxford University Press.
- Hausman, J. A. (1978). "Specification Tests in Econometrics". *Econometrica*, 46(6), 1251-1271.
- Arellano, M. y Bond, S. (1991). "Some Tests of Specification for Panel Data: Monte Carlo Evidence and an Application to Employment Equations". *Review of Economic Studies*, 58(2), 277-297.
- Grunfeld, Y. (1958). *The Determinants of Corporate Investment*. Tesis doctoral no publicada, Universidad de Chicago.

Tests y diagnóstico

- Shapiro, S. S. y Wilk, M. B. (1965). "An Analysis of Variance Test for Normality". *Biometrika*, 52(3-4), 591-611.
- Jarque, C. M. y Bera, A. K. (1980). "Efficient Tests for Normality, Homoscedasticity and Serial Independence of Regression Residuals". *Economics Letters*, 6(3), 255-259.
- Bartlett, M. S. (1937). "Properties of Sufficiency and Statistical Tests". *Proceedings of the Royal Society A*, 160(901), 268-282.
- Kass, R. E. y Raftery, A. E. (1995). "Bayes Factors". *Journal of the American Statistical Association*, 90(430), 773-795.